



Universidad Politécnica
de Madrid

**Escuela Técnica Superior de
Ingenieros Informáticos**



Grado en Ciencia de Datos e Inteligencia Artificial

Trabajo Fin de Grado

**Evaluación Neurofisiológica del Esfuerzo
Cognitivo en Pilotos mediante Machine
Learning, DNN y EEG en Simuladores de
Vuelo**

Autor: Daniel Llopis Conejo

Tutor(a): Laura Melgar García, Javier Bajo Pérez

Madrid, Junio 2025

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado

Grado en Ciencia de Datos e Inteligencia Artificial

Título: Evaluación Neurofisiológica del Esfuerzo Cognitivo en Pilotos mediante Machine Learning, DNN y EEG en Simuladores de Vuelo

Junio 2025

Autor: Daniel Llopis Conejo

Tutor: Laura Melgar García, Javier Bajo Pérez
Departamento de Inteligencia Artificial
Escuela Técnica Superior de Ingenieros Informáticos
Universidad Politécnica de Madrid

Agradecimientos

Primero de todo a mi madre, por apoyarme siempre a cumplir cada uno de mis sueños y por nunca dejar de creer en mí. No hubiera llegado aquí de no ser por ti. Te quiero mamá.

A mi padre, por ser mi ejemplo a seguir y mi claro ejemplo de fuerza, dedicación y esfuerzo. Eres el pilar fundamental de mi vida. Te quiero papá.

A mi hermano, espero estar siendo un buen guía.

A mis abuelos Loli y Pepe, por enseñarme que la unión y el amor son imprescindibles para alcanzar el éxito. Espero que me sigáis viendo crecer durante mucho tiempo.

A mis tíos, tías, primos y primas, especialmente a mi tía Pilar y a mi prima Nerea, por ser como mis segundas madres durante toda mi vida.

A Rubén, por darme fuerza siempre y acompañarme durante todo este camino. Gracias.

A Mariasun, por ser mi apoyo incondicional y sentir cada paso que he dado como si suyo fuera.

A Alba, la mejor compañera y persona que me ha podido dar la universidad. Espero no perderte nunca.

A Uma, Claudia, Luana, Marc y Rodrigo, por haberse convertido en mi familia madrileña. Gracias por estos 4 años. Espero que sean muchos más.

Al resto de mis amigos, tanto ilicitanos como madrileños, me considero muy afortunado de contar con cada uno de vosotros y de haberos hecho partícipes de este reto que me ha supuesto la carrera. Muchas gracias a todos.

A mis tutores, Laura y Javier. No puedo estar más contento por haber realizado este trabajo con vosotros. Gracias por cada consejo y por hacerme crecer profesionalmente.

A mi yayo Juan. Tú y tu enfermedad despertasteis en mí el interés por este mundo, por entenderlo y por intentar solucionarlo. Espero que allá donde estés, estés orgulloso de mí. Va por ti.

Pero si hay alguien a quien quiero agradecer y dedicar este trabajo es a su mujer, mi yaya Encarni. Te tengo más presente que nunca. Quiero darte aliento y fuerza. Se repite la batalla, pero ésta la vamos a ganar. Te quiero, nunca lo olvides.

Resumen

El objetivo general del proyecto fue investigar el uso combinado de señales neurológicas (principalmente electroencefalografía, EEG) y técnicas de inteligencia artificial para analizar y detectar distintos niveles de carga cognitiva en contextos críticos, especialmente enfocado a pilotos de avión. En otras palabras, se buscó caracterizar la relación entre la actividad cerebral medida mediante EEG y el grado de carga mental, con el fin de desarrollar modelos predictivos capaces de identificar estados de alta demanda cognitiva con alta precisión y fiabilidad.

Para el desarrollo del proyecto se utilizó un conjunto de datos público con registros EEG (y adicionales como ECG) obtenidos de sujetos realizando tareas con diferentes niveles de carga mental. Estas tareas incluían escenarios con distintas dificultades teóricas, proporcionando etiquetas iniciales de carga cognitiva basadas en la dificultad de la tarea (dificultad teórica) y en la percepción subjetiva de los participantes (dificultad percibida). Durante un análisis exploratorio inicial se observó que las medidas subjetivas de carga (como la dificultad percibida por los usuarios) no correlacionaban de forma consistente con los indicadores fisiológicos de EEG/ECG. Por ello, como parte de la metodología se definió una nueva variable objetiva de carga cognitiva fundamentada en las señales EEG, buscando un indicador más fiable de la carga mental real.

El preprocesamiento de los datos EEG fue una etapa crucial. Se aplicaron filtros y técnicas de limpieza para eliminar ruido de alta/baja frecuencia e interferencias de la red eléctrica, y se removieron artefactos comunes (movimientos, parpadeos) utilizando métodos especializados, mejorando la relación señal/ruido. Adicionalmente, las señales fueron normalizadas y segmentadas según las distintas fases de las tareas cognitivas. Sobre las señales depuradas se realizó una extracción sistemática de características (feature extraction) para condensar la información cerebral en descriptores numéricos útiles para los modelos de IA. En concreto, se extrajeron características en el dominio temporal y características en el dominio frecuencial. También se incluyeron índices derivados como la relación theta/alpha, la entropía espectral de la señal y medidas de asimetría entre hemisferios, todos ellos indicadores potenciales del estado cognitivo.

Sobre la base de datos preprocesada y caracterizada, se entrenaron múltiples modelos predictivos para clasificar el nivel de carga cognitiva. Por un lado, se desarrolló una red neuronal profunda (DNN) adaptada al problema: una arquitectura tipo perceptrón multicapa completamente conectada, con una capa inicial que incluye ruido gaussiano, diversos bloques Dense $\rightarrow$ LeakyReLU $\rightarrow$ BatchNorm $\rightarrow$ Dropout, y una capa final Dense con 3 unidades. Esta red neuronal (DNN) fue diseñada considerando estructuras utilizadas en estudios previos, pero incorporando mejoras para nuestro

caso de uso. En paralelo, se probaron algoritmos de machine learning más clásicos, destacando un modelo de Gradient Boosting entrenado utilizando las características extraídas de las señales EEG. El uso de Gradient Boosting brinda un enfoque complementario al de la red neuronal, al construir un modelo robusto a partir de conjuntos de características de entrada y combinar múltiples árboles débiles en un predictor fuerte.

La evaluación de los modelos se realizó mediante experimentos controlados de clasificación sobre los datos etiquetados de carga cognitiva. Las predicciones de cada modelo se compararon con los valores reales de nivel de carga (la dificultad teórica de la tarea) calculando métricas clave: la precisión global (accuracy), la sensibilidad (recall) para detectar correctamente los estados de alta carga y la especificidad para evitar falsas alarmas.

Los resultados obtenidos demuestran la viabilidad de predecir la carga cognitiva de forma automática a partir de EEG. En general, tanto la red neuronal profunda desarrollada como el modelo de Gradient Boosting lograron desempeños satisfactorios en la clasificación de niveles de carga mental, superando en precisión a enfoques previos de la literatura.

En resumen, el proyecto concluye que es posible y efectivo cuantificar la carga cognitiva de un usuario a través de señales EEG utilizando modelos de inteligencia artificial bien entrenados. Se resalta la importancia de un preprocesamiento cuidadoso (limpieza de señales y extracción de características relevantes) y de abordar adecuadamente retos como el desbalance de datos para lograr modelos confiables. Asimismo, el estudio pone de manifiesto que las medidas subjetivas de carga mental pueden no reflejar fielmente el esfuerzo cognitivo real, por lo que integrar métricas objetivas basadas en actividad cerebral resulta fundamental. El mejor modelo (Gradient Boosting) proporcionó predicciones precisas y balanceadas, demostrando que técnicas de machine learning tradicionales, combinadas con una buena selección de características EEG, pueden igualar o superar a arquitecturas profundas en este contexto específico. En conjunto, los modelos predictivos de carga cognitiva desarrollados permitieron distinguir con alta precisión diferentes estados mentales de los pilotos. Estos hallazgos sientan las bases para el desarrollo futuro de sistemas de monitorización en tiempo real del estado cognitivo en entornos de alta exigencia (como la cabina de vuelo), lo que podría ayudar a prevenir sobrecargas de trabajo y a optimizar el rendimiento cognitivo de los operadores en situaciones críticas.

Abstract

The overall objective of the project was to investigate the combined use of neurological signals (primarily electroencephalography, EEG) and artificial intelligence techniques to analyze and detect different levels of cognitive load in critical contexts, with a special focus on airplane pilots. In other words, the aim was to characterize the relationship between brain activity measured via EEG and the degree of mental workload, in order to develop predictive models capable of identifying states of high cognitive demand with high precision and reliability.

For the project's development, a public dataset was used containing EEG recordings (and additional measures such as ECG) obtained from subjects performing tasks with varying levels of mental workload. These tasks included scenarios of different theoretical difficulty, providing initial cognitive-load labels based both on task difficulty (theoretical difficulty) and on participants' subjective perception (perceived difficulty). During an initial exploratory analysis, it was observed that subjective load measures (such as perceived difficulty) did not correlate consistently with the physiological indicators from EEG/ECG. Therefore, as part of the methodology, a new objective cognitive-load variable grounded in the EEG signals was defined, seeking a more reliable indicator of true mental workload.

EEG data preprocessing was a crucial stage. Filters and cleaning techniques were applied to remove high-/low-frequency noise and power-line interference, and common artifacts (movements, eye-blinks) were removed using specialized methods, improving the signal-to-noise ratio. Additionally, the signals were normalized and segmented according to the different phases of the cognitive tasks. On these cleaned signals, a systematic feature-extraction process was carried out to condense the brain information into numerical descriptors useful for the AI models. Specifically, temporal-domain features and frequency-domain features were extracted. Derived indices such as the theta/alpha ratio, spectral entropy of the signal, and inter-hemispheric asymmetry measures were also included—all of them potential indicators of cognitive state.

On the basis of the preprocessed and characterized dataset, multiple predictive models were trained to classify the level of cognitive load. On one hand, a deep neural network (DNN) tailored to the problem was developed: a fully connected multilayer perceptron architecture with an input layer plus Gaussian noise, several blocks of Dense $\rightarrow$ LeakyReLU $\rightarrow$ BatchNorm $\rightarrow$ Dropout, and a final Dense output layer with 3 units. This DNN was designed considering structures used in previous studies but incorporating improvements for our use case. In parallel, more classical machine-learning algorithms were tested, most notably a Gradient Boosting model trained on the features extracted from the EEG signals. The use of Gradient Boosting provides a complementary approach to the neural network by building a robust predictor from

input feature sets and combining many weak trees into a strong ensemble.

Model evaluation was carried out through controlled classification experiments on the cognitively labeled data. Each model's predictions were compared with the true load levels (theoretical task difficulty), calculating key metrics: overall accuracy, sensitivity (recall) for correctly detecting high-load states, and specificity to avoid false alarms.

The results obtained demonstrate the feasibility of automatically predicting cognitive load from EEG data. In general, both the developed deep neural network and the Gradient Boosting model achieved satisfactory performance in classifying mental-load levels, surpassing the accuracy of previous literature approaches.

In summary, the project concludes that it is both possible and effective to quantify a user's cognitive load through EEG signals using well-trained AI models. The importance of careful preprocessing (signal cleaning and relevant feature extraction) and of properly addressing challenges such as class imbalance to achieve reliable models is emphasized. Moreover, the study shows that subjective measures of mental workload may not faithfully reflect actual cognitive effort, making it essential to integrate objective brain-activity-based metrics. The best model (Gradient Boosting) provided accurate and balanced predictions, demonstrating that traditional machine-learning techniques, combined with a good selection of EEG features, can match or even outperform deep architectures in this specific context. Altogether, the developed predictive models for cognitive load enabled the high-precision discrimination of different mental states in pilots. These findings lay the groundwork for the future development of real-time cognitive-state monitoring systems in high-demand environments (such as the cockpit), which could help prevent work overloads and optimize operators' cognitive performance in critical situations.

Índice general

1. Introducción	1
1.1. Objetivos	2
1.2. Software Utilizado	3
2. Desarrollo	5
2.1. Búsqueda y Selección de la Base de Datos	5
2.1.1. Contenidos de la Base de Datos	6
2.2. Carga, Gestión y Evaluación Inicial de los Datos	8
2.3. Análisis Exploratorio (EDO)	9
2.3.1. Resumen inicial de los datasets	10
2.3.2. Estructura de los datos y tipos de variables	10
2.3.3. Estadísticas descriptivas	10
2.3.4. Distribuciones de variables clave	11
2.3.4.1. EEG	11
2.3.4.2. ECG	13
2.3.5. Análisis de Valores Nulos	18
2.3.5.1. EEG	18
2.3.5.2. ECG	19
2.3.6. Verificación de Variables con Dominio Acotado	19
2.3.7. Análisis de Variables Categóricas	21
2.3.8. Sincronización Temporal	21
2.3.9. Outliers	22
2.3.10 Análisis de Correlaciones	22
2.3.11 Estudio y Fusión de Datasets ECG	24
2.3.12 Comprobación de Interrupciones en la Captación de Datos	24
2.3.13 Análisis de la variable CQ (Contact Quality)	24
2.3.14 Análisis de Registros Duplicados	24
2.4. Preprocesamiento de los datos	24
2.4.1. Copia y validación de <i>datasets</i>	25
2.4.2. Resolución del problema de duplicados en ECG	25
2.4.2.1. Unificación y comprobación	26
2.4.3. Preparación y tratamiento de datos EEG	26
2.4.3.1. Resolución del problema de lecturas fallidas	27
2.4.3.2. Eliminación del offset	27
2.4.3.3. Filtrado de la señal EEG	28
2.4.3.4. Downsampling	29
2.4.3.5. Eliminación de artefactos mediante ICA	30
2.4.3.5.1. FastICA	30

2.4.3.5.2. MNE-ICA	32
2.4.3.5.3. MNE-ICA individualmente por Sujeto	35
2.5. Extracción de Características	38
2.5.1. Justificación de la Segmentación	38
2.5.2. Características en el Dominio del Tiempo	39
2.5.3. Características en el Dominio de la Frecuencia	39
2.5.4. Integración con Variables del Protocolo Experimental	40
2.6. Creación de una variable objetiva de carga cognitiva	40
2.6.1. ¿Por qué es mejor esta variable que <code>theoretical_difficulty</code> o <code>perceived_difficulty</code> ?	42
2.6.2. Validación de resultados obtenidos	42
2.6.3. Conclusión	44
2.7. Creación de los modelos de IA	45
2.7.1. Regresión Logística	45
2.7.2. K-Nearest Neighbors (K-NN)	45
2.7.3. Random Forest	45
2.7.4. Support Vector Machines (SVM)	45
2.7.5. XGBoost	46
2.7.6. Gradient Boosting	46
2.7.7. Red Neuronal	46
2.7.7.1. Red Neuronal utilizada en estudios previos	46
2.7.7.2. Red Neuronal elaborada	47
2.7.7.2.1. Redes Neuronales Probadas y Selección del Mo- delo Final	47
2.7.7.2.2. Detalle de la Arquitectura Medium	48
2.7.7.2.3. Técnicas Utilizadas	48
2.8. Experimentación	50
2.8.1. Equipamiento EEG	50
2.8.2. Software y diseño experimental	51
2.8.3. Diseño alternativo propuesto	54
2.8.4. Resultados	54
2.8.4.1. Exploración y Preprocesamiento	54
2.8.4.2. Predicciones	57
2.8.5. Conclusiones	58
3. Resultados y conclusiones	60
3.1. Objetivo del análisis y métricas de evaluación	60
3.2. Comparativa de modelos de clasificación	62
3.2.1. Regresión Logística (RL)	62
3.2.2. K-Nearest Neighbors (KNN)	63
3.2.3. Máquina de Vectores de Soporte (SVM)	65
3.2.4. Random Forest	66
3.2.5. XGBoost	68
3.2.6. Gradient Boosting (GB)	69
3.3. Importancia de las características y aportes de las nuevas variables	71
3.4. Resultados de la Red Neuronal Elaborada	73
3.4.1. Análisis de la Red Neuronal DNN Propuesta	73
3.4.2. Proceso de Entrenamiento y Estabilidad	74
3.4.3. Resultados Obtenidos con la DNN	75

3.4.4. Justificación de Técnicas Utilizadas	76
3.5. Modelo recomendado	77
3.6. Conclusiones Personales	78
3.7. Trabajo Futuro	79
4. Impacto del trabajo	82
4.1. Impacto general	82
4.1.1. Impacto en el ámbito personal	82
4.1.2. Impacto en el ámbito empresarial	82
4.1.3. Impacto en el ámbito social	83
4.1.4. Impacto en el ámbito económico	83
4.1.5. Impacto en el ámbito medioambiental	83
4.1.6. Impacto en el ámbito cultural	84
4.2. Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030	84
4.2.1. ODS 3: Salud y Bienestar (Garantizar una vida sana y promover el bienestar para todos)	84
4.2.2. ODS 8: Trabajo Decente y Crecimiento Económico (Promover el crecimiento económico inclusivo y el trabajo decente)	85
4.2.3. ODS 9: Industria, Innovación e Infraestructura (Construir infraestructuras resilientes, promover la industrialización sostenible y fomentar la innovación)	85
4.2.4. Otros ODS relevantes	85
4.2.5. Decisiones del proyecto basadas en consideraciones de impacto .	86
Bibliografía	88
A. Anexo	93

Capítulo 1

Introducción

La evaluación precisa de la carga cognitiva se ha convertido en una cuestión fundamental debido al impacto significativo que tiene sobre el desempeño humano en áreas críticas como la educación, medicina, transporte, aviación e incluso en la gestión de recursos humanos en contextos laborales exigentes. La carga cognitiva se define como el esfuerzo mental requerido por un individuo para realizar una tarea específica, esfuerzo que está influenciado por diversos factores como la complejidad de la tarea, las habilidades previas, el entorno y la presión temporal, entre otros [1].

Dentro de las técnicas empleadas para evaluar la carga cognitiva, destaca la electroencefalografía (EEG), un método no invasivo que mide la actividad eléctrica cerebral mediante electrodos colocados sobre el cuero cabelludo. Estos sensores registran variaciones en los potenciales eléctricos generados por la actividad neuronal del cerebro, cuya principal ventaja es su alta resolución temporal, permitiendo capturar cambios rápidos en la actividad cerebral y relacionarlos directamente con fluctuaciones en la carga cognitiva [2].

Las señales EEG se pueden analizar en diferentes rangos de frecuencia, comúnmente conocidos como ondas cerebrales, las cuales están asociadas con estados cognitivos y emocionales específicos:

- **Ondas delta (0.5–4 Hz):** Asociadas generalmente a estados de sueño profundo o relajación profunda; también presentes en situaciones de daño cerebral o disfunción cerebral severa.
- **Ondas theta (4–8 Hz):** Comúnmente relacionadas con estados de somnolencia, meditación profunda y tareas que requieren concentración y procesamiento en la memoria.
- **Ondas alfa (8–13 Hz):** Predominantes en estados de relajación y descanso mental; su reducción está relacionada con un aumento de la atención visual y procesos cognitivos activos.
- **Ondas beta (13–30 Hz):** Relacionadas con estados activos de pensamiento, concentración y resolución de problemas, incrementándose significativamente en situaciones de alta demanda cognitiva o estrés.
- **Ondas gamma (>30 Hz):** Vinculadas a funciones cognitivas superiores como la percepción, atención enfocada, resolución de problemas complejos y procesa-

miento avanzado de información.

Recientemente, las técnicas de inteligencia artificial (IA) y *machine learning* han experimentado avances significativos aplicados al análisis de datos EEG. Métodos tradicionales como máquinas de vectores de soporte (SVM), árboles de decisión y regresión logística han sido ampliamente utilizados para clasificar niveles de carga cognitiva a partir de características extraídas manualmente, aunque con ciertas limitaciones derivadas de la selección manual de estas características, lo que puede introducir sesgos [3]. En contraste, técnicas recientes de aprendizaje profundo (*deep learning*), como las redes neuronales convolucionales (CNN) y redes neuronales recurrentes (RNN), han demostrado un gran potencial al permitir la extracción automática de características relevantes directamente desde los datos brutos, mejorando considerablemente la precisión y robustez en la clasificación de la carga cognitiva [4]. Además, enfoques híbridos como CNN-RNN combinan análisis espacial y modelado de dependencias temporales, logrando resultados aún más prometedores.

1.1. Objetivos

Este Trabajo Fin de Grado tiene como objetivo investigar profundamente el uso combinado de EEG e inteligencia artificial para analizar y detectar estados específicos de carga cognitiva, particularmente orientado al desarrollo de modelos predictivos aplicados a pilotos de aviones. El propósito último es contribuir a gestionar y optimizar el rendimiento cognitivo en contextos críticos como la aviación, mejorando la seguridad operacional y la eficiencia en la gestión de recursos.

El objetivo general del presente trabajo es, entonces, explorar y caracterizar la relación existente entre señales neurofisiológicas obtenidas mediante EEG y distintos niveles de carga cognitiva, desarrollando modelos basados en IA que permitan identificar y predecir dichos niveles con alta precisión y fiabilidad.

Los objetivos específicos del trabajo incluyen:

- Realizar una revisión exhaustiva y crítica del estado del arte sobre técnicas y herramientas de análisis de datos e IA aplicadas a la evaluación de la carga cognitiva mediante EEG.
- Seleccionar, limpiar y preprocesar adecuadamente bases de datos EEG existentes, aplicando técnicas específicas para la reducción de ruido, eliminación de artefactos y normalización de señales para garantizar la calidad de los datos.
- Diseñar, desarrollar e implementar modelos avanzados basados en algoritmos de aprendizaje automático y aprendizaje profundo, capaces de identificar patrones distintivos asociados con variaciones en la carga cognitiva.
- Validar rigurosamente los modelos propuestos mediante análisis y experimentos con bases de datos públicas existentes, evaluando métricas de rendimiento como precisión, sensibilidad, especificidad y la robustez de los modelos frente a diferentes escenarios.
- (Opcional) Realizar capturas experimentales adicionales utilizando neurosensores EEG del grupo de investigación, estableciendo protocolos específicos que permitan inducir situaciones controladas con cargas cognitivas variables.

- (Opcional) Aplicar y evaluar los modelos desarrollados sobre los datos reales capturados experimentalmente, validando su eficacia y capacidad de generalización en contextos reales.
- Documentar claramente todo el procedimiento seguido, desde el desarrollo hasta la validación de los modelos, aportando conclusiones significativas que sirvan de base para futuras investigaciones y aplicaciones prácticas en la monitorización y gestión efectiva de la carga cognitiva.

1.2. Software Utilizado

Para el desarrollo de este proyecto se empleó principalmente el lenguaje de programación **Python**, dada su versatilidad en tareas de ciencia de datos y análisis de señales. Python cuenta con un amplio ecosistema de bibliotecas especializadas que facilitaron tanto el preprocesamiento de las señales EEG como la implementación de algoritmos de Machine Learning (aprendizaje automático) y modelos de redes neuronales profundas (DNN). A continuación, se describen las principales herramientas software utilizadas durante el desarrollo:

- **NumPy**: biblioteca fundamental para cálculos numéricos eficientes con matrices y vectores. Se utilizó para manipular y procesar los datos crudos de EEG en forma de arrays, aprovechando operaciones vectorizadas que optimizan el rendimiento en comparación con la implementación de bucles tradicionales en Python.
- **Pandas**: biblioteca de manipulación de datos tabulares (estructuras DataFrame). Facilitó la organización y limpieza de los datos experimentales, permitiendo manejar grandes conjuntos de registros (marcadores de eventos, etiquetas de condiciones y características extraídas) de forma conveniente. Con Pandas se pudieron fusionar y alinear las señales EEG con la información de las tareas y respuestas de los sujetos de manera eficiente.
- **Matplotlib**: biblioteca de visualización de datos que permitió generar gráficas tanto para el análisis exploratorio de las señales como para la presentación de resultados. Se empleó para trazar las series temporales de EEG, visualizar espectros de frecuencia, y resumir el desempeño de los modelos (curvas de aprendizaje, matrices de confusión, etc.), proporcionando representaciones visuales claras que apoyan la interpretación de los hallazgos.
- **MNE-Python**: biblioteca especializada en el procesamiento de señales electroencefalográficas. Se empleó MNE para cargar los datos EEG crudos desde el dispositivo de adquisición, aplicar filtros digitales (para aislar rangos de frecuencia de interés) y segmentar las señales en épocas correspondientes a eventos o estímulos definidos en el experimento. Además, MNE proporcionó métodos avanzados de preprocesamiento; en particular, se utilizó su implementación de Análisis de Componentes Independientes (ICA) para detectar y remover artefactos fisiológicos de las señales (tales como parpadeos o movimientos musculares), preservando así las características neuronales relevantes antes de alimentar los datos al modelo de Machine Learning [5].
- **Scikit-learn**: conjunto ampliamente utilizado de herramientas de Machine Learning de propósito general. En este proyecto se empleó para implementar algorit-

mos clásicos de clasificación como método comparativo (máquinas de vectores de soporte o bosques aleatorios, utilizados como línea base para contrastar con la DNN). Asimismo, scikit-learn facilitó la validación de los modelos mediante técnicas de re-muestreo como la validación cruzada y proporcionó utilidades para la selección de características más relevantes y la normalización de los datos (escalado de atributos, estandarización), elementos cruciales para un entrenamiento adecuado de los algoritmos.

- **TensorFlow (con la API Keras):** plataforma de aprendizaje profundo utilizada para construir y entrenar la red neuronal profunda desarrollada. A través de Keras se definió la arquitectura del modelo DNN (capas, neuronas, funciones de activación, etc.), mientras que el backend de TensorFlow gestionó el cálculo distribuido y acelerado por GPU durante el entrenamiento. Esta combinación permitió entrenar modelos de alta complejidad de forma eficiente sobre los datos EEG, aprovechando la paralelización para reducir los tiempos de cómputo, y facilitó la experimentación con diferentes configuraciones de hiperparámetros de la red neuronal.

Además de estas bibliotecas de análisis y modelado, para la fase experimental del estudio se emplearon herramientas especializadas en el diseño de experimentos y la presentación de estímulos en entornos controlados:

- **PsyToolkit:** plataforma en línea para diseñar y ejecutar experimentos conductuales. En este proyecto se utilizó PsyToolkit para implementar la tarea cognitiva (un test de memoria N-Back de nivel 2 [6]) que realizaban los pilotos durante la sesión de simulación. La herramienta permitió presentar estímulos visuales y registrar las respuestas de los participantes junto con marcas de evento temporales, facilitando la sincronización básica entre la secuencia de estímulos y la grabación de EEG. PsyToolkit ofreció una solución rápida sin necesidad de instalar software adicional, proporcionando un entorno web interactivo donde se controló la lógica del experimento y se almacenaron los datos de comportamiento de forma estructurada [7].
- **PsychoPy:** biblioteca de Python de código abierto orientada a la creación de experimentos psicológicos y neurocientíficos con alta precisión temporal. Si bien las pruebas conductuales principales se llevaron a cabo con PsyToolkit, PsychoPy se consideró para escenarios extendidos que requirieran mayor control local sobre la presentación de estímulos. Esta herramienta permite desplegar estímulos visuales y auditivos con sincronización en el orden de milisegundos, registrar pulsaciones de teclado o respuestas del sujeto con mínima latencia, e incluso interactuar con hardware externo. PsychoPy resultaría especialmente útil para futuros experimentos más complejos o inmersivos en simuladores de vuelo, ya que brinda la flexibilidad de programar paradigmas a medida e integrar la adquisición de señales EEG de manera más directa en tiempo real [8].

Capítulo 2

Desarrollo

2.1. Búsqueda y Selección de la Base de Datos

Para realizar un análisis riguroso sobre la carga cognitiva utilizando señales electroencefalográficas (EEG) y técnicas avanzadas de inteligencia artificial, era fundamental disponer de una base de datos adecuada y suficientemente completa. Por ello, la primera etapa del desarrollo de este trabajo consistió en una exhaustiva exploración y evaluación de diversas fuentes disponibles para obtener los datos necesarios.

Se evaluaron inicialmente diferentes fuentes para encontrar una base de datos que cumpliera con los requisitos específicos del estudio, principalmente relacionados con la disponibilidad de señales EEG adecuadas, suficientes datos sobre situaciones específicas que indujeran niveles diferenciados de carga cognitiva, y acceso abierto o relativamente sencillo.

Entre las bases de datos exploradas estuvo AdaBase (Autonomous Driving Cognitive Load Assessment Database), una extensa fuente que incluía diversas medidas fisiológicas adicionales como ECG, EMG, EDA y respiración [9]. Sin embargo, tras el procedimiento de firma de un acuerdo de uso por parte de mi tutor y analizarla, nos dimos cuenta de que no existían datos para EEG, por lo que fue descartada a pesar de ser una muy buena opción.

Otra base considerada fue el Digit Span Working Memory Load Dataset alojado en OpenNeuro, que contenía EEG de alta densidad junto con datos de pupilometría y ECG [10]. A pesar de su riqueza en datos y adecuada estructura, su volumen extremadamente elevado (aproximadamente 100 GB) dificultaba significativamente su manejo y procesamiento para los fines prácticos del presente estudio.

El STEW (Simultaneous Task EEG Workload) Dataset fue otra alternativa inicialmente prometedora, debido a su facilidad de acceso y sus señales EEG claramente estructuradas para multitareas [11]. Aunque estaba disponible abiertamente en IEEE DataPort, este dataset se descartó finalmente debido a que el contexto experimental (multitarea simple sin simulación específica de aviación) no se alineaba de forma suficiente con el objetivo concreto de evaluar carga cognitiva en pilotos .

El CL-Drive Dataset, centrado en conductores en un simulador inmersivo, también resultaba potencialmente interesante debido a sus datos multimodales sincronizados (EEG, ECG, EDA y seguimiento ocular) [12]. Sin embargo, fue descartado debido a su

2.1. Búsqueda y Selección de la Base de Datos

enfoque específico en conducción automovilística, alejándose del ámbito de aplicación aérea del presente trabajo .

Finalmente, tras evaluar todas las opciones, se decidió utilizar el “Dataset to predict mental workload based on physiological data” proporcionado por la Universidad Autónoma de Barcelona (UAB) [13]. Este conjunto ofrecía exactamente los tipos de datos requeridos: señales EEG sincronizadas obtenidas en contextos específicos relacionados directamente con la aviación (simulador Airbus A320) y tareas cognitivas controladas (pruebas N-back y videojuego multitarea “Heat-the-Chair”). Además, presentaba una estructura clara, una licencia abierta, fácil acceso público y suficiente volumen de información para entrenar y validar robustamente modelos de inteligencia artificial. El registro se llevó a cabo con el dispositivo EEG Emotiv Epoc X, con 14 electrodos y muestreo a 128 Hz, características ideales para este estudio .

Por tanto, la base de datos seleccionada cumplió todos los requisitos técnicos y logísticos del proyecto, facilitando la realización posterior del análisis y desarrollo del modelo predictivo de inteligencia artificial orientado a evaluar y gestionar la carga cognitiva en pilotos.

2.1.1. Contenidos de la Base de Datos

La base de datos seleccionada para este estudio, como ya mencionamos anteriormente, es el “Dataset to predict mental workload based on physiological data” [13]. Este dataset fue diseñado específicamente para la evaluación y reconocimiento de diferentes niveles de carga cognitiva mediante señales EEG.

El objetivo principal es explorar y cuantificar el impacto del aumento de la carga mental en pilotos durante la realización de tareas rutinarias de vuelo, especialmente en situaciones críticas que incluyen eventos inesperados como ráfagas de viento, fallos en la maquinaria o advertencias del equipo, entre otros.

El dataset incluye registros EEG obtenidos a través de tres experimentos diferentes diseñados para inducir diferentes niveles de carga cognitiva:

1. *Primer experimento*: implicó la realización del test N-back, que combina la memoria con habilidades aritméticas. Los participantes se enfrentaron a tres variantes del test (posicional, aritmética y dual), diseñadas para inducir carga cognitiva baja, media y alta respectivamente.
2. *Segundo experimento*: se utilizó el juego “Heat-the-Chair”, un juego serio diseñado específicamente para simular la presión y multitarea experimentada por pilotos, exigiendo atención simultánea a múltiples tareas bajo condiciones controladas. Incluyó datos EEG de alta densidad junto con datos de pupilometría y ECG, además de puntuaciones de juego y resultados de cuestionarios NASA-TLX.
3. *Tercer experimento*: consistió en simulaciones de vuelo realizadas en un simulador de Airbus A320. Dos pilotos profesionales participaron en diferentes escenarios de vuelo, enfrentándose a situaciones estándar y a eventos críticos inesperados (ráfagas de viento severas, fallos de motor, tráfico aéreo inusual) diseñados para inducir niveles diferenciados de carga mental.

Para capturar las señales EEG en estos experimentos, se utilizó el dispositivo Emo-

tiv Epoc X, caracterizado por ser portátil e inalámbrico, con 14 electrodos colocados según el sistema internacional 10–20 (véase Figura 2.1), muestreo a 128 Hz y comunicación en tiempo real vía Bluetooth. Este dispositivo proporciona tanto señales EEG en bruto (en μV) como potencias espectrales en bandas cerebrales específicas (columnas POW: delta, theta, alfa, beta baja, beta alta y gamma), facilitando un análisis detallado y preciso de la actividad cerebral bajo distintas condiciones de carga mental [14].




Figura 2.1: Ubicación de los electrodos del dispositivo Emotiv Epoc X en el cráneo durante el experimento con el que se grabaron los datos de la Base de Datos utilizada

En el experimento de simulación de vuelo, los pilotos realizaron cinco vuelos diferentes entre Barcelona y Lleida con una duración aproximada de 14 minutos cada uno. Cada vuelo tenía una dificultad teórica asignada, desde fácil hasta difícil (-1,1,2,3,4), incluyendo eventos imprevistos para evaluar el impacto en la carga cognitiva. Los datos EEG fueron recopilados continuamente desde la fase inicial (*baseline*) hasta la conclusión del vuelo, y la percepción subjetiva de la dificultad fue registrada mediante una versión adaptada del cuestionario NASA-TLX [14].

Este estudio validó rigurosamente el conjunto de datos a través de tres aspectos: correlación entre la dificultad teórica y la dificultad percibida por los participantes, diferencias significativas en los patrones temporales de EEG respecto a los niveles teóricos de dificultad, y utilidad del dataset en el entrenamiento y evaluación de modelos de inteligencia artificial.

Específicamente, para el desarrollo del presente TFG se utilizará únicamente el experimento “Flight Simulation” debido a su relevancia directa con el contexto de la aviación, proporcionando escenarios realistas que permiten evaluar con precisión el

impacto de la carga cognitiva en situaciones críticas de vuelo, objetivo principal de esta investigación.

2.2. Carga, Gestión y Evaluación Inicial de los Datos

La base de datos utilizada en este estudio está estructurada en tres experimentos diferenciados, cada uno específicamente diseñado para inducir distintos niveles de carga cognitiva. Dado que cada experimento contiene información con estructuras y formatos distintos, fue necesario realizar una gestión separada y detallada de cada conjunto de datos para asegurar una manipulación adecuada y efectiva.

Inicialmente, se identificaron tres grupos de datos correspondientes a los experimentos: Test N-back, juego Heat-the-Chair, y simulador de vuelo. Para realizar la carga y tratamiento de los datos, se utilizó Python con bibliotecas estándar para análisis de datos como Pandas. A continuación, se detalla el proceso llevado a cabo para cada uno de los experimentos:

1. *Test N-back*: este conjunto contenía registros EEG obtenidos durante tres tareas de complejidad creciente (baja, media y alta). Los datos estaban almacenados principalmente en formato `.parquet`. Además de los registros EEG, este dataset incluía información adicional relevante, como puntuaciones obtenidas en el juego y resultados de los cuestionarios NASA-TLX relacionados con la percepción subjetiva de la carga mental. Los datos se cargaron utilizando Pandas y se verificó su integridad mediante inspección visual inicial de los dataframes generados.



Figura 2.2: Flujo del experimento N-Back

2. *Juego Heat-the-Chair*: el conjunto de datos del juego Heat-the-Chair también estaba organizado en archivos Parquet para señales EEG y ECG, y archivos CSV para almacenar información específica del rendimiento individual por sujeto y modalidad de juego (con o sin interrupciones). Igualmente, los datos subjetivos del cuestionario NASA-TLX estaban disponibles en formato `.parquet`. Al inspeccionar visualmente estos datos tras su carga en Pandas, se observó una cantidad considerable de columnas con valores ausentes (NaN), especialmente en los datos ECG, indicando una posible limitación o dificultad para su posterior análisis efectivo.




Figura 2.3: *Flujo del experimento Heat-the-Chair*

3. *Simulador de vuelo*: el dataset del simulador de vuelo contenía registros detallados de EEG obtenidos de pilotos profesionales durante vuelos simulados en condiciones controladas y escenarios críticos específicos. La información principal estaba almacenada en formato `.parquet`, complementada por archivos JSON que detallaban la dificultad cognitiva percibida por los pilotos en diferentes fases del vuelo. Al cargar estos datos con Pandas, se comprobó visualmente que los registros EEG y ECG presentaban una estructura clara, completa y sin anomalías significativas.




Figura 2.4: *Flujo del experimento Flight Simulation*

Una vez realizada la carga inicial de los datos mediante el código proporcionado, se realizó una primera evaluación visual de los dataframes resultantes para determinar la calidad inicial de la información disponible. Este análisis preliminar permitió identificar rápidamente posibles problemas de integridad o calidad de los datos, como ocurrió en el caso del juego Heat-the-Chair, donde se detectaron numerosos valores ausentes en los datos ECG.

Considerando los resultados obtenidos en la evaluación inicial, se tomó la decisión estratégica de enfocar el estudio inicial en el experimento de simulación de vuelo ("Flight Simulation"), dado que sus datos mostraban una integridad superior, coherencia estructural y directa relevancia con los objetivos específicos del proyecto: evaluar la carga cognitiva en pilotos bajo condiciones realistas y relevantes para la seguridad aérea. Esta decisión optimizó el uso de recursos computacionales y analíticos, garantizando un mayor rigor metodológico y relevancia aplicada de los resultados iniciales obtenidos en fases posteriores del análisis y desarrollo del modelo de inteligencia artificial.

2.3. Análisis Exploratorio (EDO)

Este apartado del desarrollo detalla el procedimiento, análisis y conclusiones derivadas del análisis exploratorio de los datos obtenidos durante el experimento de simulación de vuelo.

2.3.1. Resumen inicial de los datasets

En esta primera fase, realizamos una visualización preliminar de los datasets de EEG y ECG para comprender la estructura inicial de los datos obtenidos. El dataset EEG consta de 735.769 registros con 146 columnas, mientras que los datasets de ECG (HR y IBI) contienen cada uno 13.291 registros distribuidos en 8 columnas. Observamos que el dataset EEG es significativamente más extenso que los datasets de ECG, indicando una alta frecuencia de muestreo del dispositivo EEG utilizado. Se identificaron valores faltantes significativos en las columnas POW, señalando áreas críticas para el análisis posterior.

2.3.2. Estructura de los datos y tipos de variables

El siguiente paso es profundizar en la estructura de los datos y los tipos de variables que contienen. Esto nos ayuda a:

- Identificar variables disponibles: ver qué información está presente en todos los datasets, como identificadores de sujetos, marcas de tiempo (*timestamps*), indicadores de fases/experimentos, datos recogidos por los sensores, etc.
- Confirmar tipos de datos: asegurarnos de que las columnas tengan los tipos de datos correctos (numéricos, fechas, texto) para evitar problemas en el análisis.
- Detectar problemas iniciales: encontrar valores faltantes, inconsistencias en el formato y posibles valores atípicos que puedan afectar los resultados.

Para garantizar un análisis riguroso, verificamos los tipos de datos contenidos en cada dataset:

- **Timestamp** aparece en formato `float64` en ECG y `float32` en EEG.
- **Datetime** presenta formato uniforme (`datetime64[us]`) en todos los datasets, garantizando coherencia temporal.
- Predominan variables numéricas de tipo `float64` e `int64` en EEG, además de variables categóricas tipo `object`.

Esto, junto con un correcto tratamiento de los tipos de datos, facilita un posible *merge* futuro entre los datasets de ECG.

2.3.3. Estadísticas descriptivas

El análisis estadístico descriptivo es una etapa fundamental del análisis exploratorio de datos, ya que proporciona una visión general sobre las características básicas de las variables recogidas en los datasets, identificando potenciales problemas, patrones y coherencias internas. En este estudio en particular, las estadísticas descriptivas de los datasets EEG y ECG mostraron valores coherentes y acordes con las expectativas iniciales del experimento.

La revisión de los valores estadísticos básicos (media, desviación estándar, valores mínimos y máximos) permitió comprobar que los datos obtenidos eran razonables y consistentes, no revelando anomalías importantes más allá de lo anticipado. No obstante, fue especialmente relevante observar valores específicos como el «-1» en ciertas variables clave relacionadas con la dificultad percibida y teórica. Según el

diseño experimental descrito en el estudio original [14], este valor no es erróneo, sino que representa la «fase base» o de reposo en el contexto del experimento, donde se asume un nivel mínimo o ausencia de carga cognitiva.

Además, se destacó la necesidad de verificar la sincronización temporal entre los datasets EEG y ECG, dado que estos dos tipos de datos fueron registrados con dispositivos diferentes. La sincronización temporal correcta es crucial, especialmente cuando se desea realizar análisis integrados de datos provenientes de distintas fuentes sensoriales, como EEG y ECG. La comparación de los *timestamps* y *datetime* de ambos conjuntos de datos mostró una excelente coincidencia temporal, con los registros EEG y ECG compartiendo el mismo intervalo temporal, desde aproximadamente las 12:00 hasta las 13:08 del día 22 de diciembre de 2020. Esta coincidencia confirma que la adquisición de los datos fue realizada de manera simultánea y coherente, facilitando la integración y análisis conjunto posterior de estas señales fisiológicas.

Este resultado es particularmente importante, ya que cualquier discrepancia en la sincronización podría haber comprometido la validez de los análisis subsecuentes, como el estudio de correlaciones o la integración de modelos predictivos basados en ambas señales. Por tanto, haber confirmado esta sincronización refuerza la calidad general del dataset y proporciona una base sólida para los análisis posteriores.

2.3.4. Distribuciones de variables clave

2.3.4.1. EEG

Se llevó a cabo un análisis visual inicial de las señales EEG, agrupando los 14 electrodos en cuatro regiones cerebrales: superior izquierda, superior derecha, inferior izquierda e inferior derecha. Esta separación permite explorar patrones espaciales específicos y detectar diferencias iniciales entre regiones corticales distintas.




Figura 2.5: Gráficas de las 1000 primeras muestras de las señales EEG divididas por regiones cerebrales.

Al observar la Figura 2.5, se identificaron diferencias notables en términos de *offset* y amplitud entre los canales dentro de cada región. Cada canal muestra un nivel base (*offset*) ligeramente distinto, situándose alrededor de valores altos (entre 4150–4350 μV), lo cual es común en señales EEG brutas obtenidas con dispositivos como el Emotiv Epoc X [15]. Este *offset* elevado puede estar relacionado con factores inheren-

tes al equipo de medición, la impedancia de los electrodos en contacto con la piel, o incluso pequeñas variaciones en la conductividad del cuero cabelludo y movimientos sutiles del sujeto.

Además, la amplitud relativa de las señales es considerablemente alta y presenta variaciones lentas (*drift*), típico de señales sin preprocesar. Estas tendencias lentas y fluctuaciones pueden estar vinculadas con artefactos generados por movimientos oculares, musculares o interferencias eléctricas externas.

Dentro de cada región, los electrodos presentan patrones similares pero no idénticos, reflejando la actividad diferenciada entre áreas corticales próximas, pero con funciones ligeramente distintas. Esto justifica la necesidad imperiosa de un proceso riguroso de preprocesamiento que incluya técnicas como:

- Eliminación de *offset* (*baseline removal*): para centrar las señales alrededor de un valor de referencia estándar (0 μV), facilitando la comparación e interpretación de los datos.
- Filtrado con filtros notch (50 y 60 Hz): para eliminar interferencias de la red eléctrica.
- Segundo filtro cutoff de orden 4 establecido en 64 Hz para cumplir con el teorema de Nyquist-Shannon.
- Técnicas avanzadas de corrección de artefactos, como el análisis de componentes independientes (ICA), que permiten aislar y remover componentes indeseables (movimientos oculares, contracciones musculares, etc.).

Para profundizar en la relación entre la señal EEG y la dificultad percibida, se realizó un análisis exploratorio adicional mediante diagramas de caja (*boxplots*) de amplitud media segmentada por niveles de dificultad subjetiva (etiquetas -1, 0, 1, 2, 3).




Figura 2.6: *Boxplots para los valores de la variable dificultad percibida en EEG divididas para las regiones cerebrales*

Al observar la Figura 2.6, nos damos cuenta de que las amplitudes medias en μV no presentaron una diferenciación clara en función de estos niveles. Esto se debe principalmente al *offset* elevado y a la alta variabilidad de las señales EEG sin procesar. Los rangos intercuartílicos y medianas son muy similares a través de todos los niveles de dificultad, indicando que la amplitud bruta, por sí sola, no es un indicador robusto.

to ni fiable para distinguir estados cognitivos diferentes. Este resultado subraya la importancia de extraer características más avanzadas, como la potencia espectral en diferentes bandas de frecuencia (delta, theta, alfa, beta y gamma), estadísticas temporales específicas (por ejemplo, varianza, asimetría, curtosis) o indicadores derivados del análisis de sincronización cortical. Dichas características tienen mayor potencial discriminativo, reflejando cambios más sutiles y significativos en la actividad cerebral relacionada con distintos niveles de carga cognitiva.




Figura 2.7: *Boxplots para los valores de la variable dificultad teórica en EEG divididas para las regiones cerebrales*

Esta Figura 2.7 nos permite analizar las amplitudes de las dificultades teóricas en relación con las amplitudes de las regiones cerebrales mediante boxplots. Observamos un patrón común para todos ellos; las amplitudes para los valores -1 y 2 son más grandes, tal y como sucedía con la dificultad percibida.

2.3.4.2. ECG

Se realizó un análisis visual detallado de la distribución de variables clave relacionadas con la actividad cardíaca (ECG), centrado en las métricas de frecuencia cardíaca (HR) e intervalo RR (IBI).




Figura 2.8: *Distribución de HR en ECG*

En primer lugar, los histogramas de HR e IBI permitieron evaluar la distribución general de estos parámetros fisiológicos. La frecuencia cardíaca en la Figura 2.8 mostró una distribución aproximadamente normal con un rango predominante entre 80–100 latidos por minuto (bpm), consistente con los valores esperados para individuos en reposo o realizando tareas cognitivas ligeras. No obstante, se identificaron claramente valores extremos o atípicos, como instancias con HR menores a 40 bpm o superiores a 160 bpm. Estos valores extremos pueden explicarse por situaciones puntuales de estrés, nerviosismo o errores de registro durante los vuelos simulados, reflejando la necesidad de considerar técnicas específicas para gestionar estos datos extremos durante el preprocesamiento.

A continuación, se realizaron análisis más específicos mediante diagramas de caja, segmentando la frecuencia cardíaca por fase del vuelo (*baseline* vs. en vuelo).




Figura 2.9: *Boxplots para los valores de HR por fase de vuelo*

Este análisis de la Figura 2.9 mostró diferencias marcadas entre ambas fases experimentales. La fase *baseline* (preparación) presentó valores de HR mayoritariamente dentro del rango de 80–100 bpm, con algunos valores atípicos por encima de 120 bpm (esperable debido a la posible anticipación o ansiedad previa al vuelo simulado). En contraste, durante la fase de vuelo se identificó un rango más amplio con valores atípicos en ambos extremos (por debajo de 50 y por encima de 140 bpm), lo que podría indicar fluctuaciones emocionales y fisiológicas mayores, reflejando situaciones de estrés, nerviosismo o, por otro lado, posibles estados de somnolencia o relajación profunda en ciertos momentos.




Figura 2.10: *Boxplots para los valores de HR por dificultad percibida*

El análisis de HR en función de la dificultad percibida, Figura 2.10, reveló una falta de correlación clara entre la percepción subjetiva y la respuesta fisiológica. La distribución de HR, segmentada por niveles de dificultad percibida, no presentó tendencias consistentes: aunque cabría esperar que niveles más altos de dificultad conllevaran incrementos sostenidos en la frecuencia cardíaca, los datos mostraron fluctuaciones en gran medida independientes de esta percepción. Esto enfatiza la importancia de no asumir que una mayor percepción de dificultad necesariamente se reflejará en una respuesta cardíaca elevada o viceversa.




Figura 2.11: *Boxplots para los valores de HR por dificultad teórica*

En el caso de la dificultad teórica, los valores se mantienen parecidos. En la Figura 2.11 observamos que el número de outliers detectados aumenta con respecto a la dificultad percibida. No obstante, al tratarse ésta de la futura variable objetivo para los modelos de IA, los trataremos como outliers contextuales, ya que a pesar de que el boxplot en sí los detecta, realmente no son outliers, ya que entran dentro de los niveles cardíacos normales, y más teniendo en cuenta el contexto del experimento.




Figura 2.12: Evolución de HR y dificultad percibida a lo largo del experimento

Finalmente, al analizar temporalmente la evolución simultánea de la frecuencia cardíaca y la dificultad percibida en un sujeto particular durante una sesión específica, Figura 2.12, se observó que los cambios en dificultad percibida no siempre coinciden temporalmente con variaciones marcadas en la frecuencia cardíaca. Por ejemplo, episodios largos con dificultad constante se correspondieron con fluctuaciones variables del HR, sugiriendo nuevamente que la relación entre percepción subjetiva y respuesta fisiológica no es directa ni lineal.

Además del análisis anterior de la frecuencia cardíaca, se realizó un análisis exploratorio detallado de la distribución del intervalo RR (intervalo entre latidos), que refleja de manera inversa la frecuencia cardíaca (a mayor RR, menor frecuencia cardíaca, y viceversa). Esta medida es especialmente relevante dado que refleja la variabilidad de la frecuencia cardíaca (HRV), una métrica ampliamente usada para evaluar la respuesta del sistema nervioso autónomo frente a situaciones de estrés, concentración o relajación en experimentos psicofisiológicos y cognitivos [16].




Figura 2.13: Distribución de IBI en ECG

En primer lugar, analizamos en la Figura 2.13 la distribución general del IBI observada en la curva de densidad. La mayoría de las observaciones presentan intervalos RR que oscilan entre 600 y 800 ms aproximadamente, consistente con valores típicos en adultos sanos en reposo o actividad ligera [17]. Sin embargo, observamos

valores atípicos puntuales mayores a 1600 ms (indicativos de frecuencias cardíacas excepcionalmente bajas), posiblemente asociados a errores de medición, desconexiones temporales del sensor o estados transitorios muy profundos de relajación o bradicardia fisiológica [18].




Figura 2.14: *Boxplots de los valores de IBI por fase de vuelo*

Posteriormente, se llevó a cabo un análisis de los intervalos RR según la fase experimental del estudio (baseline vs vuelo). En la Figura 2.14 de tipo boxplot, apreciamos claras diferencias entre ambas fases. En la fase baseline, los intervalos RR (IBI) tienden a ser más largos (mediana alrededor de 750 ms), reflejando una frecuencia cardíaca más baja, lo que está alineado con situaciones iniciales de reposo y relajación, previas al inicio del vuelo simulado. Por otro lado, durante la fase de vuelo (flight), los intervalos RR tienden a ser significativamente menores (mediana alrededor de 650 ms), indicando un aumento general en la frecuencia cardíaca, esperable en situaciones donde existe mayor estrés cognitivo, emocional o físico [19]. Esta observación es coherente con estudios previos que han demostrado que actividades cognitivamente demandantes, como la simulación de vuelo, tienden a reducir la variabilidad RR e incrementar la frecuencia cardíaca, al reflejar una activación del sistema nervioso simpático [20].




Figura 2.15: *Boxplots de los valores de IBI por dificultad percibida*

Al observar la distribución del intervalo RR en función de la dificultad percibida sub-

jetivamente por los participantes, Figura 2.15, no se identificó una tendencia clara ni marcada. Las medianas de los intervalos RR se mantienen relativamente estables a través de los distintos niveles de dificultad percibida (-1, 0, 1, 2, 3), con una ligera variabilidad intercuartílica, pero sin una correlación evidente o progresiva con la percepción de dificultad reportada por los sujetos. Esto refuerza nuevamente la idea ya comentada en el análisis de la frecuencia cardíaca (HR): que la percepción subjetiva de los participantes sobre la dificultad de la tarea podría no reflejarse directamente y de forma proporcional en la respuesta fisiológica autonómica, representada en este caso por los intervalos RR. Tal situación ha sido ampliamente documentada en estudios previos que concluyen que la correlación directa entre percepción subjetiva y respuesta fisiológica no es trivial ni lineal, pudiendo depender de factores individuales como el entrenamiento, la experiencia previa, el estado emocional basal o las estrategias cognitivas empleadas por cada sujeto durante la tarea [21].




Figura 2.16: *Boxplots de los valores de IBI por dificultad teórica*

Finalmente, la distribución de los valores del intervalo RR por nivel de dificultad teórica (Figura 2.16) muestra patrones similares a los de la dificultad percibida. De nuevo, aparecen nuevos outliers detectados, incrementados sobre todo para el nivel 4 de dificultad teórica. En este caso cobra sentido entendiendo que este nivel es el más alto, y por tanto, el más difícil; el que más atención requerirá y más activará el sistema nervioso simpático.

2.3.5. Análisis de Valores Nulos

Realizamos un análisis exhaustivo para detectar la presencia de valores faltantes o nulos en nuestros datasets, un paso fundamental en cualquier estudio que involucre datos fisiológicos, ya que la calidad y continuidad de las señales son cruciales para un análisis robusto y confiable [22].

2.3.5.1. EEG

En primer lugar, nos enfocamos en los datos provenientes del EEG, donde encontramos una cantidad significativa de valores nulos, especialmente concentrados en dos grandes grupos de variables:

- **Variables de tipo marcadores (“Markers”):** Estas variables (“MarkerIndex”, “MarkerType”, “MarkerValueInt”) mostraron todos sus valores como nulos. Este resultado indica claramente que, aunque dichas columnas fueron definidas en el diseño original del estudio para marcar eventos o momentos específicos durante la captura, en la práctica, el dispositivo o software utilizado no registró datos para estas columnas. Esto podría deberse a un fallo en el proceso automatizado de marcado o una configuración errónea del sistema durante la adquisición.
- **Variables relacionadas con métricas emocionales y de engagement:** Variables como “PM.Engagement”, “PM.Excitement”, “PM.Stress”, “PM.Relaxation” y otras métricas derivadas del dispositivo EEG presentaron cientos de miles de valores nulos. Estas métricas suelen generarse mediante algoritmos embebidos en algunos dispositivos EEG, que pretenden estimar estados emocionales o cognitivos. La ausencia generalizada de datos en estas columnas sugiere que durante la adquisición hubo problemas técnicos o que simplemente no se activaron o calcularon estas métricas por algún motivo relacionado con el dispositivo, software, configuración o tipo de adquisición elegida.
- **Potencia espectral por bandas:** El tercer conjunto significativo de variables afectadas por los valores nulos son las relacionadas con la potencia espectral por bandas de frecuencia (delta, theta, alpha, beta, gamma) para cada canal EEG (AF3, F7, F3, FC5, etc.). Cada una de estas columnas presentó más de 680,000 valores nulos, lo cual es crítico dado que estas variables son comúnmente esenciales para estudios psicofisiológicos y análisis de carga cognitiva, estrés o concentración [23]. La presencia generalizada de valores nulos en estas columnas podría indicar intervalos específicos en los que no se calculó la potencia espectral, posiblemente porque la señal EEG era de mala calidad en ciertos momentos, hubo artefactos prolongados, o interrupciones intermitentes en la adquisición de los datos [24].

2.3.5.2. ECG

En contraste, los datasets ECG (tanto los relacionados con frecuencia cardíaca –HR– como los relacionados con intervalos RR o IBI) no presentaron valores faltantes en absoluto. Esto confirma que la adquisición de datos cardíacos fue más robusta y constante, permitiendo su uso inmediato para análisis posteriores sin necesidad de métodos adicionales de imputación o reconstrucción.

2.3.6. Verificación de Variables con Dominio Acotado

La coherencia interna del dataset es un requisito indispensable antes de comenzar cualquier análisis avanzado, especialmente en estudios experimentales con múltiples variables categóricas o discretas, donde la presencia de valores fuera de los rangos establecidos podría invalidar total o parcialmente el estudio. Por este motivo, se realizó una verificación sistemática de aquellas variables con dominio acotado según el protocolo experimental descrito en el estudio original:

- **‘subject’** debía contener únicamente valores 1 o 2.
- **‘flight’** debía oscilar entre los valores [-1,5].

- **'phase'** debía ser exactamente 'baseline' o 'flight'.
- **'perceived_difficulty'** debía situarse en el rango $[-1, 4]$.
- **'theoretical_difficulty'** debía estar entre $[-1, 0) \cup (0, 3]$.

Se generaron scripts específicos para verificar estos dominios en cada uno de los datasets (EEG, ECG-HR y ECG-IBI), confirmándose la integridad y validez de todas las variables mencionadas. Concretamente, se obtuvieron los siguientes resultados:

```
=== Dataset: EEG ===
Todos los valores de 'subject' son válidos.
Todos los valores de 'flight' son válidos.
Todos los valores de 'phase' son válidos.
Todos los valores de 'perceived_difficulty' son válidos.
Todos los valores de 'theoretical_difficulty' son válidos.
-----
=== Dataset: ECG (HR) ===
Todos los valores de 'subject' son válidos.
Todos los valores de 'flight' son válidos.
Todos los valores de 'phase' son válidos.
Todos los valores de 'perceived_difficulty' son válidos.
Todos los valores de 'theoretical_difficulty' son válidos.
-----
=== Dataset: ECG (IBI) ===
Todos los valores de 'subject' son válidos.
Todos los valores de 'flight' son válidos.
Todos los valores de 'phase' son válidos.
Todos los valores de 'perceived_difficulty' son válidos.
Todos los valores de 'theoretical_difficulty' son válidos.
-----
```

Figura 2.17: Resultados del test de verificación de los dominios de los datos para cada dataset.

A la vista de la Figura 2.17 podemos decir que:

- **Subject:** Todos los valores registrados en cada dataset correspondían exactamente a los valores permitidos (1 o 2), sin excepciones ni errores. Esto indica claramente que la identificación de los sujetos fue realizada correctamente según el diseño experimental.
- **Flight:** Todos los registros se encontraban dentro del rango $[1-5]$, alineándose perfectamente con los cinco escenarios experimentales propuestos inicialmente.
- **Phase:** La columna mostró siempre los valores 'baseline' o 'flight', correspondientes exactamente con las dos fases principales definidas en el protocolo.
- **Perceived Difficulty y Theoretical Difficulty:** Estas variables estaban estrictamente limitadas a sus dominios predefinidos ($[-1, 4]$ y $[-1, 0) \cup (0, 3]$ respectivamente), sin identificarse ninguna desviación.

Por tanto, podemos concluir que, en términos de valores válidos dentro de las variables acotadas, la integridad interna de los datasets se confirmó plenamente. Esto es crítico para garantizar que cualquier inferencia posterior basada en estos datos sea fiable y refleje correctamente el diseño experimental original.

Sin embargo, al verificar la existencia de combinaciones específicas de sujetos (subject) y escenarios de vuelo (flight), se detectaron ciertas combinaciones ausentes, lo

cual fue esperado y está alineado con el protocolo experimental descrito por los investigadores originales:

```
Faltan las siguientes combinaciones en df_eeg:
  subject  flight
0        1      1
3        1      4
4        1      5
6        2      2
7        2      3

Faltan las siguientes combinaciones en df_ecg_hr:
  subject  flight
0        1      1

Faltan las siguientes combinaciones en df_ecg_ibi:
  subject  flight
0        1      1

--- Verificación en df_eeg ---
Verificación: La combinación subject=1, flight=1 NO existe en df_eeg (correcto).
Verificación: La combinación subject=1, flight=4 NO existe en df_eeg (correcto).
Verificación: La combinación subject=1, flight=5 NO existe en df_eeg (correcto).
Verificación: La combinación subject=2, flight=2 NO existe en df_eeg (correcto).
Verificación: La combinación subject=2, flight=3 NO existe en df_eeg (correcto).

--- Verificación en df_ecg_hr ---
Verificación: La combinación subject=1, flight=1 NO existe en df_ecg_hr (correcto).

--- Verificación en df_ecg_ibi ---
Verificación: La combinación subject=1, flight=1 NO existe en df_ecg_ibi (correcto).
```

Figura 2.18: Resultados del test de verificación de las combinaciones de las variables sujeto y vuelo.

- **En el dataset EEG:**

- subject=1 no realizó los vuelos 1, 4 ni 5.
- subject=2 no realizó los vuelos 3 ni 5.

- **En los datasets ECG (HR e IBI):**

- subject=1 y flight=1 fue la única combinación ausente.

Esta particularidad observada en la Figura 2.18 refleja que el ECG pudo haberse registrado también en escenarios donde el sujeto no pilotaba activamente, mientras que el EEG estuvo limitado a condiciones activas. Esta estructura es coherente con estudios previos.

2.3.7. Análisis de Variables Categóricas

La columna `role` en el dataset de EEG contenía una única categoría ('flying'), por lo que se consideró innecesaria para análisis posteriores. En los tres datasets, la columna `phase` presentaba dos únicas categorías ('baseline' y 'flight'), que serán codificadas con Label Encoding (en caso de usarse) para facilitar el análisis.

2.3.8. Sincronización Temporal

Se realizó un código para verificar que los datos estuvieran grabados para todos los datasets durante los mismos periodos de tiempo.

```
----- Sincronización Temporal -----  
EEG - Mínimo datetime: 2020-12-22 10:38:58.234317  
EEG - Máximo datetime: 2020-12-22 13:08:40.872047  
ECG (HR) - Mínimo datetime: 2020-12-22 10:20:33  
ECG (HR) - Máximo datetime: 2020-12-22 13:08:40.410002  
ECG (IBI) - Mínimo datetime: 2020-12-22 10:20:33  
ECG (IBI) - Máximo datetime: 2020-12-22 13:08:40.410002
```

Figura 2.19: Resultados del test de sincronización temporal sobre la variable *datetime*

A la vista de los resultados de la Figura 2.19, observamos que los datos sí están sincronizados temporalmente. Sin embargo, decidimos realizar la misma comprobación para cada sujeto dentro del EEG.

```
Rango de tiempo sujeto 1: 2020-12-22 11:27:45.790989 2020-12-22 12:18:18.321510  
Número de muestras: 287911
```

Figura 2.20: Comprobación individual de los tiempos de grabación para el sujeto 1.

```
Rango de tiempo sujeto 2: 2020-12-22 10:38:58.234317 2020-12-22 13:08:40.872047  
Número de muestras: 447858
```

Figura 2.21: Comprobación individual de los tiempos de grabación para el sujeto 2.

A la vista de las Figuras 2.33 y 2.21, entendemos que para cada sujeto, se tienen grabados únicamente los momentos en los que condujo (realizó el experimento), no captándose sus datos en los momentos en los que observaba.

2.3.9. Outliers

Analizando las variables del dataset ECG, observamos un único outlier ($HR < 40$) en la Figura 2.8 y otro outlier en la Figura 2.13 ($RR > 1600$), ya que son valores desorbitados y muy poco comunes, casi imposibles de que sean procedentes de personas con vida. Se eliminarán.

Para EEG, tras realizar un análisis exhaustivo de todas sus variables correspondientes a los electrodos, no se observó ningún outlier. Tampoco en las variables con dominio acotado, como se vio en 2.3.6. Pero sí en *datetime*, como acabamos de ver en el apartado inmediatamente anterior.

2.3.10. Análisis de Correlaciones

Se realizó un análisis de correlaciones entre electrodos EEG para identificar áreas cerebrales con alta sincronización. Se observaron correlaciones significativas que serán consideradas en futuros análisis de características para la detección de carga cognitiva.




Figura 2.22: Heatmap de las correlaciones de las variables de EEG




Figura 2.23: Top 10 correlaciones dentro del dataset EEG

A primera vista de la Figura 2.22, observamos que los dos primeros pares (AF3-AF4, P8-T8), así como otros más, se corresponden con electrodos muy cercanos (véase figura 2.23), por lo que el estudio cobra sentido. Además, resalta que pares de electrodos inmediatamente contrarios también entran en el top 10 de correlaciones.

El análisis similar realizado en ECG identificó correlaciones internas coherentes dentro de las medidas cardíacas.

De todos los resultados de la Figura 2.22, llama la atención que `perceived_difficulty` y `theoretical_difficulty` en ambos datasets (HR e IBI) solo tengan un 0.40 % de correlación. Tiene sentido con lo visto anteriormente, aunque estudiaremos esto más adelante.

2.3.11. Estudio y Fusión de Datasets ECG

Se comprobó que, tras eliminar columnas específicas (`hr` y `rr_int`), los datasets ECG HR y ECG IBI eran estructuralmente idénticos, facilitando su fusión futura en un dataset unificado, optimizando el análisis combinado.

2.3.12. Comprobación de Interrupciones en la Captación de Datos

Los datos ECG no mostraron interrupciones o datos cero. En cambio, el dataset EEG presentó intervalos con datos cero en algunos electrodos, indicando pausas breves. Estas interrupciones estaban asociadas con un sujeto, una fase y un período continuo. Se imputarán mediante interpolación, ya que existían datos válidos justo antes y después del fallo.

2.3.13. Análisis de la variable CQ (Contact Quality)

Dentro del dataset EEG contábamos con una serie de variables `CQ.ElectrodoX` que hacían referencia a la calidad de contacto de dicho electrodo con el cráneo durante la grabación de los datos. Se decidió explorar si existía algún 0.0 para alguna de las variables CQ en algún instante, ya que estaríamos ante una pérdida de grabación de los datos y, por tanto, dicho registro no sería válido. Se comprobó que todos los datos tenían valores, por lo que no se eliminará ninguna instancia.

2.3.14. Análisis de Registros Duplicados

Al realizar el análisis con los datasets completos, no se detectaban registros duplicados. Sin embargo, al realizar un `subset=['subject', 'flight', 'phase', 'datetime']`, sí se detectaron registros duplicados (mismo `datetime`) en los datasets ECG con discrepancias mínimas en HR e IBI. Para mitigar esto, se optará por promediar dichos valores para asegurar una alta calidad y coherencia de los datos utilizados en los análisis posteriores.

Este análisis exploratorio extenso permitió identificar claramente las áreas que requerirán atención especial en las fases posteriores de preprocesamiento y análisis avanzado, facilitando la creación de un modelo de inteligencia artificial robusto y fiable para la detección de carga cognitiva.

2.4. Preprocesamiento de los datos

La etapa de preprocesamiento en estudios basados en señales de electroencefalograma (EEG) resulta fundamental para mejorar la calidad de los datos, eliminando ruido, artefactos y problemas inherentes al proceso de registro, asegurando así resultados fiables para análisis posteriores [25]. El preprocesamiento realizado en este trabajo sigue una estructura metodológica clara y rigurosa, abordando problemas específicos detectados en las señales EEG captadas mediante el dispositivo Emotiv Epoc X.

Inicialmente se realizó una preparación de ambos datasets, seleccionando las variables relevantes de EEG para simplificar la gestión de datos. En ECG, se trató el problema de los registros duplicados, utilizando la media aritmética de los valores de `HR` y `RR_int` para unificar cada par en un único registro. Posteriormente, se detectó un problema de lecturas fallidas en EEG representado por valores de amplitud igual a cero en ciertos intervalos de tiempo, lo cual afecta significativamente la calidad de la información. Para mitigar este inconveniente, se aplicó una imputación basada en el promedio de los valores previos y posteriores al punto fallido, técnica que permite preservar la continuidad de la señal de forma efectiva.

A continuación, se efectuó la eliminación del offset, centrando cada canal EEG alrededor de cero mediante la sustracción de su media global. Este procedimiento es estándar y esencial para evitar sesgos derivados de niveles DC altos característicos en dispositivos EEG como el Emotiv Epoc X [26].

La etapa de filtrado de las señales incluyó, en primer lugar, la aplicación de filtros notch a 50 y 60 Hz para eliminar interferencias provenientes de la red eléctrica [27]. Posteriormente, se aplicó un filtro paso bajo con un punto de corte en 64 Hz, lo cual permitió conservar únicamente las bandas frecuenciales relevantes para la detección de carga cognitiva (delta, theta, alpha, beta y gamma baja), y reducir el ruido de alta frecuencia.

Seguidamente, se realizó una eliminación de artefactos mediante ICA (Análisis de Componentes Independientes) utilizando el software MNE [29], un método ampliamente recomendado para aislar y remover fuentes de artefactos como movimientos musculares y parpadeos, conservando la señal cerebral pura [28]. Se ajustó ICA por sujeto, asegurando que cada señal fuera limpiada considerando su singularidad.

Finalmente, tras el proceso de ICA, se realizaron múltiples pruebas por sujeto para verificar que los datos conservaban su calidad y validez, preparando así el conjunto de datos para la etapa posterior de extracción de características y análisis mediante modelos de inteligencia artificial.

2.4.1. Copia y validación de *datasets*

En primer lugar, se crean copias de los *datasets* originales para preservar la integridad de los datos iniciales y facilitar un seguimiento claro de las modificaciones realizadas durante el preprocesamiento.

2.4.2. Resolución del problema de duplicados en ECG

Durante el análisis exploratorio identificamos un problema significativo en los *datasets* de ECG: registros duplicados que contenían valores diferentes para las variables críticas de frecuencia cardíaca (`HR`) y el intervalo RR (`RR_int`), a pesar de compartir los mismos valores de `timestamp`, `subject`, `flight` y `phase`. Este hecho comprometía la calidad del análisis posterior, pues generaba incertidumbre sobre el valor real que debían adoptar estos registros.

Para resolver esta problemática, definimos un procedimiento claro basado en la agrupación y la agregación estadística. Las claves utilizadas para identificar registros duplicados fueron `subject`, `flight`, `phase` y `datetime`. Se optó por calcular la media

aritmética para las variables afectadas (HR y RR_int), asegurando así una representación precisa y consistente de estos registros repetidos.

En términos de implementación práctica, construimos diccionarios de agregación específicos para cada *dataset* de ECG:

- Para HR (frecuencia cardíaca), agrupamos según las claves mencionadas y aplicamos la media a esta variable, preservando las otras variables con el primer registro encontrado.
- Para RR_int (intervalos RR), se aplicó el mismo procedimiento con la variable rr_int.

2.4.2.1. Unificación y comprobación

Una vez que cada dataset fue agregado y verificado para asegurar la ausencia de duplicados, procedimos a fusionarlos mediante un merge, utilizando las mismas claves identificadoras. Este proceso garantizó un único dataset unificado, libre de duplicados y confiable para análisis posteriores.

Finalmente, verificamos mediante consultas específicas a registros concretos que el procedimiento había sido exitoso, confirmando que los datos fueron correctamente imputados y que ya no existían registros contradictorios. Esta solución práctica y metodológicamente robusta mejoró sustancialmente la calidad del dataset final, asegurando que el análisis posterior se basara en información coherente y precisa.

Nota: Aunque se ha preparado este *dataset* para su uso, no se utiliza en el presente estudio debido a que faltan datos clave que impiden su aplicabilidad en este contexto.

2.4.3. Preparación y tratamiento de datos EEG

El preprocesamiento de señales EEG requiere especial atención debido a la naturaleza sensible y compleja de estos datos, donde cualquier ruido o interferencia puede afectar significativamente la calidad y fiabilidad de los resultados obtenidos en análisis posteriores [25].




Figura 2.24: Señal EEG bruta

En la Figura 2.24 podemos observar la señal EEG bruta, es decir, antes de aplicar a los datos cualquier tipo de técnica de preprocesado.

2.4.3.1. Resolución del problema de lecturas fallidas

Durante la adquisición de datos EEG con dispositivos portátiles, como el Emotiv Epoc X, es frecuente encontrar registros en los que se producen lecturas fallidas o interrupciones momentáneas de conexión, manifestándose generalmente como valores atípicos o ceros en la señal registrada. Para solventar este problema se utilizó una técnica de imputación basada en la interpolación lineal entre valores consecutivos fiables. Específicamente, se identificaron aquellas muestras con valor cero y se imputaron mediante la media aritmética de sus valores inmediatamente anterior y posterior. Este método preserva la continuidad temporal y mantiene intactas las características espectrales y temporales importantes para el análisis EEG.

2.4.3.2. Eliminación del offset

Los datos EEG obtenidos inicialmente presentaron un **offset considerable**. Este offset es una característica habitual en dispositivos EEG portátiles debido al uso de amplificadores que introducen una corriente continua (DC) de base alta en la señal, como ocurre con el dispositivo Emotiv Epoc X [29].

El offset puede dificultar considerablemente los análisis posteriores, tales como la extracción de características en dominio temporal y frecuencia, debido a que el valor medio de la señal no representa la actividad cerebral real. Por ello, es esencial realizar un proceso de eliminación del offset para centrar la señal EEG en torno a cero, lo que facilita la interpretación de los picos y variaciones de la señal como verdaderas manifestaciones de actividad cerebral [24].

El procedimiento aplicado consistió en restar, para cada canal individualmente, la media aritmética de todos los valores registrados en dicho canal:

$$EEG_{\text{corrected}}(t) = EEG_{\text{raw}}(t) - \mu_{\text{channel}} \quad (2.1)$$

Donde:

- $EEG_{\text{corrected}}(t)$ es el valor corregido de la señal en el tiempo t .
- $EEG_{\text{raw}}(t)$ es el valor bruto registrado originalmente.
- μ_{channel} es la media de todos los valores del canal específico.

Este procedimiento asegura que cada canal tenga una media de cero, manteniendo la integridad y las características de la señal original, pero facilitando enormemente los análisis posteriores.




Figura 2.25: Señal EEG tras eliminar el offset

La efectividad de este método puede observarse visualmente al comparar la Figura 2.25 y la Figura 2.24, antes y después de la aplicación respectivamente, mostrando cómo la señal se centra claramente en torno al eje cero, eliminando la interferencia causada por el offset original.

2.4.3.3. Filtrado de la señal EEG

Para asegurar la calidad y claridad de las señales EEG, resulta esencial aplicar técnicas efectivas de filtrado que eliminen interferencias específicas y ruidos no deseados, manteniendo intacta la actividad cerebral relevante.

Inicialmente, se aplicaron **filtros tipo notch (filtros de muesca) en frecuencias de 50 Hz y 60 Hz**. Estos filtros son especialmente relevantes para eliminar las interferencias generadas por la red eléctrica, las cuales suelen estar presentes en los registros EEG debido a la cercanía de equipos eléctricos y electrónicos durante las mediciones [30]. La elección de estas frecuencias se justifica por las diferencias regionales, siendo 50 Hz estándar en Europa y 60 Hz en América [31]. El factor de calidad (Q) se configuró en 30, un valor recomendado en la literatura para obtener un compromiso óptimo entre la reducción efectiva de interferencias y la preservación de la señal EEG original [32].

Posteriormente, se implementó un **filtro paso bajo Butterworth de orden 4 con un punto de corte (cutoff) establecido en 64 Hz**. La justificación de este valor reside en la naturaleza espectral de las señales EEG relacionadas con la carga cognitiva. Las principales bandas de frecuencia de interés (delta, theta, alpha, beta y gamma baja) se encuentran generalmente por debajo de esta frecuencia, por lo que eliminar componentes por encima de 64 Hz permite reducir significativamente el ruido proveniente de actividades musculares o interferencias electrónicas, sin perder información neuronal significativa [25]. El filtro Butterworth es especialmente idóneo por su respuesta plana en la banda pasante, garantizando mínima distorsión en las señales cerebrales preservadas [33].

Para la implementación técnica, se utilizó la función `iirnotch` para diseñar los filtros notch y la función `butter` para diseñar el filtro paso bajo, ambas de la librería SciPy. Estos filtros se aplicaron secuencialmente sobre cada canal mediante la función `filtfilt`, que aplica el filtrado hacia adelante y hacia atrás en el tiempo, garantizando cero desplazamientos de fase y, por tanto, la integridad temporal de la señal [34].

Tras aplicar estos filtros, se logró eliminar efectivamente la interferencia de la red eléctrica, observándose claramente en la reducción de vibraciones específicas en las frecuencias mencionadas (50/60 Hz). Además, según la Figura 2.26, la señal quedó visiblemente suavizada y depurada en sus componentes de alta frecuencia, permitiendo un posterior análisis más preciso enfocado en la identificación de la actividad cerebral asociada a la carga cognitiva.




Figura 2.26: Señal EEG tras filtros notch y Butterworth

2.4.3.4. Downsampling

El muestreo original de los datos EEG es, según los desarrolladores de la Base de Datos, de 2048 Hz, una frecuencia muy superior a la requerida para capturar la actividad cerebral relevante en nuestro estudio, que se centra principalmente en frecuencias por debajo de 64 Hz.

Según el **teorema de Nyquist-Shannon**, la frecuencia de muestreo debe ser al menos dos veces mayor que la frecuencia máxima de interés para evitar la pérdida de información [35]. En nuestro caso, al establecer un **filtro paso bajo con una frecuencia de corte en 64 Hz**, una frecuencia de muestreo de 128 Hz es suficiente para conservar íntegramente la información útil.

Por tanto, se preparó un proceso de downsampling de la señal EEG, pasando de 2048 Hz a 256 Hz (una reducción por un factor de 8). Este procedimiento tiene como objetivo reducir la redundancia de datos, disminuyendo así el coste computacional y optimizando los recursos empleados en análisis posteriores.

El proceso de downsampling implica seleccionar cada octava muestra de la señal filtrada, además de aplicar internamente un filtro antialiasing utilizando la función `decimate`. El **filtro antialiasing** es un paso crítico y necesario que asegura la eliminación de frecuencias superiores al nuevo límite de Nyquist (128 Hz tras reducir la frecuencia a 256 Hz), evitando así que se produzca el fenómeno de aliasing, que distorsiona y contamina las señales al plegar frecuencias más altas en frecuencias más bajas [36].

Visualmente, la señal EEG downsampleada mantiene fielmente la estructura original, aunque con menos puntos de datos, ya que se conservan únicamente las frecuencias esenciales que caracterizan la actividad cerebral significativa. De esta manera, se facilita notablemente la eficiencia en procesos posteriores como la eliminación de artefactos mediante ICA, la extracción de características y el entrenamiento de modelos de aprendizaje automático.

En resumen, esta estrategia permite conservar toda la información esencial contenida en las frecuencias cerebrales relevantes y, a la vez, reducir considerablemente la cantidad de datos y el costo computacional.

Esta parte del preprocesado sería muy interesante en el caso de que la frecuencia de muestreo real fuera la que se decía en estudios previos y en los mismos documentos de la base de datos. Sin embargo, tras realizar varios análisis, se comprobó que la frecuencia de muestreo real era de 128 Hz. Por tanto, este procedimiento de down-sampling no se aplicó realmente a nuestros datos, pero se dejó codificado ya que es muy interesante para conjuntos de datos con frecuencias de muestreo superiores a 128-256 Hz.

2.4.3.5. Eliminación de artefactos mediante ICA


El **Análisis de Componentes Independientes** (ICA, por sus siglas en inglés: Independent Component Analysis) es una técnica estadística avanzada ampliamente utilizada en el análisis de señales EEG. El ICA permite descomponer la señal EEG multicanal en componentes independientes, las cuales idealmente separan fuentes específicas de actividad cerebral real y artefactos no cerebrales tales como parpadeos, movimientos musculares y ruido eléctrico [37]. Esta técnica es particularmente útil en EEG debido a que permite obtener una señal cerebral más "limpia", eliminando selectivamente artefactos mientras se conserva la información neuronal relevante. Probaremos con tres formas de aplicar este procedimiento: función FastICA de la librería sklearn, MNE-ICA de MNE y MNE-ICA de MNE aplicado individualmente por sujeto.

2.4.3.5.1. FastICA

Para realizar ICA en este estudio se utilizó la técnica FastICA, una implementación eficiente del ICA basada en la maximización de la no-Gaussianidad de las fuentes independientes obtenidas. Inicialmente, se organizan los datos EEG downsampleados en una matriz multivariada, donde cada columna representa un canal EEG y cada fila representa una muestra temporal.

Luego, se aplica FastICA utilizando tantos componentes independientes como canales disponibles (en este caso, 14 canales). La salida es un conjunto de componentes independientes, cada uno representando una fuente potencial de actividad, tanto cerebral como artefactual.

Para identificar componentes artefactuales se utilizó la kurtosis, una medida estadística que refleja la «puntiagudez» o la presencia de valores extremos en la distribución de las señales. Valores elevados de kurtosis indican una fuerte presencia de artefactos [38]. En el análisis en el que se obtuvo como resultado la Figura 2.27 se identificaron claramente componentes con kurtosis extremadamente altas (componentes 5 y 11, con kurtosis de 1104.32 y 1794.08, respectivamente), lo que indica una alta probabilidad de que estas componentes representen artefactos significativos como movimientos oculares (parpadeos) o contracciones musculares.



Además, una tercera componente (componente 8, kurtosis 311.60) presentó un valor elevado, pero en la visualización mostró actividad cerebral normal junto a un pico artefactual aislado. Se decidió conservar esta componente, considerando que eliminarla podría suponer una pérdida sustancial de información cerebral relevante. Asimismo, las componentes con kurtosis moderadas (componentes 1 y 3) mostraron patrones mixtos con presencia moderada de artefactos y actividad cerebral, por lo cual también se decidió mantenerlas en el análisis.

Tras identificar las componentes claramente artefactuales, estas fueron eliminadas estableciendo sus valores a cero. Posteriormente, se aplicó la transformación inversa del ICA para reconstruir las señales EEG libres de estos artefactos específicos. Esta reconstrucción generó un dataset EEG "limpio", adecuado para análisis posteriores, como la extracción de características relevantes y entrenamiento de modelos predictivos.




Figura 2.28: Comparativa Señal Original vs Señal Reconstruida

La efectividad de este procedimiento fue visualmente confirmada al comparar gráficamente la señal original con artefactos y la señal reconstruida tras la aplicación de ICA, Figura 2.28. La comparación gráfica muestra la reducción (mínima) de picos anómalos asociados a artefactos específicos, mientras que la actividad cerebral relevante permanece intacta. Así, el procedimiento ICA mediante FastICA resultó eficaz para mejorar la calidad de los datos EEG utilizados en este estudio.

2.4.3.5.2. MNE-ICA

Preparación del objeto Raw en MNE

MNE requiere datos EEG encapsulados en objetos específicos denominados RawArray. Para ello, extrajimos nuestros datos EEG previamente filtrados con frecuencia de muestreo (128 Hz), asegurándonos de que estos datos se encuentran organizados correctamente con dimensiones adecuadas (número de canales por número de muestras temporales). Adicionalmente, definimos un objeto info que contiene información esencial, incluyendo los nombres de los canales EEG y la frecuencia de muestreo utilizada.

Renombrado y asignación de montaje

Dado que los nombres de los electrodos en nuestro dataset original (por ejemplo, EEG.AF3) difieren ligeramente del estándar internacional 10-20 (AF3), realizamos

un renombramiento automático para adaptarlos al estándar, esencial para asignar posteriormente un montaje espacial estándar que nos permite utilizar las posiciones reales en el cuero cabelludo [39]. Luego asignamos un montaje estándar `standard_1020`, el cual permite visualizar y validar gráficamente (Figura 2.29) que la colocación y posiciones espaciales de los electrodos coinciden con la distribución teórica esperada.




Figura 2.29: *Objeto MNE creado con los nombres de los electrodos reasignados al estándar internacional*

Aplicación del ICA

El ICA se configuró utilizando el método FastICA implementado en MNE, con un número de componentes igual al número total de electrodos (14 canales). Esta configuración permite una separación completa de las fuentes subyacentes de la señal original [40]. Posteriormente, se ajustó el modelo ICA a nuestros datos (`ica.fit(raw)`), permitiendo obtener las fuentes independientes para inspección.

Evaluación y selección de componentes mediante kurtosis

Una vez obtenidas las componentes independientes, calculamos la kurtosis para cada componente, métrica que mide la «puntiagudez» o la presencia de colas extremas en la distribución de los datos. La kurtosis elevada (superior a un umbral, establecido en 312 según pruebas exploratorias) se utiliza habitualmente como indicador de artefactos, como parpadeos o movimientos musculares [41].




Figura 2.30: Gráficos MNE con los componentes

Identificamos automáticamente componentes artefactuosas a partir de sus valores extremos de kurtosis, lo que resultó en la selección específica de las componentes 7 y 11 como artefactos claros, siendo marcadas para exclusión. Esta exclusión se validó adicionalmente mediante la inspección visual interactiva proporcionada por MNE (Figura 2.30), lo que confirma la relevancia de las componentes seleccionadas.

Reconstrucción de la señal EEG limpia

Tras excluir los componentes identificados como artefactos, aplicamos la transformación inversa del ICA (`ica.apply(raw.copy())`) para obtener la señal EEG reconstruida, ahora libre o significativamente reducida de artefactos.




Figura 2.31: Señal EEG tras aplicar ICA

La comparación visual posterior de la señal original y la señal reconstruida (Figura 2.31) mostró una reducción sustancial en picos relacionados con artefactos, conservando intacta la forma y características esenciales de la actividad cerebral subyacente. Se ejemplificó esto en el canal AF3, demostrando claramente la efectividad del ICA aplicado mediante MNE.

Finalmente, se creó un nuevo DataFrame (`df_eeg_ica2`) con los datos EEG ya libres de artefactos, conservando una correcta sincronización temporal con respecto a la columna original `'datetime'`. La inspección y descripción estadística rápida de esta columna temporal reveló coherencia total con la duración original del registro y sin anomalías detectadas en el eje temporal.

En resumen, el proceso completo de aplicación del ICA utilizando MNE ha resultado exitoso, permitiéndonos avanzar al siguiente paso del análisis con datos EEG limpios y robustos, listos para la extracción de características avanzadas y modelado posterior.

2.4.3.5.3. MNE-ICA individualmente por Sujeto

Para garantizar una eliminación precisa y adaptativa de artefactos en las señales EEG, especialmente los relacionados con movimientos oculares, actividad muscular, o ruido electromagnético, se aplicó el análisis de componentes independientes (ICA) mediante el paquete MNE para cada sujeto por separado.

En primer lugar, se incorporó la información del sujeto al dataset filtrado (`df_eeg_filtered`) mediante un merge con el dataset original (`eeg`), asegurando la consistencia temporal y una correcta atribución de muestras.

Tras separar los datos por sujeto, se transformaron en objetos `RawArray` compatibles con MNE, siguiendo el procedimiento estándar descrito [42]. Cada señal fue renombrada para ajustarse a la nomenclatura estándar de electrodos EEG según el montaje internacional `standard_1020`[43].

Luego, se aplicó un **filtro paso-alto a 1 Hz**, recomendado antes del ICA para asegurar la estacionariedad de las señales y mejorar la estabilidad del algoritmo ICA [41]. Este preprocesamiento es fundamental para mejorar la calidad de la descomposición y asegurar que los componentes representen fuentes fisiológicamente interpretables.




Figura 2.32: ICA sujeto 2

Se ejecutó ICA utilizando tantos componentes independientes como canales EEG disponibles (como anteriormente), lo que asegura una descomposición completa de la señal original [37]. En la Figura 2.32 podemos observar el resultado de aplicar esta técnica para, por ejemplo, el sujeto 2. Posteriormente, se calculó la kurtosis de cada componente, un indicador estadístico sensible a artefactos, como ya hemos visto anteriormente, especialmente movimientos musculares o parpadeos que suelen presentar kurtosis elevada [41].




Figura 2.33: Señales ICA con MNE




Figura 2.34: ICA sujeto 2

Se estableció un umbral empírico basado en la distribución de kurtosis ($|kurtosis| > 312$), identificando así los componentes probablemente artefactuosos. Estos componentes fueron visualizados mediante las herramientas gráficas proporcionadas por MNE (plots de componentes y fuentes, Figuras 2.33 y 2.34 respectivamente), facilitando la validación visual y la decisión final sobre qué componentes excluir [44]. Des-

pués de excluir estos componentes artefactuosos, se reconstruyeron las señales EEG limpias mediante la transformación inversa del ICA. Este procedimiento garantiza la preservación de la actividad cerebral genuina, eliminando eficazmente los artefactos no deseados [45].

Finalmente, los datos EEG limpios fueron nuevamente almacenados en un DataFrame con sus timestamps originales preservados, garantizando la coherencia temporal necesaria para análisis posteriores. Las señales limpiadas por ICA mostraron significativamente menos ruido y artefactos, tal como se observó en gráficos específicos para cada sujeto (Figuras 2.35 y 2.36) en el canal AF3, reafirmando la utilidad del análisis individualizado para preservar la calidad y autenticidad de la señal EEG original. Esta última aplicación de ICA es la que usaremos para el desarrollo del proyecto.




Figura 2.35: Señal Reconstruida Sujeto 1




Figura 2.36: Señal Reconstruida Sujeto 2

Este procedimiento meticuloso proporciona señales EEG optimizadas para análisis posteriores, como la extracción de características para modelos predictivos de carga cognitiva.

2.5. Extracción de Características

2.5.1. Justificación de la Segmentación

Segmentamos las señales EEG en ventanas de 1 segundo, pues este tamaño de ventana es un equilibrio entre la resolución temporal adecuada y suficiente información para analizar patrones relacionados con eventos cognitivos [46]. Una ventana demasiado corta podría no capturar información relevante en las frecuencias más bajas (delta y theta), mientras que una ventana demasiado larga perdería precisión temporal ante cambios rápidos del estado cognitivo.

2.5.2. Características en el Dominio del Tiempo

Las características temporales capturan estadísticos que reflejan comportamientos generales y dinámicas específicas de las señales EEG:

- **Media y Varianza:** Reflejan la tendencia central y variabilidad general en la amplitud de la señal EEG.
- **Desviación estándar (std):** Indica la dispersión respecto a la media, crucial para detectar cambios en la activación cerebral.
- **Asimetría (skew):** Identifica si la distribución de la amplitud está sesgada hacia valores altos o bajos, sugiriendo asimetría en la activación neuronal.
- **Kurtosis:** Medida de picos o extremos (artefactos o actividad neuronal intensa). Valores altos suelen indicar artefactos como movimientos musculares oculares (EOG) [23].
- **Peak-to-Peak (ptp):** Diferencia entre el valor máximo y mínimo, indicando fluctuaciones grandes, típicas en eventos neuronales o artefactos fuertes.
- **Número de cruces por cero:** Indica la frecuencia relativa de cambios en la polaridad de la señal, relacionándose con frecuencia dominante y dinámica cerebral [47].

2.5.3. Características en el Dominio de la Frecuencia

Las características frecuenciales son calculadas utilizando el método Welch para estimar la densidad espectral de potencia (PSD), conocido por su robustez frente al ruido [48].

Las bandas extraídas fueron:

- **Delta (1-4 Hz):** Asociada al sueño profundo y tareas cognitivas relacionadas con atención sostenida o procesos inconscientes [49].
- **Theta (4-8 Hz):** Vinculada a estados de somnolencia, memoria de trabajo, y tareas cognitivas complejas que requieren concentración [50].
- **Alpha (8-13 Hz):** Refleja relajación consciente, meditación o estado de reposo despierto con ojos cerrados; disminuye con activación cognitiva [51].
- **Beta (13-30 Hz):** Relacionada con actividad mental activa, concentración, alerta, resolución de problemas y percepción sensorial [52].
- **Gamma (30-50 Hz):** Asociada a alta activación neuronal, atención focalizada, procesamiento perceptual intensivo y fenómenos cognitivos superiores [53].

Además, se extrajeron:

- **Ratio Theta/Alpha:** Índice utilizado para evaluar el nivel relativo de somnolencia frente a la atención despierta o relajada.
- **Entropía Espectral:** Mide la complejidad y la predictibilidad de la señal en el dominio frecuencial.

2.6. Creación de una variable objetiva de carga cognitiva

- **Asimetría frontal en banda Alpha:** Calculada como la diferencia logarítmica entre la potencia Alpha en los electrodos frontales AF4 (derecho) y AF3 (izquierdo), usada para evaluar diferencias en activación cortical frontal.

Estas características frecuenciales aportan información directa del estado cerebral y son ampliamente utilizadas en estudios neurocientíficos para caracterizar diferentes niveles de carga cognitiva.

2.5.4. Integración con Variables del Protocolo Experimental

Incorporamos meticulosamente (gracias a `datetime`) las variables originales del experimento como `subject`, `perceived_difficulty` y `theoretical_difficulty` para contextualizar las características EEG extraídas y facilitar su interpretación en relación con la carga cognitiva real del sujeto. La variable `Role` fue excluida según el protocolo establecido previamente. El resultado del dataframe se puede observar en la Figura 2.37.

Numero de ventanas extraídas: 5748
Vista previa de las características extraídas:

	start_time	subject	theoretical_difficulty	AF3_mean	AF3_std	AF3_var	AF3_skew	AF3_kurtosis	AF3_sip	AF3_zero_crossings	...	AF4_beta_power	AF4_gamma_power	AF4_delta_power_rel	AF4_theta_power_rel	AF4_alpha_power_rel	AF4_beta_power_rel
0	2020-10-22 10:38:38.234377	2	1	9.185956	4.936416	24.368208	0.489765	-0.709345	19.113274	1	...	1.201105e-05	1.206789e-07	0.995173	0.004808	1.790548e-05	1.063151e-06
1	2020-10-22 10:38:59.240643	2	1	-1.411858	4.178314	17.458310	-0.625003	-0.576020	14.458753	5	...	1.318052e-07	6.432797e-10	0.989101	0.010898	9.519210e-07	8.960072e-09
2	2020-10-22 10:39:00.357792	2	1	0.679351	4.365827	18.060448	-0.203865	-0.678221	15.941603	5	...	5.697787e-07	4.430423e-09	0.997018	0.002978	3.245099e-06	2.073342e-08
3	2020-10-22 10:39:07.268643	2	1	-1.629880	4.709347	22.177945	0.336729	-0.938811	16.103417	3	...	9.216917e-07	8.265755e-09	0.968532	0.031464	3.763754e-06	4.501887e-08
4	2020-10-22 10:39:02.281693	2	1	2.251481	3.543632	12.557327	0.261140	-1.226234	11.208006	5	...	1.768648e-07	1.697767e-09	0.989681	0.010317	2.280073e-06	7.539291e-09

5 rows x 17 columns

Figura 2.37: *DataFrame* resultado de la extracción de características y la incorporación de nuevas variables originales

Posteriormente, se mapearon los valores de la variable objetivo `theoretical_difficulty` con el fin de capturar mejor los patrones de baja y alta carga cognitiva. Tras varios estudios experimentales, se decidió que la alta carga cognitiva se alineaba mejor con su propia definición al agrupar los 3 valores más altos definidos originalmente en la variable objetivo. De esta forma, `theoretical_difficulty` pasa de tener 5 valores [-1,1,2,3,4] a 3 únicos valores [0,1,2] correspondidos según los niveles [(-1),(1),(2,3,4)] respectivamente (véase Cuadro 2.1). Así, nuestra variable objetivo representa baja carga, carga normal y alta carga, y además pasa a estar mucho más balanceada, incrementando positivamente el rendimiento de los modelos de IA aplicados posteriormente.

Cuadro 2.1: Mapeo de valores para la variable objetivo

theoretical_difficulty_grouped	theoretical_difficulty
2	-1
0	1
1	2
Name: count, dtype: int64	

theoretical_difficulty_grouped	theoretical_difficulty
2	1954
0	1633
1	1186
3	540
4	435
Name: count, dtype: int64	

2.6. Creación de una variable objetiva de carga cognitiva

La carga cognitiva es un concepto crítico en contextos de análisis neurofisiológicos, especialmente en tareas altamente demandantes como el pilotaje de aviones. Tradi-

cionalmente, muchos estudios se han basado en mediciones subjetivas, tales como la dificultad percibida (`subject`) o dificultad teórica (`theoretical_difficulty`). Sin embargo, como se ha observado claramente en nuestro análisis exploratorio de datos (EDO), estas mediciones no presentan una correlación robusta con indicadores fisiológicos objetivos obtenidos mediante EEG o ECG. Este desacuerdo es indicativo de sesgos subjetivos inherentes, ya que los pilotos pueden no percibir adecuadamente la dificultad real de las tareas o pueden tener distintos umbrales personales para calificar estas dificultades.

Por esta razón, decidimos crear una nueva variable objetiva y fisiológicamente fundamentada, denominada `new_cognitive_load`, para capturar la actividad cerebral real y objetiva relacionada con distintos niveles de exigencia cognitiva. Para ello, se han seguido pasos meticulosos que incluyen:

1. **Extracción sistemática de características:** Se extrajeron características en dos dominios fundamentales:
 - Dominio temporal: Características estadísticas básicas (media, varianza, desviación estándar, sesgo, curtosis, peak-to-peak y cruces por cero) que ofrecen información sobre la variabilidad y estabilidad de la señal EEG.
 - Dominio frecuencial Potencia en bandas específicas mediante el método Welch (delta, theta, alpha, beta y gamma), cada una relacionada con procesos neurofisiológicos específicos. Estos son:
 - Delta (1-4 Hz): Asociada con estados de fatiga profunda o sueño.
 - Theta (4-8 Hz): Relacionada con carga cognitiva, atención sostenida y memoria operativa.
 - Alpha (8-13 Hz): Indicativa del nivel de atención y relajación.
 - Beta (13-30 Hz): Relacionada con estados de alerta activa y resolución de problemas.
 - Gamma (30-50 Hz): Asociada a procesos de atención selectiva y cognición avanzada.
 - Además, se extrajeron el ratio theta/alpha, la entropía espectral y la asimetría frontal en la banda alpha.
2. **Índice Compuesto:** Utilizando las características temporales y frecuenciales, se creó un índice compuesto (Figura 2.38) que promedia todas las características normalizadas, permitiendo condensar en un único valor representativo la actividad cerebral registrada.

2.6. Creación de una variable objetiva de carga cognitiva




Figura 2.38: Construcción del Índice Compuesto con Mediana Móvil

3. **Segmentación de Carga Cognitiva:** Se definió un umbral objetivo basado en la mediana del índice compuesto, dividiendo las ventanas analizadas en dos categorías claras: alta carga (valores por encima del umbral) y baja carga (por debajo del umbral). Este método permitió generar una clasificación objetiva e independiente de las percepciones subjetivas del piloto.

2.6.1. ¿Por qué es mejor esta variable que `theoretical_difficulty` o `perceived_difficulty`?

- **Objetividad:** Esta nueva variable se sustenta directamente en patrones cerebrales medibles y cuantificables, eliminando sesgos subjetivos.
- **Consistencia:** La variable "new_cognitive_load" se basa en datos EEG objetivos, permitiendo una consistencia inter-sujeto mayor que la alcanzada con variables subjetivas.
- **Validación Neurofisiológica:** Estudios previos respaldan la correlación de aumentos en potencia theta frontal (canales AF3, F4) con incrementos en carga cognitiva. Este patrón fisiológico validado fortalece nuestra elección metodológica.

2.6.2. Validación de resultados obtenidos

Se realizaron pruebas estadísticas (t-tests) comparando características clave como `AF3_theta_power`, `F4_theta_power` y `O1_theta_power`, así como el índice compuesto, entre grupos etiquetados como alta y baja carga.

```
Estadísticos para 'AF3_theta_power' (Umbral Global):
```

	mean	std	min	max	\
new_cognitive_load_rolling					
0	32.026311	186.204228	0.011322	4212.434069	
1	374.749471	2620.783615	0.013053	60087.297032	
	median				
new_cognitive_load_rolling					
0	2.026532				
1	3.156094				

t-test para 'AF3_theta_power' (Umbral Global): t-stat = -6.94, p-value = 0.000

Figura 2.39: Estadísticos y resultados del t-test para la variable `new_cognitive_load`

A la vista de la Figura 2.39, los resultados fueron contundentes: características como `AF3_theta_power` presentaron diferencias estadísticamente significativas entre grupos ($p - \text{value} \approx 0.000$), con valores promedio mucho mayores en alta carga ($\text{media} \approx 374$; $\text{mediana} \approx 3.15$) que en baja carga ($\text{media} \approx 32$; $\text{mediana} \approx 2$).

El índice compuesto mostró claramente dos grupos diferenciados: alta carga con índice promedio positivo (≈ 0.15) y baja carga con índice negativo (≈ -0.15).

Estos resultados se refuerzan mediante visualizaciones (boxplots y scatter plots) que evidencian una clara separación fisiológica y estadística, confirmando que nuestro método captura eficazmente diferencias en la actividad cerebral real relacionadas con la carga cognitiva.





Figura 2.40: *Boxplot de la clasificación de los valores del electrodo AF3 dentro de la nueva variable*

Además, se realizó una comparación visual de los datos para un canal específico (AF3) a modo de validación. En la Figura 2.40 se puede observar claramente la diferencia de los valores de `AF3_theta_power` para ambos valores de la variable binaria creada. Como queríamos, la carga cognitiva baja (clase 0) presenta valores muy bajos (≈ 0), mientras que la carga cognitiva alta (clase 1) comprende los más altos, llegando a alcanzar el valor 60000.

2.6. Creación de una variable objetiva de carga cognitiva

Cuadro 2.2: Comparación de los datos para el canal AF3 según `theoretical_difficulty` y `new_cognitive_load`.



Según los topomaps del Cuadro 2.2, `theoretical_difficulty=1` supondría más carga mental que la 2 (más rojo), e idénticamente sucede con los valores 3 y 4, hecho que no debe corresponderse con la realidad. Además, no se observa ningún patrón en las imágenes (por ejemplo, concentración en la corteza prefrontal), por lo que nos sugiere que podría ser incorrecto.

En cambio, en nuestra variable creada `new_cognitive_load` sí se observa esa tendencia creciente entre los valores y, además, la parte prefrontal (comúnmente asociada a tareas de carga cognitiva) aumenta considerablemente.

2.6.3. Conclusión

La creación de la variable `new_cognitive_load` ofrece una herramienta robusta y objetiva para evaluar estados de alta carga cognitiva, superando limitaciones inherentes a las variables subjetivas tradicionales. Su sólida validación estadística y fisiológica la posiciona como un recurso óptimo para investigaciones futuras y desarrollo de modelos predictivos basados en EEG. Sin embargo, **en este estudio no se utilizará** debido principalmente a que ha sido creada a partir de estos mismos datos. Además, el objetivo principal de este proyecto, en gran parte de investigación, es superar los resultados anteriores, por lo que se utilizará la misma variable.

2.7. Creación de los modelos de IA

2.7.1. Regresión Logística

La regresión logística es un modelo estadístico utilizado principalmente para problemas de clasificación binaria. A diferencia de la regresión lineal, que predice valores continuos, la regresión logística predice la probabilidad de que una instancia pertenezca a una clase específica utilizando la función logística (sigmoide). Su ecuación principal es:

$$P(Y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_n X_n)}}$$

Donde β son coeficientes que determinan el peso de cada característica en la predicción. El algoritmo busca optimizar estos coeficientes mediante técnicas de máxima verosimilitud, minimizando el error entre las probabilidades predichas y los valores reales.

2.7.2. K-Nearest Neighbors (K-NN)

El algoritmo K-NN es un método sencillo basado en instancias, que clasifica un nuevo dato identificando los «K» vecinos más cercanos en el espacio de características. La clase del nuevo dato se determina por mayoría entre sus vecinos cercanos. La distancia más usada para medir cercanía es la distancia euclidiana:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Aunque sencillo y eficaz, K-NN puede ser sensible al ruido y a características irrelevantes. La elección óptima de «K» es fundamental para el rendimiento del modelo.

2.7.3. Random Forest

Random Forest es un método de aprendizaje supervisado basado en árboles de decisión. Funciona mediante la creación de múltiples árboles de decisión entrenados con subconjuntos aleatorios de datos y características, una técnica conocida como bagging (Bootstrap Aggregating). La clasificación final se realiza mediante votación mayoritaria o promedio de predicciones individuales. Esto proporciona robustez frente al sobreajuste y mejora significativamente la precisión respecto a un solo árbol de decisión.

2.7.4. Support Vector Machines (SVM)

Las máquinas de vectores soporte (SVM) son algoritmos supervisados útiles para clasificación y regresión, particularmente efectivos en espacios dimensionales altos. SVM intenta encontrar un hiperplano óptimo que separe las distintas clases con el máximo margen posible. El margen es la distancia máxima entre el hiperplano separador y los puntos más cercanos de cada clase, llamados vectores soporte. Si las clases no son linealmente separables, SVM utiliza funciones kernel (como radial, polinómica o sigmoide) para transformar los datos a un espacio dimensional superior donde sea posible la separación.

2.7.5. XGBoost

XGBoost (Extreme Gradient Boosting) es una implementación eficiente y optimizada del algoritmo Gradient Boosting. Utiliza árboles de decisión secuenciales, donde cada árbol corrige los errores cometidos por el árbol anterior. Destaca por su velocidad y precisión, gracias a optimizaciones algorítmicas como la poda anticipada de árboles, regularización para controlar el sobreajuste, manejo eficiente de datos dispersos y paralelización automática de tareas. Estas características hacen de XGBoost una opción poderosa en competencias y aplicaciones prácticas en ciencia de datos.

2.7.6. Gradient Boosting

Gradient Boosting es una técnica de ensemble en la que múltiples modelos débiles (generalmente árboles pequeños) son combinados secuencialmente para producir un modelo fuerte. Cada nuevo modelo corrige los errores residuales del anterior. A diferencia de Random Forest, que usa un ensemble paralelo de árboles independientes, Gradient Boosting optimiza la reducción del error acumulado iterativamente mediante métodos de gradiente descendente. Su habilidad para modelar relaciones complejas y alta capacidad predictiva lo hacen ideal para tareas de clasificación y regresión complejas, aunque es susceptible al sobreajuste sin una adecuada regularización.

2.7.7. Red Neuronal

Una red neuronal artificial (NN) es un modelo computacional inspirado en la estructura y funcionamiento de las redes neuronales biológicas. Está compuesta por un conjunto interconectado de unidades de procesamiento llamadas neuronas, organizadas en capas. Estas capas suelen ser clasificadas en tres categorías principales: capa de entrada (recibe los datos iniciales), capas ocultas (procesan y extraen características complejas de los datos) y capa de salida (proporciona las predicciones o clasificaciones finales).

Cada neurona realiza cálculos ponderados utilizando las entradas que recibe, que luego pasan a través de una función de activación (como sigmoide, ReLU, tanh, etc.), permitiendo así modelar relaciones complejas no lineales entre las variables. El entrenamiento de una NN implica ajustar los pesos de cada conexión mediante un proceso conocido como retropropagación y optimización basada en métodos como el descenso del gradiente para minimizar una función de pérdida.

2.7.7.1. Red Neuronal utilizada en estudios previos

El modelo EEG_ConvNet utilizado en estudios previos es una red neuronal convolucional (CNN) específicamente diseñada para procesar datos bidimensionales, como pueden ser señales electroencefalográficas (EEG) representadas en forma de mapas o espectrogramas, aprovechando así la estructura espacial de estos datos.

La estructura (Figura 2.41) detallada del modelo EEG_ConvNet es:

1. Primera capa convolucional (Conv2D):

- Cuenta con 16 filtros convolucionales, generando un total de 160 parámetros entrenables.

- Sigue una capa de max-pooling que reduce la dimensión espacial, preservando características relevantes mientras disminuye la complejidad computacional.

2. Segunda capa convolucional:

- Tiene 32 filtros, lo que permite capturar patrones más complejos, generando 4,640 parámetros.
- También seguida por una capa de max-pooling para reducir dimensiones.

3. Tercera capa convolucional:

- Utiliza 64 filtros, incrementando significativamente la complejidad representativa del modelo con 18,496 parámetros.
- Nuevamente, una capa de max-pooling acompaña esta convolución.

4. Capa Flatten:

- Convierte la salida tridimensional de las capas convolucionales en un vector unidimensional de 2,048 elementos, facilitando su paso a capas densas posteriores.

5. Capas densas (fully-connected):

- Una primera capa densa con 256 neuronas, que acumula 524,544 parámetros entrenables.
- Una segunda capa densa con 64 neuronas, que añade 16,448 parámetros.
- Una capa final densa de 5 neuronas para realizar la clasificación final, aportando 325 parámetros.

El modelo EEG_ConvNet contiene en total 564,613 parámetros, todos ellos entrenables. Este modelo ha demostrado ser eficaz en estudios previos usando el mismo dataset (sensibilidad 76.25% y especificidad 87.81%) [54], dado que es capaz de extraer patrones relevantes de señales EEG en tareas relacionadas con neurociencia y análisis cerebral.




Figura 2.41: Arquitectura de la red ConvNet utilizada en experimentos previos

2.7.7.2. Red Neuronal elaborada

2.7.7.2.1. Redes Neuronales Probadas y Selección del Modelo Final

Para resolver el problema planteado, se construyeron diversas arquitecturas de redes neuronales completamente conectadas (fully-connected o Dense), utilizando técnicas avanzadas para optimizar su rendimiento. Las redes variaron principalmente en número y tamaño de capas densas. Las arquitecturas probadas fueron:

- **small:** dos capas densas con 128 y 64 neuronas.
- **medium (seleccionada como mejor modelo):** tres capas densas con 256, 128 y 64 neuronas respectivamente.
- **large:** tres capas densas con 512, 256 y 64 neuronas.
- **xlarge:** cuatro capas densas con 512, 256, 128 y 64 neuronas.
- **xxlarge:** cinco capas densas con 1024, 512, 256, 128 y 64 neuronas.

La arquitectura **medium** fue elegida como la mejor debido a su excelente balance entre rendimiento y complejidad, obteniendo mejores resultados en términos de recall y especificidad promedio, sin incurrir en sobreajuste.

2.7.7.2.2. Detalle de la Arquitectura Medium

La estructura final de la red neuronal medium (Figura 2.42) es:

1. **Entrada con Ruido Gaussiano:** Adición de ruido gaussiano con desviación estándar 0.1 para mejorar la robustez ante datos ruidosos.
2. **Primera capa densa:** 256 neuronas con inicialización He normal y regularización L2, seguida de activación LeakyReLU ($\alpha=0.2$), Batch Normalization y Dropout (0.5).
3. **Segunda capa densa:** 128 neuronas, misma configuración anterior (He normal, LeakyReLU, Batch Normalization y Dropout).
4. **Tercera capa densa:** 64 neuronas con idéntica configuración, optimizando la reducción gradual de características.
5. **Capa final:** capa densa con activación softmax para clasificar en 3 clases, adaptada específicamente al problema tratado.

2.7.7.2.3. Técnicas Utilizadas

- **Normalización Estándar (StandardScaler):** escala los datos de entrada para asegurar estabilidad y acelerar el entrenamiento.
- **SMOTE Borderline:** técnica avanzada para manejo de clases desbalanceadas, enfocándose en ejemplos fronterizos para mejorar la generalización.
- **Regularización L2:** evita sobreajuste penalizando pesos grandes.
- **Batch Normalization:** normaliza las salidas de cada capa intermedia para acelerar el entrenamiento y mejorar estabilidad.

Desarrollo

- **Dropout:** técnica de regularización que desconecta neuronas aleatoriamente en cada paso del entrenamiento para mejorar la generalización.
- **Focal Loss:** función de pérdida especializada en manejar clases desbalanceadas al enfocarse en ejemplos difíciles.
- **Early Stopping y ReduceLROnPlateau:** técnicas para detener tempranamente el entrenamiento y ajustar dinámicamente la tasa de aprendizaje.

Esta combinación estratégica de técnicas permitió al modelo medium lograr un rendimiento óptimo y robusto ante los desafíos específicos del dataset utilizado.




Figura 2.42: Arquitectura de la red elaborada


2.8. Experimentación

Con el fin de complementar dicha base de datos con registros adicionales bajo condiciones similares, se diseñó un experimento propio de EEG en el laboratorio, manteniendo la misma selección de canales y un protocolo análogo de tareas con periodos de estrés (tarea cognitiva) y relajación (reposo). A continuación, se describen el equipamiento y el software utilizados en este experimento, así como el diseño experimental empleado para inducir y medir cambios en la carga cognitiva.

2.8.1. Equipamiento EEG

El experimento empleó un dispositivo EEG Bitbrain modelo BBT-E32-AAB065, perteneciente a la serie Versatile 32 canales. Se trata de un casco EEG inalámbrico de 32 derivaciones, con electrodos activos de tipo semi-seco (a base de esponjas humedecidas en agua) colocados según el sistema internacional 10/20 extendido. Este equipamiento está diseñado para ser de rápida colocación y cómodo para el sujeto, permitiendo registros en tiempo real con libertad de movimiento. El amplificador EEG integrado transmite las señales de forma inalámbrica (Bluetooth 2.1 + EDR) a una frecuencia de muestreo de 256 Hz, e incluye almacenamiento local en tarjeta microSD como respaldo durante sesiones prolongadas. La autonomía de la batería del dispositivo supera las 8 horas, más que suficiente para la duración de este experimento (Cuadro 2.3).

Cuadro 2.3: Conectividad y Ajuste



Aunque el sistema cuenta con 32 canales EEG disponibles, en este estudio se seleccionaron 14 electrodos específicos (Figura 2.43), coincidiendo con los utilizados en la base de datos original de los pilotos. Las posiciones elegidas cubren regiones frontales, parietales, temporales y occipitales de ambos hemisferios, enfocadas en áreas asociadas a procesos cognitivos y atención. En concreto, los electrodos utilizados fueron: F7, AF3, FC5, T7, P7, O1, F3 (hemisferio izquierdo) y F4, AF4, FC6, T8, P8, O2, F8 (hemisferio derecho). En la figura anterior se ilustra la ubicación aproximada de estos 14 sensores sobre la cabeza. Se mantuvo un montaje referencial común; todos los canales se registraron referenciados a un electrodo neutral incluido en la diadema (sistema de referencia común al promedio de todos los sensores, proporcionado

por el amplificador de Bitbrain). Antes de cada sesión, se humedecieron las esponjas de cada electrodo con solución salina (agua corriente) para garantizar una buena conductividad y baja impedancia en el contacto con la piel. Durante el experimento, las señales EEG fueron transmitidas en tiempo real al ordenador principal, donde quedaron registradas para su posterior análisis.




Figura 2.43: Esquema de la disposición de los 14 electrodos utilizados (vista superior de la cabeza, sistema 10/20 extendido). Los electrodos grises rodeados de color azul indican las posiciones activas seleccionadas en el experimento.

2.8.2. Software y diseño experimental

Participantes: Tomaron parte en el experimento dos sujetos jóvenes y sanos: el autor del TFG (varón, 21 años) y una colaboradora azafata de vuelo (mujer, 22 años). Ninguno presentaba antecedentes neurológicos, y ambos dieron su consentimiento para participar. Se les instruyó para permanecer lo más quietos posible durante las mediciones y evitar movimientos bruscos o parpadeos excesivos que pudieran artefactar la señal EEG.

Tareas y procedimiento: El protocolo experimental se diseñó para inducir cambios en la carga cognitiva a través de una tarea de N-Back de nivel 2 (dos-back) intercalada entre períodos de relajación (Figura 2.44). La sesión de registro para cada participante tuvo una duración total de 10 minutos e incluyó las siguientes fases en secuencia:

1. **Relajación inicial (5 minutos):** El sujeto observó un video de relajación de aproximadamente cinco minutos de duración, con escenas tranquilas y música suave. Este periodo inicial sirvió para registrar la actividad cerebral en un estado basal de baja carga cognitiva (reposo atento).
2. **Tarea cognitiva N-2Back ($\approx$ 2 minutos):** A continuación, el participante realizó una tarea de memoria de trabajo del tipo N-back. En concreto se utilizó una tarea 2-Back implementada mediante la plataforma PsyToolkit (versión 3.6.2). En esta prueba, se presenta al sujeto una secuencia de estímulos (letras) y debe indicar si el estímulo actual coincide con el presentado 2 ensayos atrás, pulsando la tecla correspondiente. Este tipo de tarea es un paradigma clásico para evaluar la memoria de trabajo y la carga mental: a mayor valor de N en el N-Back, mayor es la dificultad de la tarea y, por ende, la carga cognitiva impuesta al sujeto. El bloque 2-Back utilizado constaba de varias series de estímulos con breves pausas inter-trial (según la configuración por defecto de PsyToolkit), suman-

do unos dos minutos de actividad. Durante esta fase, se espera un incremento significativo de la carga cognitiva, ya que el sujeto debe mantener y actualizar continuamente información en la memoria de trabajo mientras responde a los estímulos.

3. **Relajación post-tarea (hasta completar 10 minutos):** Tras concluir la tarea N-Back, el sujeto volvió a visualizar contenido de video relajante durante los minutos restantes, hasta completar los 10 minutos totales de la sesión. Este periodo de recuperación permitió registrar la actividad EEG mientras la carga cognitiva disminuía gradualmente, retornando hacia niveles basales a medida que el participante se relajaba de nuevo.




Figura 2.44: Flujo del experimento diseñado e implementado.

Durante todo el procedimiento, la señal EEG se registró de forma continua. Se tomaron notas de los tiempos de inicio y fin de cada fase (video de relajación, inicio y fin de N-Back) para luego segmentar y etiquetar los datos según la condición (reposo vs. tarea) en el análisis. Idealmente, estos eventos se habrían marcado automáticamente en la señal mediante triggers sincronizados; sin embargo, en este experimento piloto, los marcadores se gestionaron manualmente debido a las limitaciones de tiempo.

Software de estimulación y registro: La tarea cognitiva 2-Back fue ejecutada en un ordenador portátil mediante el entorno PsyToolkit, una herramienta en línea para diseñar y correr experimentos conductuales. PsyToolkit proporcionó el software del test 2-Back listo para usar, incluyendo la presentación de estímulos y el registro de respuestas del participante (aciertos, errores y tiempos de reacción). Por otro lado, los videos de relajación fueron reproducidos en pantalla completa usando un reproductor multimedia estándar. La sincronización precisa entre los eventos del experimento y los datos EEG no se realizó mediante software durante esta prueba inicial; en su lugar, se sincronizaron posteriormente «a mano» utilizando las marcas de tiempo registradas y señales características en el EEG. El software de adquisición EEG proporcionado por Bitbrain se utilizó para monitorizar y guardar las señales en tiempo real en el PC, asegurando así la integridad de los datos recogidos.




Figura 2.45: Interfaz de la aplicación SennsLite mediante la que se procede al grabado de los datos provenientes del EEG e tiempo real.

A pesar de que algunos electrodos aparezcan en color rojo, se comprobó que la señal percibida fuera correcta (Figura 2.45).

Antes de comenzar con el experimento en sí, se realizaron algunas pruebas para entender en tiempo real los conceptos explicados durante este trabajo. Se procedió a realizar ciertos movimientos musculares como pestañeos, movimientos oculares, apretones de mandíbula, etc. con el fin de poder visualizar en tiempo real (Figura 2.46) cómo éstos afectaban a la señal EEG .




Figura 2.46: Interfaz de la aplicación SennsLite mediante la que se procede al grabado de los datos provenientes del EEG e tiempo real.

2.8.3. Diseño alternativo propuesto

Cabe señalar que, como parte del diseño inicial de este estudio, se planteó un experimento más completo con varios niveles de carga cognitiva, aunque por razones de tiempo y coste computacional no pudo llegar a implementarse. En dicho diseño alternativo, se pretendía emplear el entorno de programación de experimentos PsychoPy (Python) junto con el sistema LabStreamingLayer (LSL) para presentar estímulos y enviar marcadores sincronizados al registro EEG en tiempo real. Este enfoque habría permitido integrar de forma más precisa las señales EEG con los eventos de las tareas cognitivas. El plan era incluir tres condiciones de carga de dificultad creciente (tareas N-Back de nivel 1, 2 y 3), de modo similar a estudios previos donde el aumento de N impone mayor demanda de memoria de trabajo. PsychoPy habría generado las tareas y enviado un marcador por cada estímulo o inicio/fin de bloque a través de LSL, que el software de registro EEG capturaría simultáneamente. Lamentablemente, la implementación de este paradigma avanzado no fue posible dentro del plazo del TFG, por lo que quedó como propuesta para trabajos futuros. No obstante, su concepción se menciona aquí para destacar que el diseño del experimento propio buscó en un inicio abarcar múltiples niveles de carga cognitiva y un control preciso de eventos, en línea con las mejores prácticas en investigaciones de BCI pasivos y carga mental. A pesar de no haberse llevado a la práctica, este diseño propuesto sirvió de guía conceptual para el experimento simplificado que finalmente se realizó, conservando la filosofía de comparar estados de baja carga (reposo/relajación) vs. alta carga (tarea exigente) bajo condiciones controladas similares a las de la base de datos de los pilotos.

2.8.4. Resultados

Tras la grabación, se generó un archivo .bbt. Al descomponerlo, se accedió a todos los datos grabados durante la sesión. Concretamente, se crearon dos carpetas para cada sujeto: RecordingSXXRXXX con 4 archivos, eeg_infor_eeg.csv, eeg_infor_quality.csv, info.json y useMarker.csv y una carpeta SD_extracted con tres archivos EEG-impedances.csv, EEG.csv, signalsInfo.csv. Tras examinar todos los documentos, los archivos que nos interesaban para el estudio eran los eeg_infor_eeg.csv, ya que contenían los datos recogidos por el dispositivo durante la sesión. Se cargaron en un diccionario y comenzó la exploración. Además, los recogidos en la tarjeta SD no tenían timestamp, de ahí la decisión de quedarnos con estos.

2.8.4.1. Exploración y Preprocesamiento

Para empezar, se procedió a realizar una primera vista de los datasets, para asegurarnos de que estuvieran completos y contuvieran toda la información que necesitábamos. Después se procedió a realizar un renombrado de las columnas de los electrodos con el fin de un mejor manejo de las mismas, y además se eliminaron todas aquellas que correspondían a los electrodos 15-32 (en blanco porque no se utilizaron).

Además, se diseñó un código que verificaba para cada dataset :


- Que no hubieran valores nulos (errores en la captación)
- La duración registrada
- Si dicha duración era de 599-601 s (los 10 minutos que debían durar)
- Si todos (14) los canales estaban presentes en el dataset

```
— Comprobaciones para Daniel —  
No hay valores nulos en los 14 canales.  
- Duración registrada: 606.34 s  
Duración fuera de rango (esperado 600s  $\pm 1.0$ s).  
Todos los 14 canales están presentes.  
  
— Comprobaciones para Paula —  
No hay valores nulos en los 14 canales.  
- Duración registrada: 630.87 s  
Duración fuera de rango (esperado 600s  $\pm 1.0$ s).  
Todos los 14 canales están presentes.
```

Figura 2.47: Comprobaciones de nulos, tiempo y variables en ambos datasets.

Como observamos, casi todo salió según lo esperado. Sin embargo, cada dataset contenía unos pequeños segundos extra (Figura 2.47), por lo que se decidió recortarlos a los 600 s (10 min) para que ambos tuvieran la misma duración .

Cuadro 2.4: Señales brutas para ambos sujetos




Según el Cuadro 2.4, a simple vista ya podemos observar la tendencia de la señal. Hasta los 300 segundos presenta una bajada continua (en estos primeros 5 minutos el sujeto se encuentra viendo el video de relajación), después se alcanza el pico (mientras se realiza el test N-Back) y posteriormente la señal se estabiliza (se vuelve a poner el vídeo de relajación).

Al igual que en nuestro dataset principal, ambas grabaciones presentan un offset elevado. Esto explica la necesidad de aplicarles un preprocesado (Cuadro 2.5), que además será prácticamente idéntico al aplicado en el resto del trabajo. De esta forma, aseguramos consistencia entre ambos procesos. Por tanto, se aplicó:

- Eliminación del offset.
- Filtros notch a 50 y 60 Hz.
- Filtro cutoff a 64 Hz.


A pesar de que la frecuencia de muestreo era de 256 Hz, no se aplicó el downsampling, aunque en este caso era prácticamente obligatorio no hacerlo simplemente porque no disponíamos de tantos datos.

Cuadro 2.5: Evolución de las señales de los sujetos durante el preprocesamiento




También se aplicó ICA con MNE (Cuadro 2.6), con el fin de detectar y eliminar posibles artefactos, al igual que en el estudio principal, pero se ajustó experimentalmente el umbral a 40.

Cuadro 2.6: ICA para ambos sujetos. Los nombres de componentes en gris indican aquellas que han sido interpretadas como artefactos y por tanto, eliminadas.



Cuadro 2.7: Señales reconstruidas de ambos sujetos tras ICA



Tras reconstruir las señales (Cuadro 2.7), se guardaron los objetos Array como Dataframes para cada sujeto y se procedió a analizar la carga cognitiva de ambos.

2.8.4.2. Predicciones

Utilizando una DNN para frecuencias de muestreo de 256 Hz, elaborada y entrenada en uno de los experimentos del estudio principal y que demostró lograr buenos resultados, se alcanzaron estos resultados:

```
(149, 169)
5/5 ————— 0s 7ms/step

Daniel → recuento de clases predichas:
pred_class
0    149
Name: count, dtype: int64
(150, 169)
5/5 ————— 0s 560us/step

Paula → recuento de clases predichas:
pred_class
1    144
4     4
0     2
```

Figura 2.48: Predicciones de la red neuronal elaborada para los datos grabados en el laboratorio.

Cómo era de esperar, el rendimiento no iba a ser óptimo (Figura 2.48). Pues ni el experimento, ni los sujetos, y lo más importante, ni el dispositivo utilizado para grabar los datos, eran iguales. No obstante, parece que se han distinguido algunas clases para el sujeto 1, por lo que procederemos a analizar su rendimiento a partir de estas distinciones:




Figura 2.49: Gráfica comparativa de AF4_mean con instantes predichos como clases 0 y 4 marcados.

En la Figura 2.49 podemos analizar cuándo han sido los momentos en los que se ha categorizado a una ventana como clase 0 (carga baja) o clase 4 (carga alta). Para un mejor análisis, realizaremos el mismo estudio sobre la señal AF3 (prefrontal) limpia:




Figura 2.50: Gráfica de la señal bruta del canal AF3 con los instantes predichos como clase 0 y 4.

Las ventanas clasificadas como carga alta en la Figura 2.50 tienen sentido, pues se encuentran justo en el momento en el que el sujeto acaba de empezar la prueba. Llama la atención que las ventanas clasificadas como carga baja también se sitúan cerca de ese periodo de tiempo, pero son justo los momentos previos a empezar. Observaremos las ondas de estas ventanas para poder confirmar el análisis.




Figura 2.51: Forma de onda del canal AF3 de las ventanas predichas como clases 0 y 4.

A la vista de la Figura 2.51, podemos confirmar la hipótesis, pues las ondas clasificadas como clase 4 (alta carga) presentan variaciones mucho más bruscas, mientras que las clase 0 (baja carga) permanecen mucho más constantes a lo largo de la ventana de tiempo.

2.8.5. Conclusiones

Tras finalizar el experimento, se observó que:

- A pesar de que muchas circunstancias clave no eran iguales respecto al estudio original, el modelo elaborado es tan robusto que fue capaz de distinguir patrones dentro de los nuevos datos grabados por el autor del trabajo.
- Se aprendió a utilizar, ajustar y programar un dispositivo EEG.
- Se observaron y entendieron ciertos conceptos clave del estudio, tales como los artefactos, las señales EEG en sí y las grabaciones de las mismas.

Desarrollo

- Se aprendió a diseñar experimentos utilizando Psychopy, LSL y psytoolkit, esencial para futuros proyectos.
- Se observó cómo las señales EEG variaban según la carga cognitiva demandada y se verificó la importancia de las características temporales.

Capítulo 3

Resultados y conclusiones

3.1. Objetivo del análisis y métricas de evaluación

El objetivo principal de este apartado es evaluar distintos modelos de clasificación para predecir la variable `theoretical_difficulty`, la cual se asocia a la carga cognitiva del usuario, y comprobar si es posible mejorar la capacidad de detección de dicha carga en comparación con estudios previos. En concreto, se toma como referencia el resultado obtenido con una red neuronal en un trabajo anterior [54], la cual reportó una sensibilidad del 76,25 % y especificidad del 87,81 % en la detección de altos niveles de carga cognitiva. El análisis presente busca superar estos valores, priorizando la correcta identificación de situaciones de carga elevada.

Recordemos que:

$$\begin{aligned} TP_i &= M_{ii}, & FN_i &= \sum_{\substack{j=1 \\ j \neq i}}^n M_{ij}, \\ FP_i &= \sum_{\substack{j=1 \\ j \neq i}}^n M_{ji}, & TN_i &= \sum_{\substack{j=1 \\ j \neq i}}^n \sum_{\substack{k=1 \\ k \neq i}}^n M_{jk}, \end{aligned}$$

$$\text{Sensibilidad}_i = \frac{TP_i}{TP_i + FN_i}, \quad \text{Especificidad}_i = \frac{TN_i}{TN_i + FP_i},$$

$$\text{Sensibilidad}_{\text{total}} = \frac{1}{n} \sum_{i=1}^n \text{Sensibilidad}_i, \quad \text{Especificidad}_{\text{total}} = \frac{1}{n} \sum_{i=1}^n \text{Especificidad}_i.$$

Dado que en la detección de carga cognitiva resulta crítico no pasar por alto los episodios de alta dificultad (es preferible generar alguna «falsa alarma» antes que dejar de detectar un caso real de sobrecarga), se decidió utilizar la **sensibilidad** o recall como métrica principal de desempeño. Esta métrica indica la proporción de casos positivos (episodios de carga cognitiva elevada) correctamente identificados por el modelo (con $n=1,2,3$ en este caso). No obstante, también se consideran otras métricas complementarias para tener una visión equilibrada del rendimiento, tales como la especificidad

Resultados y conclusiones

(tasa de verdaderos negativos, útil para medir la tasa de falsas alarmas), la precisión positiva (valor predictivo positivo) y el F1-score. En particular, el F1-score permite resumir en un solo indicador el balance entre la sensibilidad y la precisión en la detección de carga. Aun así, la sensibilidad se mantiene como la métrica prioritaria en este estudio, dado el objetivo expreso de mejorar la detección de carga cognitiva.

En cuanto al uso de características, se exploró la influencia de la selección de variables en ciertos modelos. Para la Regresión Logística, k-NN y SVM, se entrenaron dos versiones: una con todas las características disponibles y otra con selección de características y SMOTE (eliminando variables menos relevantes) para verificar si reducir la dimensionalidad mejora la generalización. En cambio, para los modelos basados en árboles de decisión, como Random Forest, XGBoost y Gradient Boosting, no se aplicó una selección manual de atributos, aunque sí se hizo otra versión únicamente aplicando SMOTE. Estos algoritmos incorporan mecanismos intrínsecos de selección durante el entrenamiento, ya que en cada partición de un árbol se escogen las variables más informativas y se puede estimar la importancia de cada predictor en el resultado final.

Adicionalmente, para asegurar una comparación justa entre modelos y extraer el mejor rendimiento de cada técnica, se realizó una optimización de hiperparámetros mediante GridSearchCV con validación cruzada. En cada caso, se definió una malla de posibles combinaciones de parámetros y se evaluó el rendimiento medio (3-fold cross-validation) para seleccionar la configuración óptima. Por ejemplo, en Regresión Logística se ajustó el parámetro de regularización C (inverso de la fuerza de penalización) probando valores en escala logarítmica, eligiendo el que maximiza la métrica objetivo. En k-Nearest Neighbors (kNN) se exploraron distintos números de vecinos k, tipos de pesos (uniformes o según la distancia) y métricas de distancia (Euclídea, Manhattan); en SVM se probaron tanto kernel lineal como no lineal (RBF), variando el parámetro de regularización C y el parámetro de forma del kernel RBF (gamma), así como el uso de `class_weight='balanced'` para contrarrestar el desequilibrio en las clases de mayor dificultad. Para los modelos de ensamble de árboles (Random Forest, XGBoost, Gradient Boosting), se consideraron hiperparámetros como el número de árboles (estimadores), la profundidad máxima de los árboles (`max_depth`), la tasa de aprendizaje (`learning_rate`) en los métodos de boosting, y fracciones de muestreo tanto de instancias como de variables (`subsample`, `colsample/max_features` en cada división) en el caso de los métodos de boosting, con el fin de introducir regularización. El uso de GridSearchCV garantizó que cada modelo fuera evaluado en su mejor configuración encontrada, facilitando así una comparación equitativa de los resultados.

Por último, cabe mencionar que este trabajo incorpora nuevas características en los datos que no habían sido utilizadas en el estudio previo. En particular, se añadieron variables de tipo temporal o derivadas de la secuencia temporal de la tarea, con la intención de capturar la dinámica de la carga cognitiva (tendencias o variaciones a lo largo del tiempo, duración de ciertos estados, etc.). Estas características adicionales podrían aportar información complementaria que ayude a los clasificadores a distinguir con mayor eficacia los niveles de dificultad. En los apartados siguientes se presentarán los resultados de cada modelo y se discutirá, entre otros aspectos, cómo la inclusión de estas nuevas variables puede haber influido en el rendimiento obtenido.

3.2. Comparativa de modelos de clasificación

3.2.1. Regresión Logística (RL)

Se evaluó primero un modelo de regresión logística usando todas las variables disponibles (sin selección previa). Este clasificador lineal alcanzó una exactitud general del 79%, con una sensibilidad del 80% y una especificidad del 89% (Figura 3.1). En términos de F1-score promedio, obtuvo alrededor de 0.80. Estos valores indican un desempeño notablemente alto para un modelo relativamente simple, superando claramente la sensibilidad y especificidad reportadas por la NN de referencia (76,25% y 87,81% respectivamente). De hecho, la regresión logística logró identificar correctamente la mayoría de los casos de carga cognitiva elevada, con muy pocos falsos negativos, a la vez que mantuvo bajo el número de falsos positivos.

```

- LogisticRegression en TEST -
Matriz de Confusión:
[[279  18  94]
 [  5 307  15]
 [ 84  23 325]]

Classification Report:

```

	precision	recall	f1-score	support
0	0.76	0.71	0.74	391
1	0.88	0.94	0.91	327
2	0.75	0.75	0.75	432
accuracy			0.79	1150
macro avg	0.80	0.80	0.80	1150
weighted avg	0.79	0.79	0.79	1150

```

Sensibilidad macro: 0.802
Especificidad macro: 0.894

```

Figura 3.1: *Matriz de Confusión y Reporte de Clasificación para Regresión Logística*

Por otra parte, en la Figura 3.2 se observa que al aplicar selección de características antes de entrenar la regresión logística, se obtuvieron ligeras variaciones en el rendimiento. En esta variante se redujo el conjunto de entrada a las 70 variables más informativas (eliminando posibles colinealidades o atributos menos correlacionados con la dificultad teórica). Con dicha reducción, la RL obtuvo una exactitud del 80%, con una sensibilidad del 81% y especificidad del 89%. Es decir, la sensibilidad aún se mantuvo por encima de la lograda por la DNN previa y a la versión de RL sin selección, mientras que la especificidad se mantuvo en un nivel similar al base.

```
- Resultados LogisticRegression (con SMOTE + FS) -  
Matriz de Confusión:  
[[267 13 111]  
 [ 5 314  8]  
 [ 66 25 341]]  
  
Classification Report:  
              precision    recall  f1-score   support  
  
      0       0.79       0.68       0.73       391  
      1       0.89       0.96       0.92       327  
      2       0.74       0.79       0.76       432  
  
   accuracy              0.80  
  macro avg       0.81       0.81       0.81  
weighted avg       0.80       0.80       0.80  
  
Sensibilidad macro: 0.811  
Especificidad macro: 0.898
```

Figura 3.2: Matriz de Confusión y Reporte de Clasificación para Regresión Logística con Selección de Características y SMOTE

En concreto, se observó que con la selección de variables el modelo ganó algo de capacidad para detectar los casos más difíciles (hubo menos falsos negativos en la clase de mayor dificultad). Este resultado indica que, en este conjunto de datos, la eliminación de características mejoró la generalización de la regresión logística; aunque la versión con todas las variables aprovechaba también la información disponible para ajustar el modelo casi idénticamente. En cualquier caso, la RL (particularmente en su versión con FS+SMOTE, las 70 variables más explicativas y con un parámetro de regularización óptimo $C=100$) demostró ser un modelo competitivo, alcanzando niveles de desempeño cercanos al 80% de F1 y mejorando las métricas de la DNN de referencia en la detección de la carga cognitiva. No obstante, como se verá a continuación, otros modelos más complejos lograron incluso métricas superiores o un balance más favorable entre sensibilidad y precisión.

3.2.2. K-Nearest Neighbors (KNN)

Para el clasificador de vecinos más próximos se realizó igualmente una búsqueda de sus parámetros principales. El mejor resultado se obtuvo con $k=29$ vecinos `clf__n_neighbors: list(range(3, 101, 2))`, usando distancia Manhattan y ponderación de votos uniforme (por lo que los vecinos más cercanos no tienen mayor influencia). Esta configuración del KNN arrojó una exactitud de alrededor de 59%, con una sensibilidad global estimada del 58% y una especificidad de 79% (Figura 3.3). En otras palabras, el modelo KNN produjo unos resultados inferiores a los dos modelos vistos hasta ahora. El informe de clasificación mostró un F1-score macro de 0.59, inferior también al de modelos como la RL o los ensambles de árboles, lo que refleja que el rendimiento por clases estuvo desequilibrado. En particular, el KNN tendió a confundir algunas situaciones de “no carga” como carga leve (falsos positivos en clases bajas de dificultad), reduciendo la precisión global.

3.2. Comparativa de modelos de clasificación

```
- Resultados K-NN -  
Matriz de Confusión:  
[[270  6 115]  
 [ 24 125 178]  
[139  5 288]]  
  
Classification Report:  
              precision    recall  f1-score   support  
  
    0         0.62       0.69       0.66       391  
    1         0.92       0.38       0.54       327  
    2         0.50       0.67       0.57       432  
  
   accuracy          0.59       0.59       0.59       1150  
  macro avg          0.68       0.58       0.59       1150  
weighted avg          0.66       0.59       0.59       1150  
  
Sensibilidad macro: 0.580  
Especificidad macro: 0.788
```

Figura 3.3: Matriz de Confusión y Reporte de Clasificación para K-NN

Al aplicar selección de características se produjo un cambio en la detección de los mejores hiperparámetros: la métrica para los pesos utilizada fue la distancia (a más cerca, más influencia). En cuanto a los resultados recogidos en la Figura 3.4, la precisión y la sensibilidad se incrementaron bastante, así como el F1-score promedio. Además, observamos que las predicciones en la clase 1 aumentan en un factor de 2 (el doble).

```
- Resultados K-NN (con SMOTE + FS) -  
Matriz de Confusión:  
[[268 32 91]  
 [ 15 268 44]  
[127 53 252]]  
  
Classification Report:  
              precision    recall  f1-score   support  
  
    0         0.65       0.69       0.67       391  
    1         0.76       0.82       0.79       327  
    2         0.65       0.58       0.62       432  
  
   accuracy          0.69       0.69       0.69       1150  
  macro avg          0.69       0.70       0.69       1150  
weighted avg          0.68       0.69       0.68       1150  
  
Sensibilidad macro: 0.696  
Especificidad macro: 0.841
```

Figura 3.4: Matriz de Confusión y Reporte de Clasificación para K-NN con Selección de Características

En resumen, el KNN mostró no ser capaz de alcanzar una alta sensibilidad (priorizando la detección de la carga) incluso ajustando adecuadamente sus parámetros, así como que su desempeño en especificidad y F1 global fue inferior al de otros clasificadores.

3.2.3. Máquina de Vectores de Soporte (SVM)

El modelo Support Vector Machine (SVM) optimizado mediante GridSearchCV logró una sensibilidad macro de 0.809 y una especificidad macro de 0.897. La matriz de confusión mostrada en la Figura 3.5 indica una precisión notablemente alta en la clase 1 (93 % precisión y 94 % recall), mientras que las clases 0 y 2 mostraron resultados más moderados, con un recall de aproximadamente 72 %-77 % y una precisión cercana al 75 %. Esto refleja que el modelo estándar clasifica de forma muy eficiente la clase intermedia (1), pero presenta algunas dificultades con las otras clases, especialmente la clase 0.

Parámetros óptimos obtenidos: C: 100, class_weight: 'balanced', gamma: 'scale', kernel: 'linear'

```
- Resultados SVM -
Matriz de Confusión:
[[282  11  98]
 [  9 307  11]
 [ 88  13 331]]

Classification Report:

```

	precision	recall	f1-score	support
0	0.74	0.72	0.73	391
1	0.93	0.94	0.93	327
2	0.75	0.77	0.76	432
accuracy			0.80	1150
macro avg	0.81	0.81	0.81	1150
weighted avg	0.80	0.80	0.80	1150

```
Sensibilidad macro: 0.809
Especificidad macro: 0.897
```

Figura 3.5: Matriz de Confusión y Reporte de Clasificación para SVM

Al incorporar técnicas avanzadas como SMOTE y Selección de Características (k=70 de nuevo), el rendimiento del modelo SVM mejoró significativamente. El recall macro subió ligeramente a 0.826, manteniendo una especificidad macro alta (0.906).

La matriz de confusión de la Figura 3.6 muestra que, aunque se observó una pequeña disminución en la precisión para la clase 0 (del 74 % al 80 %) acompañada de un descenso leve en su recall (72 % a 70 %), las mejoras fueron más evidentes en la clase 2, donde el recall aumentó considerablemente (del 77 % al 82 %). La clase 1 continuó mostrando un desempeño sobresaliente, mejorando aún más su recall hasta un 96 %.

Parámetros óptimos obtenidos (SMOTE + FS): C: C:1000, class_weight: None, gamma: 'scale', kernel: 'linear'

```

- Resultados SVM (con SMOTE + FS) -
Matriz de Confusión:
[[272  8 111]
 [ 5 313  9]
 [ 61 15 356]]

Classification Report:

```

	precision	recall	f1-score	support
0	0.80	0.70	0.75	391
1	0.93	0.96	0.94	327
2	0.75	0.82	0.78	432
accuracy			0.82	1150
macro avg	0.83	0.83	0.82	1150
weighted avg	0.82	0.82	0.82	1150

```

Sensibilidad macro: 0.826
Especificidad macro: 0.906

```

Figura 3.6: *Matriz de Confusión y Reporte de Clasificación para SVM+FS+SMOTE*

La combinación de SMOTE y Selección de Características mejora ligeramente el desempeño general del modelo SVM en términos de sensibilidad, demostrando una mejor capacidad para capturar patrones en clases minoritarias o difíciles, lo que sugiere que esta estrategia combinada es beneficiosa en contextos con datos desbalanceados y de alta dimensionalidad.

3.2.4. Random Forest

El modelo de Bosque Aleatorio entrenado (utilizando 200 árboles de decisión y profundidad máxima libre) obtuvo un desempeño sobresaliente en la clasificación de la dificultad teórica. Con Random Forest se alcanzó una accuracy del 82 %, prácticamente la más alta entre todos los modelos probados, y un F1-score macro igualmente alto (0.83). En términos de sensibilidad y especificidad, el Random Forest logró aproximadamente 82% de sensibilidad y 91% de especificidad global (Figura 3.7). Esto implica que mejoró simultáneamente tanto la detección de casos de carga (sensibilidad) frente al 76,25% base, como la correcta identificación de casos sin carga (especificidad) frente al 87,8 % base . En la matriz de confusión se observó que el bosque aleatorio identificó correctamente casi todos los casos de mayor carga cognitiva (clase de dificultad más alta), y en general distribuyó equilibradamente sus errores, con pocos falsos positivos dispersos en clases de carga baja.

```
- Resultados RandomForest -  
Matriz de Confusión:  
[[283  4 104]  
 [ 9 304  14]  
 [ 72  7 353]]  
  
Classification Report:  
              precision    recall  f1-score   support  
  
      0       0.78       0.72       0.75       391  
      1       0.97       0.93       0.95       327  
      2       0.75       0.82       0.78       432  
  
   accuracy              0.82       1150  
  macro avg       0.83       0.82       0.83       1150  
weighted avg       0.82       0.82       0.82       1150  
  
Sensibilidad macro: 0.824  
Especificidad macro: 0.905
```

Figura 3.7: Matriz de Confusión y Reporte de Clasificación para Random Forest

Un factor a resaltar es que no se realizó selección manual de características para Random Forest, ya que como se mencionó, este algoritmo tiende a enfocarse en las variables más informativas durante sus divisiones internas. En línea con ello, el Random Forest entrenado asignó ponderaciones de importancia altas a ciertas características relevantes (ver Figura 3.13 en sección 3.3), mientras que variables irrelevantes tuvieron poca o nula influencia en las predicciones. La literatura respalda este enfoque, indicando que Random Forest maneja adecuadamente conjuntos con muchas variables al realizar una especie de selección implícita de atributos durante el aprendizaje. De este modo, el modelo pudo beneficiarse de todo el espectro de características para lograr un rendimiento óptimo, sin incurrir en sobreajuste notable. De todas formas, se volvió a entrenar el modelo pero simplemente aplicándole SMOTE.

```
- Resultados RandomForest (con SMOTE) -  
Matriz de Confusión:  
[[287  4 100]  
 [ 6 305  16]  
 [ 75  8 349]]  
  
Classification Report:  
              precision    recall  f1-score   support  
  
      0       0.78       0.73       0.76       391  
      1       0.96       0.93       0.95       327  
      2       0.75       0.81       0.78       432  
  
   accuracy              0.82       1150  
  macro avg       0.83       0.82       0.83       1150  
weighted avg       0.82       0.82       0.82       1150  
  
Sensibilidad macro: 0.825  
Especificidad macro: 0.906
```

Figura 3.8: Matriz de Confusión y Reporte de Clasificación para Random Forest + SMOTE

Comparando el reporte de la Figura 3.8 con el del modelo base (Figura 3.7), la so-

3.2. Comparativa de modelos de clasificación

lución de Random Forest+SMOTE captura de casi igual forma las relaciones y las interacciones entre variables.

En términos prácticos, el Random Forest alcanzó métricas ligeramente superiores o equivalentes a las de la SVM lineal y XGBoost, situándose entre los mejores modelos del estudio. La mejora obtenida respecto al modelo neuronal previo es significativa en ambos ejes (sensibilidad y especificidad), lo que valida el uso de ensambles de árboles con el conjunto de características propuesto para la detección fiable de carga cognitiva.

3.2.5. XGBoost

La implementación de Extreme Gradient Boosting (XGBoost) arrojó igualmente resultados muy positivos. Tras llevar a cabo una optimización de hiperparámetros con GridSearch, se encontró que una configuración relativamente simple de XGBoost era suficiente para obtener el máximo rendimiento: concretamente, con una tasa de aprendizaje `learning_rate` moderada (~ 0.1), 200 estimadores (árboles) de profundidad máxima 7 y submuestreo de ejemplos = 0.8 y de columnas = 1), el modelo alcanzó su mejor desempeño en validación. En su evaluación final (Figura 3.9), el XGBoost reportó una exactitud alrededor del 84%, con un recall (sensibilidad) aproximado del 84% y una especificidad en torno al 92%. Estas cifras indican un equilibrio excepcional: XGBoost logró detectar casi un 84% de los episodios de carga cognitiva (mejorando en alrededor de 8 puntos la sensibilidad de la NN previa) a la vez que redujo aún más los falsos positivos, alcanzando una especificidad alrededor de 5 puntos superior. El resultado fue un F1-score promedio de 0.84, superior también al de Random Forest.

```
- Resultados XGBoost -
Matriz de Confusión:
[[300  2  89]
 [ 10 305 12]
 [ 71  3 358]]

Classification Report:
              precision    recall  f1-score   support

     0         0.79         0.77         0.78         391
     1         0.98         0.93         0.96         327
     2         0.78         0.83         0.80         432

 accuracy         0.84         0.84         0.84        1150
 macro avg         0.85         0.84         0.85        1150
weighted avg         0.84         0.84         0.84        1150

Sensibilidad macro: 0.843
Especificidad macro: 0.916
```

Figura 3.9: Matriz de Confusión y Reporte de Clasificación para XGBoost

Al igual que con Random Forest, no fue necesario filtrar variables de antemano para XGBoost, ya que el algoritmo aplica regularización interna y calcula importancias de atributos durante el entrenamiento. Esto previno que atributos irrelevantes afectaran negativamente el modelo. De hecho, XGBoost tiende a asignar pesos (ganancias) bajos a las variables que no contribuyen a reducir la pérdida, excluyéndolas efectivamente de la decisión final. Gracias a estos mecanismos, el modelo pudo aprovechar las

Resultados y conclusiones

múltiples características (incluidas las temporales nuevas) sin sobreajustar. Cabe señalar que la configuración óptima encontrada (200 árboles de profundidad máx 7 con `learning_rate` moderado) sugiere que el modelo no necesitó una gran complejidad para ajustarse bien a los datos; es posible que los datos ya fueran suficientemente informativos y la regularización intrínseca de XGBoost ayudó a mantener el modelo generalizable. También se reestudió su desempeño aplicando SMOTE.

```
- Resultados XGBoost (con SMOTE + FS) -
Matriz de Confusión:
[[292  6  93]
 [  7 309 11]
 [ 88  8 336]]

Classification Report:
              precision    recall  f1-score   support

     0       0.75         0.75         0.75         391
     1       0.96         0.94         0.95         327
     2       0.76         0.78         0.77         432

 accuracy          0.81         0.81         0.81         1150
 macro avg         0.82         0.82         0.82         1150
 weighted avg      0.82         0.81         0.82         1150

Sensibilidad macro: 0.823
Especificidad macro: 0.904
```

Figura 3.10: *Matriz de Confusión y Reporte de Clasificación para XGBoost+SMOTE*

Tras aplicar SMOTE al subconjunto de train de nuestro conjunto de datos, se observa en la Figura 3.10 que el accuracy disminuyó en un 3 %, así como su sensibilidad y su especificidad también cayeron.

En comparación con la NN previa, XGBoost muestra una mejora clara: su sensibilidad y especificidad superan notablemente a la red de referencia, validando que un ensamble bien ajustado puede alcanzar al menos el mismo nivel de rendimiento e incluso mejorar la precisión de la detección de carga. De hecho, XGBoost sobresale ligeramente sobre Random Forest en términos de especificidad (menos falsos positivos), lo cual puede ser valioso en contextos donde las falsas alarmas deban minimizarse. En conclusión, XGBoost se posiciona como uno de los mejores modelos evaluados, logrando el objetivo de mejorar la detección de la carga cognitiva teórica respecto al estudio previo.

3.2.6. Gradient Boosting (GB)

Finalmente, se analizó el algoritmo de Gradient Boosting clásico (implementación de `sklearn`), estrechamente relacionado con XGBoost, pero con posibilidades de regularización ligeramente distintas. Se evaluaron dos configuraciones principales de Gradient Boosting para ilustrar el impacto de los hiperparámetros en su rendimiento:

Se entrenó, tras la búsqueda de GridSearch, un modelo de Gradient Boosting con parámetros diferentes al estándar: `learning_rate` = 0.1, 200 estimadores, profundidad de árboles = 5, submuestreo de instancias constante (`subsample`=1.0) y (`max_features` = `sqrt`). Este modelo obtuvo, según la Figura 3.11, un accuracy de 84 %, superior a

3.2. Comparativa de modelos de clasificación

la de Random Forest e igual a la de XGBoost. Al desglosar su rendimiento, se encontró una sensibilidad global alta, de aproximadamente 85 %, y una especificidad alta también, alrededor de 92 %. El F1 macro se quedó en 0.85. En resumen, aunque la configuración inicial de GB ya superaba la sensibilidad de la DNN baseline, se sitúa por delante de XGBoost en desempeño general, ya que recordamos que buscamos aumentar la sensibilidad como objetivo principal.

```
- Resultados Gradient Boosting -
Matriz de Confusión:
[[300  3  88]
 [  9 306  12]
 [ 70  2 360]]

Classification Report:
              precision    recall  f1-score   support

     0       0.79         0.77         0.78         391
     1       0.98         0.94         0.96         327
     2       0.78         0.83         0.81         432

 accuracy          0.84
 macro avg         0.85         0.85         0.85         1150
weighted avg         0.84         0.84         0.84         1150

Sensibilidad macro: 0.845
Especificidad macro: 0.917
```

Figura 3.11: *Matriz de Confusión y Reporte de Clasificación para Gradient Boosting*

Asimismo, se decidió revalorar este modelo aplicándole SMOTE.

```
- Resultados Gradient Boosting (con SMOTE) -
Matriz de Confusión:
[[302  3  86]
 [  9 309  9]
 [ 81  5 346]]

Classification Report:
              precision    recall  f1-score   support

     0       0.77         0.77         0.77         391
     1       0.97         0.94         0.96         327
     2       0.78         0.80         0.79         432

 accuracy          0.83
 macro avg         0.84         0.84         0.84         1150
weighted avg         0.83         0.83         0.83         1150

Sensibilidad macro: 0.839
Especificidad macro: 0.913
```

Figura 3.12: *Matriz de Confusión y Reporte de Clasificación para Gradient Boosting+SMOTE*

A la vista de la Figura 3.12, se repite el comportamiento de incorporar esta técnica con XGBoost, ya que el rendimiento general disminuye, por lo que nos quedaremos con su modelo base.

3.3. Importancia de las características y aportes de las nuevas variables

Como se mencionó, un factor diferenciador de este trabajo es la inclusión de nuevas características, en particular de tipo temporal, destinadas a mejorar la modelización de la carga cognitiva. Las Figuras 3.13, 3.14 y 3.15 ilustran la importancia relativa de las características calculada por los 3 modelos de ensamble.




Figura 3.13: Coeficientes de importancia de un Random Forest sobre el conjunto completo de datos




Figura 3.14: Coeficientes de importancia de un XGBoost sobre el conjunto completo de datos

3.3. Importancia de las características y aportes de las nuevas variables




Figura 3.15: Coeficientes de importancia de un GradientBoosting sobre el conjunto completo de datos

En dichas visualizaciones se aprecia que varias de las nuevas variables introducidas figuran entre las más influyentes para la predicción de la dificultad teórica. Por ejemplo, características como la variación de la carga en ventanas temporales, la duración de ciertos eventos cognitivos o medidas temporales derivadas muestran importancias altas en el modelo, comparables y superiores a las de características más tradicionales (bandas de frecuencia). Esto sugiere que la dinámica temporal de la carga cognitiva aporta información valiosa que ayuda a los clasificadores a distinguir estados de carga alta vs. baja con mayor precisión. En otras palabras, no solo importa el valor instantáneo de ciertas señales o indicadores, sino también cómo cambian o evolucionan con el tiempo, y esas tendencias están siendo aprovechadas por los modelos predictivos.

Este hallazgo concuerda con lo reportado en la literatura reciente, donde se ha visto que la integración de atributos temporales con otras características (espaciales, espectrales, etc.) mejora la capacidad de los sistemas automáticos para reconocer estados cognitivos. En nuestro caso, la disponibilidad de dichas variables temporales y de otras nuevas métricas derivadas probablemente haya contribuido de forma significativa a las mejoras de rendimiento observadas frente al modelo neuronal anterior. De hecho, los modelos clásicos aquí probados (RL, K-NN, SVM, ensambles) lograron igualar y superar la efectividad de la NN, lo cual puede atribuirse en parte a que contaban con un conjunto de características más informativo. En síntesis, la incorporación de nuevas fuentes de datos y características (especialmente aquellas que capturan la evolución temporal de la carga cognitiva) ha resultado clave para alcanzar una mayor sensibilidad en la detección de la carga cognitiva sin comprometer la especificidad. Este enriquecimiento del espacio de características, combinado con la selección apropiada de modelos y la optimización de sus hiperparámetros, ha permitido cumplir el objetivo de mejorar la detección de la carga cognitiva teórica respecto al estado del arte previo.

3.4. Resultados de la Red Neuronal Elaborada

3.4.1. Análisis de la Red Neuronal DNN Propuesta

Este apartado presenta un análisis detallado de la red neuronal profunda (DNN) desarrollada en este trabajo y una comparación con modelos previos, en particular con la red convolucional EEG_ConvNet reportada en estudios anteriores, así como con modelos de machine learning tradicionales (Random Forest, XGBoost, SVM, etc.). La DNN propuesta ha sido diseñada con el objetivo de mejorar significativamente los resultados de clasificación de estados mentales obtenidos previamente (sensibilidad del 76,25 % y especificidad del 87,81 % en la detección de alta carga mental). A continuación, se describe la arquitectura de la nueva red, su proceso de entrenamiento y estabilidad, los resultados alcanzados, y se comparan dichos resultados con los de la EEG_ConvNet y los de otros clasificadores clásicos, discutiendo cuál puede considerarse el mejor modelo global en función de métricas, estabilidad, interpretabilidad y coste computacional.

Layer (type)	Output Shape	Param #
input_layer_30 (InputLayer)	(None, 267)	0
gaussian_noise_29 (GaussianNoise)	(None, 267)	0
dense_130 (Dense)	(None, 256)	68,608
leaky_re_lu_100 (LeakyReLU)	(None, 256)	0
batch_normalization_100 (BatchNormalization)	(None, 256)	1,024
dropout_100 (Dropout)	(None, 256)	0
dense_131 (Dense)	(None, 128)	32,896
leaky_re_lu_101 (LeakyReLU)	(None, 128)	0
batch_normalization_101 (BatchNormalization)	(None, 128)	512
dropout_101 (Dropout)	(None, 128)	0
dense_132 (Dense)	(None, 64)	8,256
leaky_re_lu_102 (LeakyReLU)	(None, 64)	0
batch_normalization_102 (BatchNormalization)	(None, 64)	256
dropout_102 (Dropout)	(None, 64)	0
dense_133 (Dense)	(None, 3)	195

Total params: 111,747 (436.51 KB)

Trainable params: 110,851 (433.01 KB)

Non-trainable params: 896 (3.50 KB)

Figura 3.16: Esquema de la arquitectura de la red DNN propuesta, formada por capas densas totalmente conectadas con normalización por lotes (batch normalization), dropout y ReLu. La red toma un vector de 267 características de entrada y produce una clasificación en 3 clases de salida.

La red neuronal desarrollada consta de varias capas densas intercaladas con técnicas avanzadas de regularización y estabilización. En primer lugar, la entrada del mode-

lo es un vector de 267 características extraídas de las señales EEG preprocesadas, condensando información esencial para facilitar el aprendizaje. Posteriormente, se aplica ruido gaussiano (GaussianNoise) para aumentar la robustez del modelo ante variaciones en los datos.

A continuación, la arquitectura propuesta (Figura 3.16) consta de tres capas densas consecutivas:

- **Primera capa densa:** 256 neuronas con inicialización He Normal y activación Leaky ReLU ($\alpha=0.2$), seguida por Batch Normalization que normaliza las activaciones acelerando la convergencia del modelo y Dropout con una tasa del 50 % para prevenir el sobreajuste.
- **Segunda capa densa:** 128 neuronas, repitiendo la secuencia de activación Leaky ReLU, Batch Normalization y Dropout.
- **Tercera capa densa:** 64 neuronas, nuevamente utilizando Leaky ReLU, Batch Normalization y Dropout.

Finalmente, la red termina con una capa de salida densa de 3 neuronas, correspondientes a las tres clases objetivo definidas en el problema, utilizando una activación softmax que genera probabilidades asociadas a cada clase. Esta arquitectura posee un total de 111,747 parámetros, siendo 110,851 parámetros entrenables y 896 parámetros no entrenables, derivados del uso de Batch Normalization.

Se probaron múltiples arquitecturas (small, medium, large, xlarge, xxlarge), pero finalmente se eligió la arquitectura mediana (medium) porque sus resultados son muy similares a las redes más complejas, pero con significativamente menos parámetros, lo cual facilita el entrenamiento, reduce riesgos de sobreajuste y mejora la generalización.

3.4.2. Proceso de Entrenamiento y Estabilidad

La DNN propuesta se entrenó usando el conjunto de datos EEG preparado para este proyecto. Se implementó una función de pérdida personalizada conocida como Focal Loss, especialmente efectiva en escenarios con clases desbalanceadas, enfatizando en los ejemplos más difíciles de clasificar. Se utilizó un optimizador Adam con tasa de aprendizaje adaptativa.

Para manejar el desbalance de clases, se aplicó Borderline SMOTE, una técnica específica de sobremuestreo que prioriza los ejemplos cercanos a la frontera entre clases. Esta técnica incrementó notablemente el rendimiento, especialmente en clases minoritarias.

Durante el entrenamiento, se utilizaron técnicas como Early Stopping y ReduceLROnPlateau para garantizar un entrenamiento eficiente y estable, evitando el sobreajuste y asegurando la convergencia a mínimos óptimos.

La curva de pérdida (Figura 3.17) presentó una disminución rápida inicial, seguida de una convergencia estable, indicando un aprendizaje eficaz sin sobreajuste evidente (curvas de entrenamiento y validación prácticamente coincidentes tras varias épocas).




Figura 3.17: Pérdida para la red medium.

3.4.3. Resultados Obtenidos con la DNN

La DNN propuesta alcanzó resultados sólidos (Figura 3.18):

- **Precisión (accuracy):** aproximadamente 75 %.
- **Sensibilidad:** 0.756, indicando un buen equilibrio en la detección de todas las clases.
- **Especificidad:** 0.873.
- La matriz de confusión mostró que las clases se predicen consistentemente bien, aunque la clase 1 mostró mayor precisión y recall (80 % y 85 %, respectivamente), lo que evidencia áreas específicas para mejorar la diferenciación entre clases 0 y 2.

Estos resultados permanecieron consistentes en diferentes particiones y ejecuciones, indicando robustez y generalización efectiva.




Figura 3.18: Matriz de confusión y reporte de clasificación para la red medium.

3.4.4. Justificación de Técnicas Utilizadas

1. **Batch Normalization:** acelera el entrenamiento al estabilizar la distribución interna de las activaciones, reduciendo la sensibilidad a la inicialización de parámetros y variaciones en la tasa de aprendizaje.
2. **Dropout:** previene el sobreajuste mediante la desconexión aleatoria de neuronas durante el entrenamiento.
3. **Ruido Gaussiano:** mejora la robustez ante variabilidad y ruido en los datos de entrada.
4. **Leaky ReLU:** evita el problema de neuronas “muertas”, permitiendo el paso de pequeños gradientes negativos.
5. **SMOTE Borderline:** especialmente efectiva para equilibrar clases minoritarias, centrando el esfuerzo en ejemplos más informativos.
6. **Focal Loss:** ideal para mejorar el aprendizaje en situaciones desbalanceadas, al enfocar el entrenamiento en ejemplos difíciles.

En resumen, la arquitectura propuesta ofrece un rendimiento balanceado y robusto con una complejidad moderada, mostrando clara superioridad frente a enfoques previos como la red convolucional EEG_ConvNet, gracias a la selección cuidadosa de características y al uso estratégico de técnicas avanzadas de entrenamiento y regularización.

3.5. Modelo recomendado

	Sensibilidad	Especificidad	Accuracy
Gradient Boosting	0.845	0.917	0.84
XGBoost	0.843	0.916	0.84
Gradient Boosting + SMOTE	0.839	0.913	0.83
SVM + SMOTE + FS	0.826	0.906	0.82
Random Forest + SMOTE	0.825	0.906	0.82
Random Forest	0.824	0.905	0.82
XGBoost + SMOTE	0.823	0.904	0.81
Regresión Logística + FS + SMOTE	0.811	0.898	0.80
SVM	0.809	0.897	0.80
Regresión Logística	0.802	0.894	0.79
Paper	0.760	0.870	NaN
Medium Net	0.756	0.873	0.75
Small Net	0.751	0.870	0.75
Large Net	0.750	0.870	0.75
XX-Large Net	0.749	0.869	0.74
X-Large Net	0.746	0.868	0.74
K-NN + FS + SMOTE	0.696	0.841	0.69
K-NN	0.580	0.788	0.59

Figura 3.19: Tabla resumen del rendimiento de todos los modelos considerados, ordenados por sensibilidad y especificidad.

En la tabla proporcionada (Figura 3.19) se presenta un resumen comparativo del rendimiento de múltiples modelos predictivos evaluados sobre la tarea específica de detección de carga cognitiva elevada mediante señales EEG. Recordemos que, dado que el objetivo principal es no dejar pasar episodios críticos de alta dificultad (carga cognitiva elevada), se eligió la sensibilidad (recall) como métrica principal.

Al evaluar los modelos según este criterio, el mejor desempeño lo presenta claramente el modelo **Gradient Boosting**, con una sensibilidad del 84.5 %, especificidad del 91.7 % y accuracy general del 84 %. Esta combinación destaca especialmente por equilibrar una elevada sensibilidad (crítica para asegurar la detección de episodios de alta carga mental) con una excelente especificidad (reduciendo al mínimo las falsas alarmas).

Comparativamente, el modelo XGBoost también mostró resultados muy competitivos con una sensibilidad del 84.3 % y especificidad del 91.6 %, ligeramente inferior al Gradient Boosting, pero prácticamente similar. Sin embargo, por una leve diferencia en sensibilidad, el Gradient Boosting se posiciona como el modelo más apropiado para este estudio.

Si el objetivo específico del estudio fuera seleccionar una red neuronal, es destacable que la **red neuronal densa “medium” (Medium Net)** es preferible en comparación con la red convolucional utilizada en estudios previos. A pesar de presentar una sensibilidad algo menor (75.6 % frente al 76 % de la red CNN Paper), la red Medium Net

tiene una ventaja considerable en términos de eficiencia y complejidad computacional, al contar con aproximadamente 400,000 parámetros menos que la CNN Paper. Esta reducción significativa en parámetros implica menos recursos computacionales necesarios, menor riesgo de sobreajuste y mayor facilidad para el entrenamiento y la generalización del modelo.

Además, es crucial resaltar que los resultados generales obtenidos en este estudio superan claramente los reportados por el modelo original del paper [54], incluso considerando que se ha trabajado con una cantidad significativamente mayor de instancias y aplicando un preprocesamiento ligeramente diferente, más realista y adaptado específicamente para optimizar la detección efectiva de carga cognitiva.

En conclusión, dado el criterio principal (maximizar sensibilidad), el modelo más recomendable para la detección de episodios críticos es claramente el Gradient Boosting, debido a su equilibrio superior entre sensibilidad y especificidad. No obstante, en escenarios donde se prefiera una solución basada en redes neuronales, la DNN propuesta (Medium Net) ofrece un balance óptimo entre complejidad y rendimiento, siendo considerablemente más eficiente que la CNN previamente utilizada y con resultados prácticamente equivalentes.

3.6. Conclusiones Personales

Este proyecto ha supuesto una oportunidad invaluable para integrar conocimientos de distintas disciplinas y enfrentar desafíos prácticos en la interpretación de datos cerebrales mediante técnicas de Data Science & AI. A continuación, destaco lo más relevante de lo aprendido:

- **Neurotecnología:** Adquirí un conocimiento profundo sobre cómo interpretar las señales EEG para extraer información sobre los estados cognitivos, reconociendo la importancia fundamental de entender la fisiología cerebral que sustenta estas mediciones. Este proceso resaltó la complejidad inherente a las señales cerebrales, incluyendo su ruido, variabilidad individual y dependencia del contexto. Además, comprendí que el éxito en aplicaciones neurotecnológicas depende no solo del algoritmo utilizado, sino también de una adecuada adquisición de datos y un preprocesamiento eficaz que mitigue los artefactos.
- **Aplicación de inteligencia artificial:** La experiencia práctica confirmó el potencial significativo de la inteligencia artificial en la extracción de patrones sutiles y relevantes en datos EEG, destacando especialmente el uso efectivo de redes neuronales profundas y de la optimización de hiperparámetros en modelos de IA básicos. No obstante, también se aprendió sobre la necesidad crítica de evitar el sobreajuste y garantizar que los modelos capturen correlaciones auténticamente relacionadas con los procesos cerebrales, así como la importancia vital de la validación rigurosa con sujetos independientes para asegurar generalización.
- **Selección de características:** Experimenté de primera mano la importancia decisiva de seleccionar adecuadamente las características extraídas de las señales EEG. La ingeniería de características, combinando conocimiento del dominio con métodos automáticos de selección, me demostró ser esencial para mejorar el desempeño, facilitar la interpretabilidad del modelo y reducir costos computacionales. Este aspecto fue crucial para mejorar la calidad y eficacia de los

modelos de IA.

- **Diseño del modelo y rendimiento:** Se evidenció claramente que las decisiones relacionadas con la arquitectura del modelo, como la inclusión de capas de normalización por lotes (Batch Normalization) y técnicas de regularización como el dropout, tienen un impacto significativo en el rendimiento. La comparación entre diversos modelos subrayó que un mayor número de capas o parámetros no siempre implica mejores resultados; más bien, es fundamental equilibrar la complejidad del modelo con la cantidad de datos disponibles y los objetivos del problema.
- **Interacción entre datos y modelos inteligentes:** Reconocí la interdependencia crucial entre la calidad de los datos y la efectividad de los sistemas inteligentes que los analizan. Este trabajo destacó la importancia de asegurar que los datos utilizados representen adecuadamente el fenómeno estudiado y estén libres de sesgos, resaltando que un enfoque integral desde la recolección de datos hasta la validación del modelo es imprescindible para obtener resultados exitosos en neurotecnología.

En conjunto, **este proyecto refleja un crecimiento muy significativo en mi formación**. A través de este TFG, logré integrar conocimientos teóricos de neurociencia e inteligencia artificial en una aplicación práctica, desarrollando no solo competencias técnicas (en programación, modelado y análisis de datos), sino también una visión crítica sobre cómo abordar problemas complejos en la intersección entre la tecnología y las ciencias de la vida. Este aprendizaje sienta las bases para futuras investigaciones o desarrollos en el campo, donde la continua evolución de la neurotecnología y la IA abrirá nuevas posibilidades para entender y mejorar la interacción entre el cerebro humano y los sistemas inteligentes.

3.7. Trabajo Futuro

Aunque el presente trabajo ha cumplido con sus objetivos iniciales, existen diversas oportunidades para ampliar y mejorar el sistema desarrollado. A continuación se proponen algunas líneas de trabajo futuro que podrían explorarse:

- **Mejorar la arquitectura de la red neuronal elaborada:** Se podría refinar la topología de la DNN ajustando sus hiperparámetros e incorporando capas adicionales de forma controlada.
- **Experimentar con modelos híbridos CNN-RNN:** Se propone investigar arquitecturas que combinen redes neuronales convolucionales (CNN) y redes recurrentes (RNN) para aprovechar simultáneamente la información espacial y temporal de las señales EEG. Las CNN podrían extraer características locales y espaciales a partir de los múltiples canales del EEG (identificando patrones de activación que ocurren de forma sincronizada en distintas regiones corticales), mientras que las RNN del tipo LSTM o GRU capturarían la dinámica temporal de la actividad cerebral a lo largo de la tarea. Este enfoque híbrido permitiría modelar de manera más rica la naturaleza espaciotemporal de la carga cognitiva, potencialmente aumentando la precisión y robustez en la detección de cambios en el nivel de esfuerzo mental.
- **Optimizar el modelo para ejecución en tiempo real con baja latencia:** Para que el

sistema sea aplicable en un entorno de simulación de vuelo operativo, es fundamental reducir el tiempo de procesamiento y la complejidad computacional del algoritmo. En futuros desarrollos se podría simplificar la arquitectura del modelo (mediante poda de conexiones sinápticas de poca relevancia o reduciendo la dimensionalidad de entrada mediante selección de características) y aplicar técnicas de optimización como la cuantización de pesos, de modo que el modelo resultante sea más liviano. Asimismo, aprovechar hardware especializado (GPUs de baja potencia, FPGAs o dispositivos embebidos de inferencia neuronal) podría ayudar a lograr que la estimación del esfuerzo cognitivo ocurra prácticamente al instante, sin interrumpir la experiencia de simulación del piloto.

- Extender el estudio a un número mayor de sujetos y escenarios: Actualmente, el modelo podría estar ajustado a las características de un conjunto limitado de participantes y condiciones de prueba. Un paso siguiente importante sería validar y entrenar el sistema con más pilotos, idealmente de distintos niveles de experiencia y perfiles, para comprobar que las predicciones se mantienen consistentes frente a la variabilidad interindividual. Igualmente, conviene probar el enfoque en escenarios de simulación de vuelo adicionales y más complejos para evaluar cómo se comporta el modelo bajo circunstancias variadas. Ampliar la diversidad de datos ayudaría a robustecer la generalización del algoritmo y acercarlo a un uso práctico más amplio.
- Automatizar la eliminación de artefactos en las señales EEG: Una línea de mejora clave en el flujo de procesamiento sería implementar métodos más autónomos de detección y corrección de artefactos, minimizando la intervención manual. Por ejemplo, podrían emplearse algoritmos de aprendizaje automático entrenados para identificar componentes de ruido (parpadeos, movimientos o interferencias electromecánicas) en las grabaciones EEG y filtrarlos en tiempo real. También existe la posibilidad de usar extensiones de MNE u otras herramientas que auto-etiquetan componentes ICA basadas en criterios estadísticos o machine learning. Al lograr un preprocesamiento mayormente automático y confiable, se agilizaría el pipeline completo de análisis y se sentarían las bases para un sistema en tiempo real que garantice la calidad de la señal entrante de forma continua.
- Integrar el sistema en una plataforma utilizable en simuladores de vuelo reales: Para trasladar esta tecnología al ámbito aplicado, sería necesario desarrollar interfaces que conecten el módulo de análisis EEG con el software de simulación de vuelo. Un trabajo futuro consistiría en construir un prototipo donde los datos EEG del piloto se transmitan en vivo durante la sesión en el simulador, de modo que el cálculo del esfuerzo cognitivo esté disponible en tiempo real. Esto podría reflejarse en una visualización para el instructor o en retroalimentación al propio simulador, permitiendo, por ejemplo, ajustar dinámicamente la carga de trabajo de la misión si se detecta que el piloto está alcanzando un estado de sobrecarga cognitiva. La integración completa abarcaría consideraciones prácticas como la facilidad de uso del equipo EEG (sensores inalámbricos, sistemas de calibración rápida) y la robustez del sistema en un entorno operativo, garantizando que la presencia del sistema de monitoreo no interfiera con la seguridad ni la inmersión del simulador.
- Aplicar técnicas de interpretabilidad del modelo (XAI, eXplainable AI): Dado el

Resultados y conclusiones

carácter de “caja negra” que pueden tener las redes neuronales profundas, sería valioso incorporar métodos que permitan explicar las predicciones del modelo en términos neurofisiológicos comprensibles. Por ejemplo, se podría analizar la importancia de cada canal o característica de entrada en la decisión del modelo, visualizar patrones de activación internos de la DNN que correspondan a determinados estados cognitivos, o emplear mapas de calor temporales/frecuenciales que destaquen qué segmentos de la señal EEG influyen más en la estimación de la carga. Estas técnicas de interpretabilidad ayudarían a validar que el modelo basa sus decisiones en indicadores coherentes con la literatura (como aumentos de ciertas bandas de frecuencia durante alta carga mental) y proporcionarían confianza adicional a pilotos e instructores al comprender por qué el sistema emite un determinado diagnóstico de esfuerzo cognitivo.

Capítulo 4

Impacto del trabajo

4.1. Impacto general

4.1.1. Impacto en el ámbito personal

Este trabajo amenaza con revolucionar la forma en que el ser humano piensa en la salud cognitiva y la calidad de vida. El hecho de que una persona pueda, en última instancia, evaluar y gestionar en tiempo real su carga mental le permitiría prevenir el agotamiento total y, en efecto, optimizar su rendimiento personal y su seguridad en la realización de actividades críticas como el vuelo o la conducción. Existe el riesgo de que la privacidad cognitiva se vea comprometida, ya que la utilización de dispositivos como los sensores EEG implica la recolección de datos relevantes para la identidad personal y el estado de ánimo. Otra amenaza es que se convierta en una adicción que inhiba la búsqueda de estrategias cognitivas naturales o de una ansiedad derivada del monitoreo constante (efecto de Hawthorne) [55]. Por ello, no se puede permitir que estas tecnologías se utilicen contra la autonomía individual; la toma de decisiones siempre debe dejarse al usuario.

4.1.2. Impacto en el ámbito empresarial

En el contexto laboral, estos dispositivos neurológicos podrían contribuir a la seguridad, salud y eficiencia en el trabajo. Este proyecto, que puede identificar situaciones de carga de tensión mental excesiva y prevenir errores humanos, contribuiría a la productividad y el bienestar al adaptar las obligaciones laborales a la capacidad cognitiva del ser humano, especialmente en ocupaciones críticas.

Además, estas herramientas consideran métricas científicas recopiladas de manera objetiva y pueden facilitar programas de formación individualizados. Sin embargo, también hay amenazas; la falta de regulación y el uso de la monitorización para presionar o castigar a los empleados son algunos de los aspectos más serios. Otros riesgos son la privacidad y la confidencialidad, la limitación del acceso y la resistencia al cambio por temor a la sombra constante de la vigilancia. Considerando estos riesgos y oportunidades, es necesario implementar medidas éticas, respetar la privacidad así como presentarse con una transparencia óptima y priorizar el bienestar general sobre todo.

4.1.3. Impacto en el ámbito social

La medición de la carga cognitiva a través de la tecnología neuronal puede aportar significativas mejoras en la seguridad pública, educación y salud comunitaria. En el caso del transporte y aviación, la detección de situaciones de fatiga o distracción podría evitar accidentes y, en general, reducir errores humanos, beneficiando a la seguridad de toda la sociedad.

En la educación, un manejo más efectivo de la carga puede inducir a un clima de aprendizaje óptimo, reducir la deserción y mejorar el rendimiento académico, afectando a una población mejor formada y más saludable psicológicamente. Sin embargo, existen desafíos como la aceptación pública de estas tecnologías, el temor de utilizarlas indebidamente y eventualmente ser descubiertos, y el hecho de que aumentarán las desigualdades si estas tecnologías solo se utilizan por una comunidad privilegiada, además del riesgo de poder etiquetar biotipos causales en el aumento de la carga cognitiva. Para que el impacto social sea plenamente positivo, es clave tratar asuntos de este tipo en el campo ético, tratar objetivos sobre este dilema educacional y la distribución igualitaria de estos aparatos.

4.1.4. Impacto en el ámbito económico

Este TFG tiene el potencial de hacer un fuerte impacto económico, originando oportunidades comerciales en la neurotecnología y reducción de costes productivos asociados. La industria de las BCI, que crece rápidamente, convergiendo desde una valoración de 2,1 mil millones de dólares en 2023 a 4,5 mil millones en 2029 [56], presenta posibles mercados para nuevos productos y servicios, donde dispositivos portátiles para medir la fatiga cognitiva y soluciones mentales de workflow estarán presentes, lo que induce a empleo especializado y economía del conocimiento. Indirectamente, una buena gestión de la carga cognitiva puede reducir el gasto asociado con accidentes de trabajo, errores operacionales, abandono relacionado con enfermedades y ausencias causadas por estrés, aumentando la productividad general y competitividad económica. Dado que el estrés laboral genera casi 1 billón de dólares anuales en coste según la OMS, estos desarrollos podrían aliviar una porción significativa de estos costes.

Sin embargo, la implementación inicial del proyecto requiere importantes inversiones económicas, lo que podría no permitir la promoción inmediata de la tecnología y, por lo tanto, crear brechas entre empresas a gran escala y en desarrollo. En segundo lugar, es importante asegurarse de que estas soluciones sean realmente eficaces y no hacer inversiones en sistemas que no funcionarán al 100% en ciertos contextos. Por último, para maximizar el beneficio de la tecnología local, será necesario garantizar el desarrollo de proyectos tecnológicos autónomos a nivel local y no comprar productos extranjeros en esta área en su totalidad.

4.1.5. Impacto en el ámbito medioambiental

La investigación de carga cognitiva y sus aplicaciones tienen un impacto ambiental directo bajo, ya que se utilizan dispositivos EEG de bajo consumo energético y se aprovechan los recursos digitales y de datos que ya están disponibles. Indirectamente, el resultado de la implementación de este proyecto podría ser beneficioso para el

4.2. Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030

medio ambiente, ya que no habría tantos accidentes de transporte y de producción, y no habría fugas tóxicas o vertidos, ya que todos los procesos se optimizarían.

Sin embargo, la popularización masiva podría crear problemas ambientales asociados con la generación de residuos electrónicos (dispositivos obsoletos) y un consumo energético global muy alto si millones de sistemas operan continuamente. Por lo tanto, será necesario garantizar algunos requisitos de sostenibilidad tecnológica, como dispositivos que pueden reciclarse o actualizables y algoritmos eficientes, para no contribuir al desarrollo insostenible.

4.1.6. Impacto en el ámbito cultural

La introducción de tecnología para medir la carga cognitiva también puede transformar la cultura que rodea la relación entre humanos, máquinas y salud mental. La normalización de los indicadores cognitivos en la vida cotidiana puede llevar a la normalización de temas como la fatiga o el estrés mental y, por lo tanto, promover el cuidado personal y un respeto más profundo hacia los límites personales y, lo que es más importante, la comprensión de quién está experimentando qué situación. Por lo tanto, la popularización de estos indicadores también puede promover la ciencia cognitiva de manera más general y hacer que toda la sociedad conozca una terminología específicamente técnica de la neurociencia en cierta medida, incluso en campos como el deporte y el arte.

Por otro lado, posibles resistencias culturales podrían surgir por temor a invasiones de privacidad mental, intrusión corporal o conflictos con creencias personales y espirituales. Análisis de falsedades, como la “lectura de pensamientos,” necesitarán educación y transparencia para generar aceptación.

4.2. Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030

La Agenda 2030 de Naciones Unidas establece 17 Objetivos de Desarrollo Sostenible (ODS) como hoja de ruta para lograr un progreso global equilibrado en lo social, económico y ambiental. Los resultados y enfoques de este trabajo guardan una estrecha relación con varios de estos ODS, haciendo una contribución concreta a ciertos objetivos internacionales. A continuación, se detallan las correspondencias más directas y justificadas:

4.2.1. ODS 3: Salud y Bienestar (Garantizar una vida sana y promover el bienestar para todos)

Este trabajo está alineado directamente con el ODS 3, que busca promover la salud física y mental. Argumentado con la definición de la meta 3.4: “promover bienestar mental”. Al desarrollar métodos para evaluar y manejar la carga cognitiva, el proyecto ofrece herramientas prácticas para prevenir estrés crónico, ansiedad y agotamiento mental extremo en trabajos críticos como la medicina o la aeronáutica, así como para situaciones cotidianas. La prevención de errores debidos al estrés mental reduce accidentes, promoviendo la seguridad vial y física. De hecho, la capacidad para identificar y manejar el estrés mental temprano está impulsando iniciativas concretas para mejorar la salud mental y el bienestar general.

4.2.2. ODS 8: Trabajo Decente y Crecimiento Económico (Promover el crecimiento económico inclusivo y el trabajo decente)

Este trabajo también tiene un impacto directo en este ODS, en particular en la meta 8.8, que busca proteger los derechos laborales y asegurar un entorno seguro y saludable en el trabajo. La evaluación de la carga cognitiva en tiempo real permitirá evitar los accidentes que resultan de la fatiga cognitiva o distracción, lo que mejorará considerablemente la seguridad en el trabajo. Estas tecnologías promueven un empleo más digno al respetar los límites cognitivos gracias a la reducción del estrés, agotamiento y la tasa de rotación, aumentando así la productividad y permitiendo un crecimiento económico más sostenible e inclusivo. Además, permiten tareas de trabajo adaptadas a la capacidad individual y optimizan la gestión del tiempo laboral, lo que previene condiciones de trabajo perjudiciales, creando empleo en condiciones saludables. Por tanto, el proyecto crea las herramientas necesarias para un lugar de trabajo seguro, saludable y sostenible.

4.2.3. ODS 9: Industria, Innovación e Infraestructura (Construir infraestructuras resilientes, promover la industrialización sostenible y fomentar la innovación)

Este proyecto también contribuye directamente al ODS 9, enfocado en fomentar la innovación tecnológica y construir infraestructuras resilientes e inclusivas. Al desarrollar una solución innovadora que combina neurociencia e inteligencia artificial para evaluar la carga cognitiva, el proyecto fortalece infraestructuras críticas (como transporte o producción industrial) frente a fallos humanos, aumentando su resiliencia y seguridad. Además, impulsa la industria 4.0 al promover la digitalización avanzada, creando “fábricas inteligentes” que integran monitoreo cognitivo humano. Este proyecto también fomenta alianzas entre universidades, empresas y centros de investigación, fortaleciendo ecosistemas científicos y tecnológicos. Por tanto, el proyecto potencia la innovación tecnológica, favorece una industrialización inclusiva y sostenible, y proporciona herramientas concretas para infraestructuras más seguras y resilientes.

4.2.4. Otros ODS relevantes

Además de los anteriores, que son los más directamente vinculados, cabe mencionar otros ODS con los que este TFG guarda relación:

ODS 4: Educación de Calidad – Este objetivo persigue garantizar una educación inclusiva y equitativa de calidad. Los hallazgos sobre carga cognitiva pueden aplicarse en entornos educativos para mejorar los procesos de enseñanza-aprendizaje. Por ejemplo, adaptar la carga de trabajo académico al nivel que los estudiantes pueden procesar sin saturarse contribuiría a reducir la deserción escolar y mejorar el desempeño (metas del ODS 4). La tecnología podría ayudar a identificar estudiantes con dificultades de atención o altos niveles de carga, permitiendo intervenciones tempranas. Así, el proyecto apoya una educación de calidad al ofrecer herramientas para personalizar la instrucción y cuidar el bienestar cognitivo de los alumnos, fomentando entornos de aprendizaje más eficaces y saludables.

ODS 10: Reducción de las Desigualdades – Si las soluciones derivadas de esta investigación se implementan ampliamente, pueden ayudar a personas con necesi-

4.2. Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030

dades especiales o con diferentes ritmos cognitivos a integrarse mejor en actividades formativas y laborales. Por ejemplo, individuos con Trastorno de Déficit de Atención (TDAH) u otros desafíos cognitivos podrían beneficiarse de sistemas de apoyo que monitoreen su carga mental, nivelando el campo de juego respecto a sus pares. Esto reduce desigualdades al ofrecer apoyos adaptados a quienes más lo necesitan. Asimismo, es importante que la tecnología en sí sea accesible y asequible para distintos países y comunidades, evitando brechas digitales; el uso de dispositivos no invasivos relativamente económicos como EEG portátiles va en línea con esa accesibilidad.

ODS 11: Ciudades y Comunidades Sostenibles – Dentro de este objetivo, la meta 11.2 busca proporcionar acceso a sistemas de transporte seguros. Como se mencionó, la aplicación de monitores cognitivos en conductores profesionales (autobuses, camiones, taxis) o en control de tráfico urbano puede aumentar significativamente la seguridad vial, contribuyendo a ciudades con menos accidentes de tránsito.

ODS 12: Producción y Consumo Responsables – Si bien de forma tangencial, este TFG aporta a la eficiencia de procesos (producir más con menos errores y desperdicios) y promueve la reutilización de datos y dispositivos existentes. La ciencia de datos aplicada aquí reutiliza datasets abiertos y propone soluciones que evitan pérdidas materiales por errores humanos. Esto resuena con la filosofía de responsabilidad en la producción. También inculca una noción de consumo responsable de tecnología: aprovechar al máximo los dispositivos neurológicos (extendiendo su uso a distintos fines: salud, ergonomía, aprendizaje) para sacarles el mayor valor posible, en lugar de multiplicar gadgets especializados.

ODS 17: Alianzas para lograr los Objetivos – Finalmente, es destacable que este trabajo ejemplifica la importancia de las alianzas multidisciplinarias. Combina conocimiento de ingeniería, neurociencia, psicología y emplea datos recopilados globalmente, algunos provenientes de colaboraciones internacionales (por ejemplo, bases de datos públicas compartidas por la comunidad científica). Esto refleja cómo el avance en un ODS (salud y bienestar, trabajo decente) se apoya en la colaboración entre distintos actores: academia, industria tecnológica, sector salud, etc. Fomentar estas alianzas es precisamente el enfoque del ODS 17. Además, al ser investigación abierta y compartible, otros investigadores alrededor del mundo pueden aprovechar estos hallazgos, potenciando un esfuerzo conjunto para llevar la teoría a aplicaciones prácticas en diversos contextos geográficos. Por tanto, aunque el ODS 17 es más meta-proceso que resultado, el TFG contribuye al mostrar un caso donde el intercambio de conocimiento y la cooperación (entre disciplinas y aprovechando recursos abiertos) aceleran soluciones para desafíos comunes.

4.2.5. Decisiones del proyecto basadas en consideraciones de impacto

A lo largo del TFG se han tomado decisiones metodológicas clave alineadas con principios éticos y de sostenibilidad, destacando las siguientes:

- **Uso de EEG no invasiva:** Elegí electroencefalografía superficial por ser segura, ética, viable y aceptable culturalmente, permitiendo detección precisa y rápida de cambios en carga cognitiva, aumentando así la seguridad.
- **Entorno experimental seguro:** Empleé simulaciones controladas (p.ej., simuladores de vuelo o conducción) para evaluar la carga cognitiva sin exponer a los participantes a riesgos reales, priorizando su bienestar y seguridad (ODS 3).

- **Reutilización de bases de datos abiertas:** Utilicé datasets públicos para evitar redundancias, reducir consumo de recursos y promover la ciencia abierta, facilitando la replicabilidad y el impacto científico-social del trabajo (ODS 17).
- **Robustez y fiabilidad del modelo:** Prioricé desarrollar modelos precisos y validados rigurosamente para minimizar errores críticos en contextos reales, asegurando que las alertas del sistema sean confiables y efectivas (ODS 9).
- **Eficiencia y portabilidad:** Busqué equilibrio entre precisión y viabilidad técnica para permitir implementación eficiente y económica en dispositivos locales, favoreciendo sostenibilidad económica y medioambiental (ODS 9, ODS 12).
- **Ética de datos y privacidad:** Manejé los datos EEG con rigurosidad, ya que se trataban de datos médicos sensibles, incluyendo anonimización y almacenamiento seguro, respetando la privacidad y anticipándome a legislaciones emergentes sobre neuroderechos (ODS 16).

En conclusión, todas estas decisiones tomadas -desde la selección de la tecnología apropiada hasta la forma de validar los resultados- demuestran que el TFG no solo se enfocó en lograr objetivos técnicos, sino que integró una visión holística del impacto. Cada elección metodológica fue informada por la pregunta: “¿Cómo afectará esto a las personas, al entorno de aplicación y a la sociedad en general?”. Gracias a ello, el trabajo no solo aporta una contribución científica, sino que lo hace de manera responsable y alineada con el desarrollo sostenible, maximizando las posibilidades de que sus beneficios potenciales en los ámbitos personal, empresarial, social, económico, medioambiental y cultural se materialicen en la práctica, y minimizando, a su vez, los riesgos asociados.

Bibliografía

- [1] Christopher Wickens. «Multiple Resources and Mental Workload». En: *Human factors* 50 (jul. de 2008), págs. 449-55. DOI: 10.1518/001872008X288394.
- [2] Haleh Aghajani y Ahmed Omurtag. «Assessment of mental workload by EEG+FNIRS». En: vol. 2016. Ago. de 2016. DOI: 10.1109/EMBC.2016.7591549.
- [3] Pietro Aricò et al. «Adaptive Automation Triggered by EEG-Based Mental Workload Index: A Passive Brain-Computer Interface Application in Realistic Air Traffic Control Environment». En: *Frontiers in Human Neuroscience* Volume 10 - 2016 (2016). ISSN: 1662-5161. DOI: 10.3389/fnhum.2016.00539. URL: <https://www.frontiersin.org/journals/human-neuroscience/articles/10.3389/fnhum.2016.00539>.
- [4] Yueying Zhou et al. «Cognitive Workload Recognition Using EEG Signals and Machine Learning: A Review». En: *IEEE Transactions on Cognitive and Developmental Systems* PP (jun. de 2021), págs. 1-1. DOI: 10.1109/TCDS.2021.3090217.
- [5] MNE Developers. *MNE-Python: MEG and EEG data analysis in Python*. <https://mne.tools/stable/index.html>. Accessed: May 26, 2025.
- [6] Gijsbert Stoet. *PsyToolkit Experiment Library: 2-back task*. <https://www.psychtoolbox.org/experiment-library/nback2.html>. Accessed: May 26, 2025.
- [7] Gijsbert Stoet. *PsyToolkit: A software package for programming psychological experiments and surveys*. <https://www.psychtoolbox.org/>. Accessed: May 26, 2025.
- [8] Jonathan W. Peirce y PsychoPy Contributors. *PsychoPy: An open-source application for running experiments in psychology, neuroscience, and psychophysics*. <https://www.psychopy.org/about/index.html>. Accessed: May 26, 2025.
- [9] AdaBase. *Autonomous Driving Cognitive Load Assessment Database*. <https://adabase-dataset.github.io/>. Accessed: May 26, 2025.
- [10] Yury Pavlov et al. *Digit Span Working Memory Load Dataset*. <https://openneuro.org/datasets/ds003838>. Accessed: May 26, 2025.
- [11] IEEE DataPort. *STEW: Simultaneous Task EEG Workload Dataset*. <https://ieee-dataport.org/open-access/stew-simultaneous-task-eeq-workload-dataset>. Accessed: May 26, 2025.
- [12] M. Prithila et al. *CL-Drive Dataset*. <https://github.com/Prithila05/CL-Drive>. Accessed: May 26, 2025.
- [13] Universitat Autònoma de Barcelona. *UAB Mental Workload Dataset (Flight Simulator & Cognitive Tasks)*. <https://ddd.uab.cat/record/259591>. Accessed: May 26, 2025.

- [14] Aura Hernández-Sabaté et al. «EEG Dataset Collection for Mental Workload Predictions in Flight-Deck Environment». En: *Sensors* 24.4 (2024). ISSN: 1424-8220. DOI: 10.3390/s24041174. URL: <https://www.mdpi.com/1424-8220/24/4/1174>.
- [15] Emotiv. *Notes on the Data: DC Offset*. <https://emotiv.gitbook.io/emotivpro-v3/notes-on-the-data/dc-offset>. Accessed: May 26, 2025.
- [16] Fred Shaffer y J. P. Ginsberg. «An Overview of Heart Rate Variability Metrics and Norms». En: *Frontiers in Public Health* Volume 5 - 2017 (2017). ISSN: 2296-2565. DOI: 10.3389/fpubh.2017.00258. URL: <https://www.frontiersin.org/journals/public-health/articles/10.3389/fpubh.2017.00258>.
- [17] Gary G. Berntson et al. «Heart Rate Variability: Origins, Methods, and Interpretive Caveats». En: *Psychophysiology* 34.6 (1997). Accessed: May 26, 2025, págs. 623-648. DOI: 10.1111/j.1469-8986.1997.tb02140.x. URL: <https://pubmed.ncbi.nlm.nih.gov/9401419/>.
- [18] Task Force of the European Society of Cardiology the North American Society of Pacing Electrophysiology. «Heart Rate Variability». En: *Circulation* 93.5 (1996), págs. 1043-1065. DOI: 10.1161/01.CIR.93.5.1043. eprint: <https://www.ahajournals.org/doi/pdf/10.1161/01.CIR.93.5.1043>. URL: <https://www.ahajournals.org/doi/abs/10.1161/01.CIR.93.5.1043>.
- [19] P.G.A.M. Jorna. «Spectral analysis of heart rate and psychological state: A review of its validity as a workload index». En: *Biological Psychology* 34.2 (1992). Special Issue Cardiorespiratory Measures and thier Role in Studies of Performance, págs. 237-257. ISSN: 0301-0511. DOI: [https://doi.org/10.1016/0301-0511\(92\)90017-O](https://doi.org/10.1016/0301-0511(92)90017-O). URL: <https://www.sciencedirect.com/science/article/pii/0301051192900170>.
- [20] L.J.M. Mulder et al. «Cardiovascular state changes during performance of a simulated ambulance dispatchers' task: Potential use for adaptive support». En: *Applied Ergonomics* 40.6 (2009). Psychophysiology in Ergonomics, págs. 965-977. ISSN: 0003-6870. DOI: <https://doi.org/10.1016/j.apergo.2009.01.009>. URL: <https://www.sciencedirect.com/science/article/pii/S0003687009000258>.
- [21] Glenn Wilson. «An Analysis of Mental Workload in Pilots During Flight Using Multiple Psychophysiological Measures». En: *International Journal of Aviation Psychology - INT J AVIAT PSYCHOL* 12 (ene. de 2002), págs. 3-18. DOI: 10.1207/S15327108IJAP1201_2.
- [22] Ying Dong y Chih-Yuan Y. Peng. «Principled missing data methods for researchers». En: *SpringerPlus* 2.1 (2013). Accessed: May 26, 2025, pág. 222. DOI: 10.1186/2193-1801-2-222. URL: <https://springerplus.springeropen.com/articles/10.1186/2193-1801-2-222>.
- [23] Arnaud Delorme y Scott Makeig. «EEGLAB: An open source toolbox for analysis of single-trial EEG dynamics including independent component analysis». En: *Journal of Neuroscience Methods* 134.1 (2004). Accessed: May 26, 2025, págs. 9-21. DOI: 10.1016/j.jneumeth.2003.10.009. URL: <https://pubmed.ncbi.nlm.nih.gov/15102499/>.
- [24] Mike X Cohen. *Analyzing Neural Time Series Data: Theory and Practice*. The MIT Press, ene. de 2014. ISBN: 9780262319553. DOI: 10.7551/mitpress/9609.001.0001. URL: <https://doi.org/10.7551/mitpress/9609.001.0001>.
- [25] Saeid Sanei y J.A. Chambers. «Fundamentals of EEG Signal Processing». En: *EEG Signal Processing*. John Wiley & Sons, Ltd, 2007. Cap. 2, págs. 35-125.

- ISBN: 9780470511923. DOI: <https://doi.org/10.1002/9780470511923.ch2>. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1002/9780470511923.ch2>. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1002/9780470511923.ch2>.
- [26] Fabien Lotte. «A Tutorial on EEG Signal-processing Techniques for Mental-state Recognition in Brain-Computer Interfaces». En: *Guide to Brain-Computer Music Interfacing*. Ed. por Eduardo Reck Miranda y Julien Castet. London: Springer London, 2014, págs. 133-161. ISBN: 978-1-4471-6584-2. DOI: 10.1007/978-1-4471-6584-2_7. URL: https://doi.org/10.1007/978-1-4471-6584-2_7.
 - [27] Scott Makeig et al. «Independent Component Analysis of Electroencephalographic Data». En: *Advances in Neural Information Processing Systems*. Ed. por D. Touretzky, M.C. Mozer y M. Hasselmo. Vol. 8. MIT Press, 1995. URL: https://proceedings.neurips.cc/paper_files/paper/1995/file/754dda4b1ba34c6fa89716b8Paper.pdf.
 - [28] Ricardo Vigário et al. «Independent component approach to the analysis of EEG and MEG recordings». En: *IEEE transactions on bio-medical engineering* 47 (jun. de 2000), págs. 589-93. DOI: 10.1109/10.841330.
 - [29] Emotiv. *Emotiv EPOC X: Technical Specifications*. <https://emotiv.gitbook.io/epoc-x-user-manual/introduction/technical-specifications>. Accessed: May 26, 2025.
 - [30] L. Sörnmo y Pablo Laguna. *Bioelectrical Signal Processing in Cardiac and Neurological Applications*. Ene. de 2005. ISBN: 0-12-437552-9. DOI: 10.1016/B978-0-12-437552-9.X5000-4.
 - [31] Robert Oostenveld et al. «FieldTrip: Open source software for advanced analysis of MEG, EEG, and invasive electrophysiological data». En: *Computational Intelligence and Neuroscience 2011* (2011). Accessed: May 26, 2025, págs. 1-9. DOI: 10.1155/2011/156869. URL: <https://pubmed.ncbi.nlm.nih.gov/21253357/>.
 - [32] Michal Teplan. «Fundamental of EEG Measurement». En: *MEASUREMENT SCIENCE REVIEW* 2 (ene. de 2002).
 - [33] S. Butterworth. «On the Theory of Filter Amplifiers». En: *Experimental Wireless and the Wireless Engineer* 7 (1930). Accessed: May 26, 2025, págs. 536-541. URL: <https://www.scirp.org/reference/referencespapers?referenceid=635334>.
 - [34] Steven W. Smith. *The Scientist and Engineer's Guide to Digital Signal Processing*. Accessed: May 26, 2025. California Technical Publishing, 1997. URL: <https://www.dspguide.com/>.
 - [35] C.E. Shannon. «Communication in the Presence of Noise». En: *Proceedings of the IRE* 37.1 (1949), págs. 10-21. DOI: 10.1109/JRPROC.1949.232969.
 - [36] National Instruments. *Acquiring an Analog Signal – Bandwidth Nyquist Sampling Theorem*. [Online; accessed 26-May-2025]. 2025. URL: https://www.ni.com/es/shop/data-acquisition/measurement-fundamentals/analog-fundamentals/acquiring-an-analog-signal--bandwidth--nyquist-sampling-theorem-.html?srsId=AfmBOopSYF6LiJrZjKMH6QJ_MMWm7jV46SvQu8FuQbQF
 - [37] A. Hyvärinen y E. Oja. «Independent component analysis: algorithms and applications». En: *Neural Networks* 13.4 (2000), págs. 411-430. ISSN: 0893-6080. DOI: [https://doi.org/10.1016/S0893-6080\(00\)00026-5](https://doi.org/10.1016/S0893-6080(00)00026-5). URL: <https://www.sciencedirect.com/science/article/pii/S0893608000000265>.

- [38] Ruhi Mahajan y Bashir I. Morshed. «Unsupervised Eye Blink Artifact Denoising of EEG Data with Modified Multiscale Sample Entropy, Kurtosis, and Wavelet-ICA». En: *IEEE Journal of Biomedical and Health Informatics* 19.1 (2015), págs. 158-165. DOI: 10.1109/JBHI.2014.2333010.
- [39] H. H. Jasper et al. «The ten-twenty electrode system of the International Federation». En: *Electroencephalography and Clinical Neurophysiology* 10 (1958). Accessed: May 26, 2025, págs. 371-375. URL: <https://pubmed.ncbi.nlm.nih.gov/10590970/>.
- [40] A. Hyvarinen. «Fast and robust fixed-point algorithms for independent component analysis». En: *IEEE Transactions on Neural Networks* 10.3 (1999), págs. 626-634. DOI: 10.1109/72.761722.
- [41] Arnaud Delorme, Terrence Sejnowski y Scott Makeig. «Enhanced detection of artifacts in EEG data using higher-order statistics and independent component analysis». En: *NeuroImage* 34.4 (2007). Accessed: May 26, 2025, págs. 1443-1449. DOI: 10.1016/j.neuroimage.2006.11.004. URL: <https://pubmed.ncbi.nlm.nih.gov/17188898/>.
- [42] Alexandre Gramfort et al. «MEG and EEG data analysis with MNE-Python». En: *Frontiers in Neuroscience* Volume 7 - 2013 (2013). ISSN: 1662-453X. DOI: 10.3389/fnins.2013.00267. URL: <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2013.00267>.
- [43] Vladimir Jurcak, Daisuke Tsuzuki e Ippeta Dan. «10/20, 10/10, and 10/5 systems revisited: their validity as relative head-surface-based positioning systems». En: *NeuroImage* 34.4 (2007). Accessed: May 26, 2025, págs. 1600-1611. DOI: 10.1016/j.neuroimage.2006.09.024. URL: <https://pubmed.ncbi.nlm.nih.gov/17207640/>.
- [44] Julie Onton et al. «Imaging human EEG dynamics using independent component analysis». En: *Neuroscience & Biobehavioral Reviews* 30.6 (2006). Accessed: May 26, 2025, págs. 808-822. DOI: 10.1016/j.neubiorev.2006.06.007. URL: <https://pubmed.ncbi.nlm.nih.gov/16904745/>.
- [45] Tzyy-Ping Jung et al. «Removing electroencephalographic artifacts by blind source separation». En: *Psychophysiology* 37.2 (2000). Accessed: May 26, 2025, págs. 163-178. DOI: 10.1111/1469-8986.3720163. URL: <https://pubmed.ncbi.nlm.nih.gov/10731767/>.
- [46] Pietro Aricò et al. «Adaptive Automation Triggered by EEG-Based Mental Workload Index: A Passive Brain-Computer Interface Application in Realistic Air Traffic Control Environment». En: *Frontiers in Human Neuroscience* Volume 10 - 2016 (2016). ISSN: 1662-5161. DOI: 10.3389/fnhum.2016.00539. URL: <https://www.frontiersin.org/journals/human-neuroscience/articles/10.3389/fnhum.2016.00539>.
- [47] Thomas F. Collura. «Technical Foundations of Neurofeedback». En: *Technical Foundations of Neurofeedback*. Vol. 1. Accessed: May 26, 2025. Routledge, 2014, págs. 105-110. DOI: 10.4324/9780203795132. URL: <https://www.taylorfrancis.com/books/mono/10.4324/9780203795132/technical-foundations-neurofeedback-thomas-collura>.
- [48] P. Welch. «The use of fast Fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms». En: *IEEE Transactions on Audio and Electroacoustics* 15.2 (1967), págs. 70-73. DOI: 10.1109/TAU.1967.1161901.

-
- [49] Ernst Niedermeyer y Fernando H. Lopes da Silva. *Electroencephalography: Basic Principles, Clinical Applications, and Related Fields*. Lippincott Williams & Wilkins, 2005, págs. 167-192.
 - [50] Chris Berka et al. «EEG correlates of task engagement and mental workload in vigilance, learning, and memory tasks». En: *Aviation, space, and environmental medicine* 78 (jun. de 2007), B231-44.
 - [51] Joel F. Lubar. «Neocortical dynamics: Implications for understanding the role of neurofeedback and related techniques for the enhancement of attention». En: *Applied Psychophysiology and Biofeedback* 22.2 (1997). Accessed: May 26, 2025, págs. 111-126. URL: <https://www.scirp.org/reference/referencespapers?referenceid=955936>.
 - [52] Robert J. Barry et al. «EEG differences between eyes-closed and eyes-open resting conditions». En: *Clinical Neurophysiology* 118.12 (2007). Accessed: May 26, 2025, págs. 2765-2773. DOI: 10.1016/j.clinph.2007.07.028. URL: <https://pubmed.ncbi.nlm.nih.gov/17911042/>.
 - [53] Andreas Keil et al. «Human Gamma Band Activity and Perception of a Gestalt». En: *Journal of Neuroscience* 19.16 (1999), págs. 7152-7161. ISSN: 0270-6474. DOI: 10.1523/JNEUROSCI.19-16-07152.1999. eprint: <https://www.jneurosci.org/content/19/16/7152.full.pdf>. URL: <https://www.jneurosci.org/content/19/16/7152>.
 - [54] Universitat Autònoma de Barcelona. *UAB Dataset: EEG signals under cognitive tasks (eyes open/closed, arithmetic, memory, digit span)*. <https://ddd.uab.cat/record/289812>. Accessed: May 26, 2025. 2024.
 - [55] Wikipedia contributors. *Efecto Hawthorne – Wikipedia, La enciclopedia libre*. https://es.wikipedia.org/wiki/Efecto_Hawthorne. Accessed: May 26, 2025.
 - [56] Securities.io. *Las 5 mejores empresas de interfaces cerebro-computadoras (BCI)*. [https://www.securities.io/es/Las-5-mejores-empresas-de-interfaces-cerebro-computadoras-\(BCI\)](https://www.securities.io/es/Las-5-mejores-empresas-de-interfaces-cerebro-computadoras-(BCI)) /. Accessed: May 26, 2025. 2023.

Apéndice A

Anexo

Enlace al repositorio de GitHub dónde se encuentra alojado el proyecto: \url <https://github.com/danillopis/TFG>